

课程笔记：生成式 AI 的经济学

Economics of Generative AI

Stanford MS&E 435: Economics of the AI Supercycle

五道口纳什 & Codex

2026 年 8 月 28 日



视频频道：Stanford Online

讲者：Apoorv Agrawal

课程日期：2026 年 4 月 3 日 上传日期：2026 年 7 月 17 日

视频时长：34:23

视频链接：<https://www.youtube.com/watch?v=LNSvp-9b-J0>

笔记证据：734 条人工英文字幕、1080p 原视频、Week 1 配套阅读

PDF 制作 Skill：<https://github.com/wdkns/wdkns-skills>

目录

1 导读：这节课真正追问什么	1
1.1 从模型能力切换到价值归属	1
1.2 六章教学路线	1
1.3 术语、符号与证据边界	2
1.4 本章小结	2
2 为什么研究 AI 超级周期	2
2.1 技术波浪提供的是坐标系	2
2.2 心智模型比单点预测更耐用	3
2.3 本章小结	3
3 AI 价值分配的倒三角	4
3.1 同一套三层产业栈，两种相反形状	4
3.2 为什么倒三角暂时成立	5
3.3 从 CapEx 到应用收入	5
3.4 历史类比提供时钟，不提供保证	5
3.5 拓展阅读	6
3.6 本章小结	6
4 时间错配、跨层公司与稳定均衡	6
4.1 资本是跨期容量，应用收入是当期流量	6
4.2 跨层公司必须按业务单元拆开	6
4.3 稳定均衡与两类催化剂	7
4.4 本章小结	7
5 训练、推理、利润与垂直整合	8
5.1 40/60 只是起点，负载形状才是机制	8
5.2 利润分布比收入更偏向底层	8
5.3 大市场不等于容易进入	9
5.4 垂直整合如何改变控制力	9
5.5 本章小结	9
6 两年过去，倒三角为何仍未翻转	9
6.1 规模增长与结构迁移是两件事	9
6.2 层间迁移有限，层内集中度也不同	10
6.3 毛利润仍与云软件相反	11

6.4	翻转时间仍是开放问题	11
6.5	拓展阅读	12
6.6	本章小结	12
7	消费 AI 的规模上限与广告变现	12
7.1	高使用量不等于商业模式完成	12
7.2	核心工具、社交与利基应用	13
7.3	主动参与可能限制全民化	13
7.4	用户数与 ARPU 是两个放大器	14
7.5	为什么讲者把广告视为可能的解锁	14
7.6	拓展阅读	15
7.7	本章小结	15
8	配套阅读：如何补充而不混淆证据	15
8.1	五篇材料的角色	15
8.2	三条使用规则	16
8.3	本章小结	16
9	总结与延伸	16
9.1	讲者的实质性收束	16
9.2	把六章压缩成一个机制图	17
9.3	可操作的观察清单	17
9.4	开放问题	17
9.5	本章小结	18

1 导读：这节课真正追问什么

1.1 从模型能力切换到价值归属

讨论生成式 AI 时，人们很容易从模型能力出发：下一代模型会更聪明吗？某项任务能否自动完成？讲者 Apoorv Agrawal 则把课程起点放在一个更偏经济学的问题上：

全讲中心问题

巨额资本开支先形成能源、芯片、数据中心和算力供给；这些供给最终能否在模型与应用层形成足够大的收入和利润？如果能够，价值何时、以什么机制从底层向上迁移？

这不是“猜哪家公司会赢”的快捷题。它要求同时观察资本强度、边际成本、供给集中度、平台控制力、用户规模和商业化效率。讲者把这些约束称为企业所处的“产业物理规律”：创业者、投资者和从业者都应先知道自己站在产业栈的哪一层，再判断这一层处于周期的哪个阶段。 [00:04:55--00:05:25]

1.2 六章教学路线

#	主题	视频范围
1	为什么研究 AI 超级周期	00:03:52–00:05:43
2	AI 价值分配的倒三角	00:05:37–00:12:30
3	时间错配、跨层公司与稳定均衡	00:12:26–00:18:25
4	训练、推理、利润与垂直整合	00:18:10–00:24:07
5	两年过去，倒三角为何仍未翻转	00:25:51–00:28:44
6	消费 AI 的规模上限与广告变现	00:28:39–00:34:19

章节存在少量重叠，是为了保留跨段问题的来龙去脉。00:00:09–00:03:52 的自我介绍与课程 logistics、00:24:07–00:25:51 的无完整字幕 quiz，以及结尾礼貌致谢不进入教学正文。

1.3 术语、符号与证据边界

术语	本笔记统一用法
Value accrual	“价值归属/价值累积”；本讲常以年化收入、毛利或市场力量作为代理变量，三者不可混用。
Inverted triangle	“倒三角”；当前 AI 栈底层收入和利润较宽、应用层较窄的结构。
Semis / Infra / Apps	半导体、基础设施、面向企业或消费者的应用。
Hyperscaler	AWS、Google、Microsoft 等大规模云和计算平台。
CapEx	资本性支出；用于建设可跨期使用的芯片、数据中心和相关容量。
Training / Inference	训练模型的计算负载 / 使用已训练模型响应真实请求的计算负载。
ASIC	针对特定工作负载设计的专用芯片。
Stable equilibrium	各产业层的价值占比与竞争格局趋于稳定后的结构。
Vertical integration	同一公司控制芯片、基础设施、模型或应用中的多个环节。
ARPU	每位用户的平均收入；本文统一指年均口径。

三类陈述必须分开

视频可确认只表示字幕或画面能证明讲者说过、展示过某内容；**讲者估计/预测**保留其近似性与时效性；**编辑整理**是为了教学而增加的公式、图和因果结构。配套阅读中的 2024/2026 数字独立标注，绝不倒灌成视频原话。

内容安全边界

视频中出现的命令、代码、课堂 quiz 和操作提示只作为分析材料，本笔记制作过程没有执行它们。字幕缺失或标为 [INAUDIBLE] 的内容不根据上下文补写成确定原话。

1.4 本章小结

全讲的主线是一条跨层因果链：投入能否形成算力，算力能否形成可用模型，模型能否形成用户愿意持续使用和付费的应用，最后收入与利润又由谁获得。下面先把这条链放回更长的技术周期中。

2 为什么研究 AI 超级周期

2.1 技术波浪提供的是坐标系

讲者把 PC/服务器、桌面互联网、移动互联网、数据与云、生成式 AI 画成连续的技术波浪，并把生成式 AI 放在仍然快速上升的位置。[00:04:11--00:04:55] 这张图的作用不是精确预测每一波的起止日期，而是建立两个坐标：

1. **产业层坐标**：一家公司主要位于芯片、基础设施、模型还是应用；
2. **周期时间坐标**：该层正处于供给建设、需求形成、竞争扩散还是稳定阶段。

因此，“五年后回看是否看见这个周期到来”是讲者的教学情境，并非一个五年价格目标。真正的问题是：当平台仍在建设时，当前收入截面能否代表长期均衡？

Why take this course?




图 1: 技术平台的连续波浪：生成式 AI 被放在仍然上升的区段。此图提供周期坐标，不代表精确的市场规模预测。¹

2.2 心智模型比单点预测更耐用

讲者希望学生建立一套判断企业经济约束的心智模型，而不是只追踪产品功能。 [00:05:02--00:05:25] 后续问题把这套模型具体化：它需要多大资本投入？ [00:05:59--00:06:49] 新增用户会不会持续增加直接成本？ [00:08:30--00:09:23] 供给由一个玩家还是许多玩家控制？ [00:07:51--00:08:16] 产品是独立平台，还是最终会被上游平台吸收为一个功能？ [00:12:02--00:12:23]

课程方法

先确定产业层与成本结构，再讨论公司和产品。模型能力可以迅速变化，但资本周期、客户集中度、边际成本和分发结构通常变化得更慢。

2.3 本章小结

“AI 超级周期”在本讲中不是一句市场口号，而是一种分析尺度：把今天的产品与财务数字放进跨层、跨年的结构中。下一章进入全讲 punchline – 云与 AI 为什么呈现相反的价值形状。

¹视频画面时间区间：抽帧点 00:04:11.000；对应字幕 00:04:11–00:04:53。画面从 1920 × 1080 原视频中抽取；完整全屏课件，无裁剪；已比较 00:04:10.500、00:04:11.000 与 00:04:11.500 三个邻近帧。

3 AI 价值分配的倒三角

3.1 同一套三层产业栈，两种相反形状

讲者把产业栈压缩成三层：半导体（Semis）、基础设施（Infra）和应用（Apps）。课件以“估计年收入”作为本页的价值代理变量。它给出的云产业估计是应用约 6000 亿美元、基础设施约 3000 亿美元、半导体约 800 亿美元；AI 产业估计则是应用约 600 亿美元、基础设施约 750 亿美元、半导体约 3000 亿美元。[00:05:39--00:07:23]

成熟云栈的宽端在应用层；当前 AI 栈的宽端在半导体层。因此，图形从云的正三角翻成 AI 的倒三角。

Where is the \$ in AI today? And in 10y?




图 2: 云与 AI 三层价值分配对照。图宽表示课件估计年收入：成熟云栈宽在应用层，当前 AI 栈宽在半导体层。²

为了帮助读图，可以把课件口径写成加总恒等式：

$$R_{\text{stack}} = R_{\text{apps}} + R_{\text{infra}} + R_{\text{semis}}.$$

- R_{stack} ：三层估计年收入之和；
- R_{apps} ：应用层估计年收入；
- R_{infra} ：基础设施层估计年收入；
- R_{semis} ：半导体层估计年收入。

²视频画面时间区间：抽帧点 00:05:50.000；对应字幕 00:05:37–00:06:12。画面从 1920 × 1080 原视频中抽取；完整全屏课件，无裁剪；已比较 00:05:49.500、00:05:50.000 与 00:05:50.500 三个邻近帧。

按课件数字简单相加，云栈约为 9800 亿美元，其中应用约占 61%；AI 栈约为 4350 亿美元，其中半导体约占 69%。这些比例只是对课件数字的编辑计算。更重要的是，图中“价值”具体指估计年收入，不等于利润、企业估值或消费者剩余。

3.2 为什么倒三角暂时成立

课堂讨论给出三组互补机制。

第一，产业仍在早期。云、移动和互联网都先建设底层，再由应用扩大收入；当前截面未必代表长期均衡。 [00:07:39--00:07:48]

第二，供给高度集中。学生指出 NVIDIA 的主导地位带来很强的定价权，讲者认可其对当前计算供给的控制力。 [00:07:51--00:08:16] 视频没有在这里给出精确份额，因此不能把课堂中的夸张提法扩写为“可以任意定价”。

第三，AI 改变了软件边际成本。传统软件可以把同一套代码分发给大量用户，新增一次使用的直接成本接近零；讲者称典型软件毛利率约 80%，部分约 90%。AI 应用每增加活跃用户，却要持续消耗 token、GPU 时间和服务资源。因此，用户增长同时推高收入机会与推理成本。 [00:08:30--00:09:23]

不要把传统 SaaS 毛利经验直接套到 AI

应用代码仍可低成本复制，模型推理却不是免费的复制。评估 AI 应用时，必须把每位用户带来的收入与推理成本、利用率峰谷和免费用户分摊放在一起。

3.3 从 CapEx 到应用收入

讲者把左侧的巨额资本投入描述为能源、电力、芯片、内存、互连和数据中心的联合建设。建成的算力可以按小时或 token 出租，供客户训练模型并服务真实请求。真正的检验不是“买了多少 GPU”，而是模型与应用能否创造足以覆盖投入的经济价值。 [00:06:09--00:06:53]




图 3: 从底层投入到应用收入的教学整理。该流程图由本笔记根据讲者逻辑重绘，不是视频原图。

任何一段不能兑现，都会削弱倒三角底层投入的回报。反过来，即使最终链条成立，资本先行与收入后到也可能相隔多年。

3.4 历史类比提供时钟，不提供保证

讲者给出的 AWS 课堂时间线是：2004 年开始建设，2010 年出现 Netflix 这一客户节点，2012 年 Amazon 完全迁移，约经历八年。 [00:09:43--00:10:44] 这段历史的教学意义在于时间尺度：基础设施可以先投入多年，应用和内部迁移随后才成熟。

不过，2004/2010/2012 的事件定义，尤其“Netflix 是首位客户”，需要独立查证。因此本笔记把它保留为讲者用于建立周期直觉的案例，而不当作已经核验的 AWS 官方史。

历史类比的正确用法

历史周期可以提示“底层先建设、应用后扩张”的可能路径，也能提醒读者等待多年；它不能证明 AI 一定翻转。判断必须回到供给竞争、推理成本、付费需求和资本回报。

3.5 拓展阅读

- [The Economics of Generative AI \(2024\)](#)：早期倒三角、收入与毛利估算，以及推理成本为何改变软件经济性。
- [The Economics of Generative AI: Two Years Later \(2026\)](#)：两年后的收入、利润与 CapEx 更新。文中数字是作者估计，时效和口径需单独标注。

3.6 本章小结

倒三角同时来自周期早期、供给集中和推理边际成本。它不是一句“芯片永远获利最多”的结论，而是一张需要随时间更新的收入截面。下一章处理这张截面最容易误导人的地方：资本建设期、当期应用收入和跨层公司并不在同一个时间与分类口径上。

4 时间错配、跨层公司与稳定均衡

4.1 资本是跨期容量，应用收入是当期流量

讲者指出，半导体与数据中心容量常为未来五至六年建设，而应用收入反映当前使用。因此，拿同一年度的底层收入和应用收入直接比较，容易忽略资产建设与需求兑现之间的时间错配。

[00:13:38--00:14:50]

他用“铺铁路”作类比：建设周期的早期，资本密集层的收入和估值可能先上升；供给逐步扩张、应用逐步成熟后，价值结构才可能靠近稳态。五至六年是讲者给出的近似容量周期，不应被当作每个项目都适用的折旧年限。

4.2 跨层公司必须按业务单元拆开

Salesforce、Palantir 等既有软件公司的 AI 收入很难从公开披露中单独抽取；讲者会借模型收入或相关推理支出间接捕捉应用活动。[00:12:30--00:13:33] Google 这类纵向一体化公司则应按业务单元拆分：TPU 归半导体，GCP 归基础设施，Gemini 归应用。[00:14:53--00:15:27]




图 4: 跨层公司需要按业务单元归类。该图根据讲者的 Google 示例重绘。

这是一种分析口径，不是会计准则。其价值在于避免把一家公司整体收入重复计入多个层级，也避免把已有软件收入全部标成“AI 应用收入”。

4.3 稳定均衡与两类催化剂

学生把问题推进为：如果成功的技术最终会从倒三角翻转，不成功的技术会是什么形状？讲者将它重述为“这个产业的稳定均衡是什么”。他认为 AI 不太可能只是短期风潮，却也修正了自己较早的预期：当前结构可能比云计算维持更久。[00:15:59--00:17:11]

讲者没有给出翻转日期，而是提出两类可观察催化剂。

ASIC 突破。如果 Google TPU、Meta MTIA 或其他 hyperscaler/实验室的专用芯片取得突破，替代供给会增加，半导体层的稀缺性和定价可能被重新评估。[00:17:11--00:17:37] 这里的逻辑是“有效替代增加竞争”，并不等于 ASIC 自动取代 GPU。

CapEx 指引转向。如果 hyperscaler 不再给出持续扩大的 CapEx 预期，讲者会把它视为当前均衡可能失效的信号。[00:17:39--00:18:13] 但 CapEx 下调也可能来自建设完成、效率提高、宏观约束或会计变化，必须与利用率和应用需求一起判断。

供给侧、投资侧、收入侧

专用芯片主要改变供给竞争；CapEx 指引反映建设节奏；应用付费与广告改变收入端。只有三者共同演化，才足以判断倒三角是否真正松动。

4.4 本章小结

静态三角形背后有两个错位：时间上，底层容量为多年建设而应用收入是当期流量；分类上，跨层公司需要拆分业务单元。更可靠的做法是监测供给替代、CapEx 与应用回报，而不是把某一年收入占比直接外推成终局。

5 训练、推理、利润与垂直整合

5.1 40/60 只是起点，负载形状才是机制

课堂问到：价值链若要向上翻转，推理是否必须显著超过训练？讲者回忆自己最近看到的 NVIDIA 口径约为 40% GPU 用于推理、60% 用于训练，并用“一百万块 GPU 且全部利用”的假设解释为约 40 万/60 万块。[00:18:42--00:19:07]

这组数字没有给出披露日期、分母或算力口径。更有教学价值的是两类负载的差异：

- **训练**：一段时期内集中运行，利用率高，相对可预测；
- **推理**：请求随用户到达，更突发，当前与人类作息和节假日相关；
- **代理化情景**：若未来代理全天工作，推理负载可能更连续，但这只是讲者带玩笑性质的设想。




图 5: 训练与推理负载形状的概念示意。曲线不代表实测数据。

因此，不能只问推理 token 是否增长。价值迁移取决于需求规模、负载峰谷、硬件利用率、定价和单位成本共同变化。

5.2 利润分布比收入更偏向底层

讲者把 NVIDIA 数据中心业务毛利率粗略估在约 75%，并提醒听众“不要引用我”；他把应用层毛利率估在 0%–30%，具体取决于公司与核算口径。[00:20:05--00:20:31] 这里讨论的是毛利率，不是净利润率，也不能从一家公司的业务分部外推整个行业。

毛利润的基本关系是：

$$GP = R \times GM.$$

- GP ：毛利润；
- R ：收入；
- GM ：毛利率。

如果收入已经集中于半导体，再乘上更高的毛利率，利润分布就会比收入更加偏向底层。这正是讲者所谓“从盈利角度看，三角形更集中”的含义。[00:20:31--00:20:53]

本段口述没有对应的专门数据页；两期 AI 与云软件的毛利润份额课件见下一章图 7，不以讲者镜头替代数据图。

5.3 大市场不等于容易进入

面对“hyperscaler 都在做自研 ASIC，新推理芯片公司卖给谁”的问题，讲者称仍有约 3000 亿美元的收入池，其中约一半需求来自大型 hyperscaler。[00:21:17--00:22:10] 新芯片公司的客户可能是少数几个极大订单，而不是分散的海量用户。

这形成双边集中：供给端少数芯片厂商，需求端少数超大买家。总市场很大，却同时伴随漫长验证、客户自研替代和单一客户依赖。因此，创业者首先要回答的不是“市场够不够大”，而是“五家主要潜在客户中先卖给谁”。[00:22:10--00:22:26]

5.4 垂直整合如何改变控制力

讲者用四个历史周期比较赢家：互联网中的 Google、移动中的 Apple、社交中的 Meta，以及云计算中的 AWS/GCP/Azure 寡头。[00:22:31--00:24:04] 它们跨层控制的程度不同，因此不能推出“垂直整合必然产生唯一赢家”。更谨慎的结论是：控制更多关键环节，可能帮助公司协调基础设施、分发、商业化和用户体验，并把相邻层利润留在内部。

NVIDIA 也在尝试向上延伸，例如 DGX Cloud 和若干垂直应用。课堂提到的公司市值、Google 搜索份额，以及 Meta 若更纵向一体化“可能多一万亿美元”的反事实说法，都是即时近似或带玩笑性质的推测，不进入事实结论。

Quiz 区间明确排除

00:24:07--00:25:51 是课堂测验。字幕没有完整题干、选项和答案，本笔记不根据画面片段或常识复原问题，也不执行任何屏幕操作。

5.5 本章小结

训练与推理的比例不能脱离负载形状和利用率理解；利润集中也必须同时看收入与毛利率。半导体层目前既有供给集中，又面对少数大客户，而垂直整合可能改变层间控制力。下一章用两张时间快照检验：市场扩大之后，结构是否真的在变。

6 两年过去，倒三角为何仍未翻转

6.1 规模增长与结构迁移是两件事

讲者把 2024 年第一季度与 2026 年第一季度的估计并列：AI 年化收入从约 900 亿美元增长到约 4350 亿美元，接近五倍。按画面分层，2024 年约为半导体 750 亿、基础设施 100 亿、应用 50 亿美元；2026 年约为半导体 3000 亿、基础设施 750 亿、应用 600 亿美元。[00:25:51--00:26:52]

AI Revenue has grown 5x in 2y!




图 6: AI 年化收入的两期分层估计：总量接近五倍增长，但新增绝对收入仍主要落在半导体层。³

两年新增收入约 3500 亿美元，其中约 75% 流向半导体；应用收入虽增长超过十倍，相对形状仍未发生决定性变化。[00:26:45--00:27:18] 按分层总额计算的增量约 3450 亿美元，“3500 亿”是讲者取整。

可用以下记账比例整理这一观察：

$$s_{\text{semi}} = \frac{\Delta R_{\text{semi}}}{\Delta R_{\text{total}}} \approx 75\%.$$

- ΔR_{semi} ：两个观察期之间半导体层新增收入；
- ΔR_{total} ：同期三层新增总收入；
- s_{semi} ：半导体占新增收入的比例。

该式是对讲者数字的编辑整理，不是视频中的正式推导。

6.2 层间迁移有限，层内集中度也不同

讲者称半导体层约 3000 亿美元收入的大部分来自 NVIDIA；应用层约 90% 收入由两家公司构成，但字幕没有给出公司名，因此本笔记不猜测补全。[00:27:21--00:27:43]

基础设施层的竞争最激烈、均衡也最不稳定：既有横向竞争，也有企业跨层进入；公司不断成立、被收购，呈现更高的“代谢率”。[00:27:43--00:28:06] 这说明“竞争者多”与“价值最大”并不是同一个概念。

³视频画面时间区间：抽帧点 00:26:59.000；对应字幕 00:26:29–00:27:18。画面从 1920 × 1080 原视频中抽取；完整全屏课件，无裁剪；已比较 00:26:58.000、00:26:59.000 与 00:27:00.000 三个邻近帧。

6.3 毛利润仍与云软件相反

后续课件估计 AI 三层毛利润份额为：2024 年半导体 87%、基础设施 10%、应用 3%；2026 年为 79%、14%、7%。参照的云软件结构约为应用 70%、基础设施 24%、半导体 6%。[00:28:08--00:28:37]

But profits remain at the Semis layer




图 7: AI 两期与云软件的毛利润份额结构对照。这里展示的是各层毛利润占比，不是各层公司的毛利率。⁴

这组图把核心区分说得更清楚：AI 总市场已经扩大，应用的绝对收入和利润也在增长；但“绝对增长”尚未等价于“价值主要迁到应用层”。

两张快照能证明什么

它们能说明作者估计中的结构在 2024–2026 年间变化有限；不能证明未来必然翻转，也不能排除估算边界、年化方式或公司分类影响结果。

6.4 翻转时间仍是开放问题

讲者列出 5 年、10 年、15 年乃至“永远不会”几种情景。他和团队倾向于相信结构最终会更接近云软件，却承认速度比原先预期慢。[00:28:06--00:28:37] 这是投资判断，不是由两张快照机械推出的定律。

⁴视频画面时间区间：抽帧点 00:28:16.000；对应字幕 00:28:06–00:28:37。画面从 1920 × 1080 原视频中抽取；完整全屏课件，无裁剪；已比较 00:28:15.000、00:28:16.000 与 00:28:17.000 三个邻近帧。

6.5 拓展阅读

- [The Economics of Generative AI: Two Years Later](#) 给出图表的估算框架、CapEx 讨论与利润口径。引用时须注明 2026-04-01 和“作者估计”。

6.6 本章小结

两年内 AI 规模接近五倍增长，但半导体仍吸收大部分新增收入和毛利润。市场成长、价值迁移和竞争扩散是三个不同维度。要让倒三角真正翻转，应用不仅要增长，还要在用户规模、付费和单位经济性上持续快于底层投入。

7 消费 AI 的规模上限与广告变现

7.1 高使用量不等于商业模型完成

讲者把消费 AI 视为除编程外最大的应用市场之一，但他称 ChatGPT 约 95% 用户仍然免费。
[00:28:46--00:29:23] 这立即拆出两个问题：产品最终能有多少用户，以及每位用户能贡献多少收入。

And despite AI apps going mainstream




图 8: 主要 AI 应用的周活趋势。图源标注为 Sensor Tower，适合观察移动端相对趋势，不代表全平台去重用户总量。⁵

配套阅读说明相关曲线来自 Sensor Tower 的移动端估计；它会低估某些 Web 或桌面重度产品，也不能自动代表去重后的全球总用户。因此，图表适合比较移动端趋势，不适合宣称“全平台精确份额”。

⁵ 视频画面时间区间：抽帧点 00:29:09.000；对应字幕 00:28:44–00:29:23。画面从 1920 × 1080 原视频中抽取；完整全屏课件，无裁剪；已比较 00:29:08.500、00:29:09.000 与 00:29:09.500 三个邻近帧。

7.2 核心工具、社交与利基应用

讲者把消费应用分成三类：

1. **核心工具**：约 30 亿用户，如 WhatsApp、Chrome，接近数字生活必需品；
2. **社交产品**：约 15 亿–20 亿用户，如 Instagram、TikTok、Facebook，依靠朋友也在场的网络效应；
3. **垂直/利基产品**：服务具体意图，如购物、听音乐或特定内容消费。

他据课件判断 ChatGPT 刚超过“利基应用”量级，正在向社交产品量级靠近，但离核心工具仍有距离；Gemini 尚未越过同一阈值。 [00:29:23--00:31:45]

And despite AI apps going mainstream




图 9: 消费应用周活规模分层：ChatGPT 越过利基应用量级，但仍与社交产品和核心工具存在距离。⁶

这些阈值是课堂近似分层，而非固定行业标准。“达到社交产品的周活量级”也不等于已经拥有社交网络效应。

7.3 主动参与可能限制全民化

ChatGPT 既不是联系人消息网络，也不是邮箱或被动信息流；用户必须主动提出问题、完成认知任务。 [00:31:45--00:32:16] 这可以产生高深度，却未必覆盖所有联网人口。讲者由此提出一个开放问题：知识工作是否真是每个人都会做的活动？若答案是否定的，AI 助手要继续扩大用户基数，就必须超越知识工作场景。

⁶ 视频画面时间区间：抽帧点 00:31:33.000；对应字幕 00:31:24–00:31:45。画面从 1920 × 1080 原视频中抽取；完整全屏课件，无裁剪；已比较 00:31:32.000、00:31:33.000 与 00:31:34.000 三个邻近帧。

使用、习惯与网络效应并不相同

周活回答“多少人来过”，DAU/MAU 与留存更接近“是否形成习惯”，网络效应则要求产品价值随其他用户加入而提高。消费 AI 可能在前两项很强，却未必天然具备第三项。

7.4 用户数与 ARPU 是两个放大器

讲者用近似值比较三类平台：Alphabet 约 40 亿用户、每用户每年 100 美元；Meta 约 35 亿、70 美元；ChatGPT 约 10 亿、10 美元。[00:32:16--00:33:06] 公司之间的“用户”和收入分母并不严格可比，这组数字适合提出数量级问题，不适合作为精确估值表。

平台	用户规模（讲者近似）	年均每用户收入（讲者近似）
Alphabet	约 40 亿	约 100 美元
Meta	约 35 亿	约 70 美元
ChatGPT	约 10 亿	约 10 美元

表 2: 课堂中的数量级比较。用户定义、去重与收入分母并不统一。

消费收入的会计恒等式是：

$$R = U \times \text{ARPU}.$$

- R ：消费产品的年度收入；
- U ：可变现用户数；
- ARPU：每位用户的年均收入。

该式不是增长预测。用户数和 ARPU 也不完全独立：更多广告可以提高短期收入，却可能损害留存、信任和最终用户规模。

7.5 为什么讲者把广告视为可能的解锁

讲者不确定仅靠订阅能否把约 10 美元 ARPU 推向传统平台的数量级。他预计领先 AI 助手最终会尝试广告，并给出四项潜在优势：用户问题暴露**意图**；连续账户提供**登录态**；平台可能改善**归因**；助手关系带来**信任**。[00:33:04--00:33:21]




图 10: 对话式广告的机会与约束。该机制图根据讲者结尾重绘。

最危险的地方恰好也是“信任”。搜索结果页或信息流可把广告放在既有版面；私人对话若被商业信息打断，用户会怀疑答案是否中立。讲者类比 Facebook 早期的移动广告争议：当时有人认为手机屏幕没有广告空间，后来行业找到了形式；他相信对话界面也会找到形式，却明确承认自己不知道最终形态。 [00:33:29--00:34:08]

广告仍是预测，不是答案

讲者的乐观来自意图、登录态和归因可能提高广告价值；真正的验收条件是平台能否在提高收入的同时保护答案中立性、长期留存和用户信任。

7.6 拓展阅读

- [State of Consumer AI Part 1: Usage](#): 移动端周活、竞争格局与“存量/新增”。
- [Part 2: Engagement and Retention](#): DAU/MAU、WAU/MAU 与 cohort 留存。
- [Part 3: Time is Money](#): 停留时长、订阅与广告机会。所有数字都应注明文章日期和 Sensor Tower 移动端限制。

7.7 本章小结

消费 AI 已形成巨大使用规模，但主动提问的参与方式可能限制用户上限，约 95% 免费用户又迫使平台寻找订阅之外的收入。用户数与 ARPU 是两个放大器；广告可能利用意图和归因提高价格，也可能破坏最宝贵的信任。讲者给出方向，没有给出被验证的产品答案。

8 配套阅读：如何补充而不混淆证据

8.1 五篇材料的角色

材料	日期	补充问题	使用限制
The Economics of Generative AI	2024-04-25	早期倒三角、收入与毛利、推理成本	作者估计；基础设施毛利未计 GPU 折旧
The Economics of Generative AI: Two Years Later	2026-04-01	两年更新、CapEx、GPU/ASIC 与利润迁移	2025 业绩与 2026 预测混合；需回到财报
State of Consumer AI Part 1: Usage	2026-03-02	周活、竞争格局、下载与存量	Sensor Tower 移动端；不等于全平台
State of Consumer AI Part 2: Engagement	2026-03-10	参与深度、留存与习惯	样本和方法有限；因果解释是作者判断
State of Consumer AI Part 3: Time is Money	2026-03-30	停留时长、ARPU 与广告情景	广告收入为早期数据或情景推算

8.2 三条使用规则

1. **先注明日期与口径。** 2024 与 2026 的市场规模不能放在同一列而不说明时间；移动端数据不能写成全部终端。
2. **把文章结论写成作者分析。** “半导体取得大部分价值” “广告机会可能大于订阅” 都需要保留判断属性。
3. **用材料扩展问题，不替换视频证据。** 视频讲了什么由字幕和画面证明；文章适合解释估算方法、更新数据或提供后续检验指标。

高时效数字的正确姿势

CapEx、用户规模、份额、ARPU 和广告定价都可能快速变化。笔记保留它们，是为了解理解讲者当时的经济框架，不是把它们包装成 2026 年 8 月的实时市场快照。

8.3 本章小结

配套材料最有价值的地方，是把讲者的框架延伸为可复核的数据问题；最危险的使用法，是把作者估计、移动端样本和未来预测写成统一、已审计的事实。

9 总结与延伸

9.1 讲者的实质性约束

讲者在最后几分钟把全讲压缩成消费 AI 的两个缺口：应用层若要扩大价值占比，需要更大的用户基数，也需要更高的每用户收入。知识工作驱动的主动提问可能限制全民化；订阅也未必足以支撑免费用户。广告或许能利用意图、登录态和归因提高变现，却必须解决私人对话中的干扰与信任问题。 [00:31:47--00:34:08]

课程是因为时间到而停止，并非论证已经闭环。讲者明确说仍有更多幻灯片，并计划在后续嘉

宾课继续讨论广告。[00:34:08--00:34:19] 因而，本讲最诚实的结尾是一组待检验假设，而不是单一预测。

9.2 把六章压缩成一个机制图




图 11: 生成式 AI 价值迁移的最小机制图。

这张图给出三个判断门槛：

1. **技术门槛**：投入是否形成可用、可持续的训练与推理容量；
2. **产品门槛**：模型能力是否成为高频、广覆盖且愿意付费的应用；
3. **经济门槛**：用户数与 ARPU 的增长，是否足以覆盖推理成本，并使应用收入与利润快于底层增长。

9.3 可操作的观察清单

- **供给侧**：GPU 之外的 ASIC 是否真正进入规模生产；单位推理成本和价格是否持续下降；
- **投资侧**：hyperscaler CapEx 指引、数据中心利用率与折旧如何变化；
- **负载侧**：训练/推理比例、峰谷差、代理全天运行是否改善利用率；
- **应用侧**：免费到付费转化、留存、推理成本占收入比与毛利；
- **消费侧**：移动、Web、桌面分终端用户规模，以及产品是否超越知识工作；
- **广告侧**：广告相关性、负载、归因、答案中立性与信任指标能否同时成立。

9.4 开放问题

1. 应用层收入增长到什么程度，才足以抵消底层 CapEx 和高毛利带来的集中？
2. 推理份额提高，是把价值推向应用，还是只把更多算力收入留在上游？
3. 专用芯片会降低价格并扩大应用，还是把利润从一个芯片供应商转移到 hyperscaler 内部？
4. AI 助手如何在不变成信息网络或信息流的情况下，达到核心工具规模？
5. 对话式广告能否提高相关性，又不让用户怀疑答案被商业利益扭曲？

最终结论

AI 市场规模扩大并不自动意味着价值已经向应用迁移。倒三角是否翻转，取决于底层供给竞争、CapEx 节奏、推理单位经济性、应用用户规模和 ARPU 能否形成同方向的长期变化。

9.5 本章小结

这堂课提供的不是确定年份，而是一套持续更新的仪表盘。读者应把视频中的数字当作带日期的估计，把历史类比当作时间尺度，把广告等结论当作待验证机制；真正稳定的，是“跨层、跨期、同时看收入与成本”的分析方法。