

课程笔记：GPU 经济

从 token 工厂到智能的单位经济

五道口纳什 & Codex

2026 年 8 月 28 日



课程：Stanford MS&E 435, Economics of the AI Supercycle (Week 2)

嘉宾：Brad Gerstner (Altimeter); Sunny Madra (Groq, 后加入 NVIDIA)

教师：Apoorv Agrawal

视频频道：Stanford Online

视频发布日期：2026 年 7 月 23 日

视频时长：56:01

视频链接：<https://www.youtube.com/watch?v=BB18bNJP6ds>

笔记范围：人工英文字幕、原视频画面、Stanford Week 2 官方补充材料与独立复核

PDF 制作 Skill：<https://github.com/wdkns/wdkns-skills>

目录

1 导读：AI 的边际成本为何重新变得重要	1
1.1 本讲在回答什么	1
1.2 从软件复制到 AI 服务：成本曲线改变了	1
1.3 八个自然章节与证据边界	1
1.4 术语表：先消除最容易误读的名称	3
1.5 符号与三条关系	3
1.6 本章小结	4
2 从软件边际成本到 token 经济	5
2.1 一个被 AI 改写的成本前提	5
2.2 为什么先从两千年的增长曲线讲起	5
2.3 科技份额与利润复利：为什么投资者预期 AI 会放大增长	8
2.4 从知识工作的市场规模落到 token	9
2.5 本章小结	10
3 Groq 的起点：为推理重做计算机	11
3.1 当算法已经可行，而通用计算还不够强	11
3.2 Groq 的核心不是孤立芯片，而是架构与编译器	11
3.3 为什么 token 生成与数据库取数不是同一种负载	12
3.4 为什么一项技术可以领先多年，却没有市场	12
3.5 GPU 的路径依赖：方便沿用不等于推理最优	13
3.6 Cloud API：先消除采购摩擦，再让开发者评价模型能力	13
3.7 推理时推理把 token 曲线推向新的约束	14
3.8 拓展阅读	14
3.9 本章小结	14
4 异构推理工厂：拆分 prefill、decode 与内存瓶颈	15
4.1 第一层拆分：prefill 与 decode	15
4.2 第二层拆分：计算密集与内存带宽密集	15
4.3 互联把互补部件变成一个系统	16
4.4 固定功率下，多生产 token 才是经济目标	16
4.5 从原型到交易：系统整合本身就是证据	17
4.6 拓展阅读	18
4.7 本章小结	18

5 推理成本为何下降，却仍然稀缺	18
5.1 先问清楚：什么叫“成本下降”	18
5.2 成本下降的三类输入	18
5.3 光刻放缓后，封装与系统共设计接棒	19
5.4 效率、模型规模与需求的三线竞赛	19
5.5 本章小结	20
6 从回答到行动：代理如何改写单位经济	20
6.1 负毛利起点：成本下降与付费意愿上升的双重赌注	21
6.2 从 autocomplete 和问答，跨到可交付的行动	21
6.3 能力阈值：产品质量如何变成购买行为	22
6.4 收入增长能否承担算力扩张	22
6.5 Harness：把一次问答变成长时运行的执行系统	23
6.6 单位成本与单位价值从两端改善经济性	24
6.7 本章小结	25
7 100× 共设计、基础设施扩张与社会契约	25
7.1 先把事实、传闻与预测分开	25
7.2 “100×”是跨层共设计的组织挑战	25
7.3 AI 辅助芯片设计：递归创新与需求反弹	26
7.4 基础设施的外溢与期权价值	26
7.5 从能力强预测转向社会契约	27
7.6 拓展阅读	27
7.7 本章小结	28
8 人在智能商品化之后如何创造价值	28
8.1 技术替代的是任务，人的价值会重新组合	28
8.2 智能民主化：把稀缺服务变成普遍能力	29
8.3 让自己成为 bionic：工具、创造与专业判断	29
8.4 IQ 商品化之后，关系与组织能力更重要	30
8.5 从等待偶然发现，到主动扩大搜索空间	30
8.6 本章小结	30
9 边缘设备、安全治理与 NVIDIA 的竞争经济学	31
9.1 端侧与云端：隐私、能力和能耗的多目标权衡	31
9.2 安全沟通：真实风险与监管俘获之间的边界	32
9.3 训练资产不会立刻报废：从训练集群转入推理服务	33

9.4	NVIDIA 必须继续竞争，而不是依靠既有优势	33
9.5	本章小结	35
10	总结与延伸	35
10.1	把全讲压缩成一条因果链	35
10.2	五个最可迁移的分析框架	36
10.3	给建设者、投资者与学习者的检查表	36
10.4	仍然开放的研究问题	36
10.5	补充材料的正确用法	37
10.6	本章小结	37

1 导读：AI 的边际成本为何重新变得重要

1.1 本讲在回答什么

传统软件最强大的经济特征之一，是复制与分发的边际成本可以接近零；而生成式 AI 每服务一次新请求，都要实际执行新的计算、搬运新的数据并生成新的 token。于是，“更多用户”不再只是一次服务器扩容后的纯软件增长，而会持续牵动芯片、内存、互联、电力、机房与模型效率。这就是本讲所谓 GPU 经济的起点 [00:00:09--00:00:32]。

56 分钟的课堂并不是一份芯片规格比较。它把三个层面串成一条因果链：第一，**token 如何被生产**；第二，**一次任务产生的智能为何值得付费**；第三，**基础设施扩张后的收益与转型成本如何分配**。因此本笔记以“生产函数—价值函数—社会契约”作为统一框架，而不是逐句重排访谈。

贯穿全文的核心判断

AI 的竞争单位已从一块芯片扩展为一座 token 工厂：在受限的功率、内存和时间内，芯片、互联、编译器、模型与代理工作流共同决定能够交付多少有用智能，以及这些智能能否产生足以覆盖资本开支的价值。

1.2 从软件复制到 AI 服务：成本曲线改变了

下图只表达机制，不使用讲座未提供的精确成本数据。传统软件完成前期开发后，新增一次复制的成本近乎水平；AI 服务则在每次请求上继续消耗推理资源。单位 token 成本可以迅速下降，但只要请求量、上下文长度与每任务 token 数增长得更快，总计算需求仍会上升。




图 1: 传统软件与 AI 服务的边际成本差异：机制示意

1.3 八个自然章节与证据边界

YouTube 没有提供官方 chapters。outline agent 根据 1,238 条人工英文字幕的问答转折与主题切换，重建了八个连续章节：

章	教学问题	时间范围
1	从软件边际成本到 token 经济	00:00:09–00:08:55
2	Groq 的起点：为推理重做计算机	00:08:55–00:15:02

章	教学问题	时间范围
3	异构推理工厂：拆分 prefill、decode 与内存瓶颈	00:15:02–00:21:52
4	推理成本为何下降，却仍然稀缺	00:21:52–00:25:37
5	从回答到行动：代理如何改写单位经济	00:25:37–00:34:57
6	100× 共设计、基础设施扩张与社会契约	00:34:57–00:41:03
7	人在智能商品化之后如何创造价值	00:41:03–00:45:37
8	边缘设备、安全治理与 NVIDIA 的竞争经济学	00:45:37–00:55:57

为避免把现场观点写成已证事实，本文使用四种证据口径：**画面可见的图表、嘉宾明确陈述的数字、嘉宾的投资判断或预测、笔记作者的机制综合**。后两类都会显式标明来源层级。

1.4 术语表：先消除最容易误读的名称

术语	本笔记的统一用法
Groq / Grok	Groq 是本讲讨论的推理芯片与云服务公司；Grok 是另一实体。字幕多次误写，全文统一校正为 Groq。
LPU	Groq 对其 Language Processing Unit 的称呼；本文重点讨论数据流、静态调度与片上内存，不把它等同 TPU。
dataflow architecture	数据流架构；计算随数据依赖推进。本讲把它与确定性编译器一起解释。
deterministic compiler	确定性编译器；在编译期安排数据与指令的位置和时序，从而提高执行可预测性。
inference-time reasoning	推理时推理；模型在回答期间执行更多中间计算，显著增加 token 与算力需求。
prefill / decode	预填充处理输入上下文；解码逐 token 生成输出。两阶段的计算与内存特性不同。
HBM / SRAM	HBM 是加速器外部高带宽显存；SRAM 是片上静态存储。讲者用二者的容量、带宽与延迟差异解释异构互补。
NVLink Fusion	NVIDIA 向定制 XPU/CPU 开放其 scale-up 互联与机架生态的机制；它不等于视频中某个性能数字本身。
AI factory	“AI 工厂”或“token 工厂”；把电力、芯片、建筑与软件转成 token 输出的整套系统。
co-design	共设计；跨电路、内存、互联、机架、编译器与模型共同优化，而非等待单点制程改进。
harness	模型外层的执行、工具、状态、反馈与持续运行框架；它把一次回答扩展为长期行动循环。
willingness to pay	付费意愿（WTP）；当模型真正完成高价值任务时，用户愿意支付的金额可能上升。
gross margin	毛利率；本文只用现场示例解释单位经济，不把未审计口述当作公司公开财务。
edge inference	端侧推理；在设备本地运行模型，需同时权衡隐私、能力、功耗、散热与延迟。

1.5 符号与三条关系

本讲没有给出完整的经济模型。为了让各章使用一致符号，本文只引入三个**明确标为作者综合**的关系。

第一，token 工厂的能源效率：

$$\eta = \frac{N_{\text{tok}}}{W \Delta t}$$

- η ：固定观察期内的 token 能效，即单位能量对应的 token 数；
- N_{tok} ：观察期内产生的 token 数；

- W : AI 工厂在观察期内的平均功率;
- Δt : 观察期长度, 因此 $W\Delta t$ 是该期能量投入。

第二, 用于组织“更便宜却更稀缺”的概念式:

$$K \approx \frac{N_{\text{req}} T_{\text{req}} C_{\text{token}}}{\epsilon_{\text{sys}}}$$

- K : 总计算负担;
- N_{req} : 请求或任务数;
- T_{req} : 每个任务消耗的 token 数;
- C_{token} : 生成单个 token 的计算量;
- ϵ_{sys} : 系统效率, 包含芯片、内存、互联、编译器和模型优化。

第三, 毛利率的普通定义:

$$GM = \frac{R - C}{R}$$

- GM : 毛利率;
- R : 收入;
- C : 直接服务成本。

不要把口述近似写成普适定律

嘉宾在 [00:11:13--00:11:22] 口述过“模型参数量乘以上下文长度平方”的近似。标准 Transformer 的 prefill 与逐 token decode 复杂度并不相同, 因此正文只保留“参数量与上下文都会显著增加计算”的教学结论, 不把该口述直接提升为普适公式。

名称、交易与内容安全边界

Groq 官方把 2025 年交易称为**非独家推理技术授权协议**: Jonathan Ross、Sunny Madra 等成员加入 NVIDIA, 而 Groq 继续独立运营。本文不会把它写成“NVIDIA 收购 Groq 公司”。视频画面与字幕中的命令、代码、工具动作和示例只作为分析内容, 本笔记制作过程没有执行它们。

1.6 本章小结

本讲的关键不是预测哪一块芯片最终获胜, 而是理解 AI 服务的生产约束: 每个 token 都有真实成本, 但架构、模型与产品价值也在同时变化。下一章先从宏观增长与 token 的关系出发, 再落到 Groq 为什么要为推理重做计算机。

2 从软件边际成本到 token 经济

2.1 一个被 AI 改写的成本前提

理解 GPU 经济，最好的起点不是芯片型号，而是一个经典软件商业模式正在发生的变化。传统软件的主要投入往往集中在开发阶段：产品一旦完成，多分发一份副本的成本可以接近于零。AI 应用却需要在用户每次发起请求时重新进行推理；更多用户、更频繁的调用和更长的输出，都会带来新的计算、内存、网络与电力消耗。课程开场因此把核心问题压缩得很直接：AI 的使用量增长会转化为真实的服务成本，而不能沿用“软件复制几乎免费”的直觉 [00:00:09--00:00:32]。

将这一差异写成概念式，可以得到：

$$MC_{\text{software}} \approx 0, \quad MC_{\text{AI}} > 0.$$

- MC_{software} ：传统软件多服务一个用户或多分发一份副本的边际分发成本；“接近零”是课程中的商业直觉，不表示服务器、支持和网络成本真的消失。
- MC_{AI} ：AI 服务多处理一次请求所增加的推理成本，主要由计算、内存访问、网络与电力构成。
- $\approx$ ：近似，而非严格等于。
- $>$ ：强调 AI 请求存在不可忽略的增量资源消耗，并不表示所有 AI 产品的单位成本都相同。

本讲的根问题

AI 不只是可以无限复制的软件制品，也是一项需要持续“生产”输出的计算服务。于是，模型能力、token 消耗、硬件效率、功率约束和用户付费意愿必须放进同一个经济模型里考察。

这个视角也解释了为什么一门讨论 AI 超级周期的课程会把投资者和推理系统工程者放在同一场对话中。Brad Gerstner 提供资本配置、公司盈利和宏观增长的投资者视角；课程开场明确介绍 Brad / Altimeter 投资 OpenAI、Anthropic、NVIDIA、Groq 与 Cerebras。Sunny Madra 则从 GroqCloud、推理芯片与加入 NVIDIA 后的系统工程位置解释 token 如何被生产。两人的经历与利益关系有助于理解其观察位置，也意味着后文相关公司收入、资本开支、毛利与竞争判断必须保留归因，不能被当作中立审计结论 [00:00:32--00:05:11]。

Brad 在人物介绍阶段提出“让自己成为被 AI 增强的人”的建议：重要的不是学校或履历标签本身，而是能否使用最新工具交付异常高的价值 [00:02:48--00:03:22]。本章只把它作为伏笔；课程后半段会在职业问答中重新讨论人的专业判断、创造力与协作能力。

2.2 为什么先从两千年的增长曲线讲起

Brad 随后展示全球人均 GDP 的长期曲线。他对图表的解读是：在前约 1,800 年中，劳动与资本创造的剩余非常有限；到了十九、二十世纪，生产率提高才使人类社会明显越过单纯生存，获得更多可用于教育、健康、消费与公共生活的剩余 [00:05:22--00:05:49]。这个宏观铺垫的教学作用，不是直接证明某一种芯片会创造繁荣，而是说明技术创新为何值得从“生产率”而非单一产品收入的尺度观察。

Global GDP Accelerates with Technology




图 2: 课堂展示的长期人均 GDP 加速曲线; 它承担宏观背景, 不单独构成技术创新的因果识别
图源脚注: 视频画面时间区间 00:05:16–00:05:49。画面从 1920×1080 原视频中抽取, 并在字幕对齐区间内比较附近候选帧后选定。

按照课件的明确标签, 当前**全球人均 GDP** 的翻倍时间可近似写为:

$$T_2 \approx 25 \text{ 年.}$$

- T_2 : 全球人均 GDP 的翻倍时间。
- 25 年: Brad 根据课堂图表给出的近似值; 图内来源与统计边界随课件保留, 不能据此补充课件未说明的价格或购买力口径。

GDP Per Capita Doubling Every 25 Yrs



Source: Maddison Project Database, version 2013. Bolt, J. and J. L. van Zanden (2014). The Maddison Project: collaborative research on historical national accounts. *The Economic History Review*, 67 (3): 627–651. Data post 2008 is using World Bank data

As of September 2025. For illustrative purposes only. Reflects Altimeter's views and beliefs as of this date, none of which should be assumed to be correct. The GDP per capita growth rates and doubling periods shown are based on historical data and should not be relied upon as predictive of future economic performance. In addition, the compound annual growth rate calculations assume consistent growth patterns, which rarely occur in practice due to economic cycles, recessions, and other market volatilities. The information presented relies on data from the Maddison Project Database (version 2013) for historical periods, with post-2008 data sourced from the World Bank. Different methodologies between these sources may create inconsistencies in the dataset. There is no guarantee that any trend depicted or described will continue, or that any such trend would be profitable. Third party content is not necessarily representative of Altimeter and has not been reviewed for completeness or accuracy.


Confidential & Proprietary Altimeter Information — Unauthorized distribution, disclosure, reproduction, use, or possession is strictly prohibited.

ALTIMETER 3

图 3: 课堂用翻倍时间连接增长率与生活水平; “约 25 年”是讲者根据课件给出的近似
图源脚注: 视频画面时间区间 00:05:50–00:06:03。画面从 1920×1080 原视频中抽取, 并在字幕对齐区间内比较附近候选帧后选定。

Brad 进一步把较高 GDP 与较低贫困率、更广泛的基础教育与识字、更高疫苗接种率、较低儿童死亡率, 以及更多自由和民主联系起来 [00:06:14–00:06:41]。这一步把“技术进步”从企业盈利扩展到社会剩余: 若创新使同样的劳动与资本生产更多价值, 它可能改善多种社会结果。

Radically Improving the Standard Quality of Life



Source: Max Roser (2016), “The short history of global living conditions and why it matters that we know it” Published online at OurWorldinData.org. Retrieved from: <https://ourworldindata.org/a-history-of-global-living-conditions>. Originally published on December 14, 2016 (last partial update and revision in February 2024). Third party content is not necessarily representative of Altimeter and has not been reviewed for completeness or accuracy. Reflects Altimeter's general views and beliefs that capitalism has evolved since 1820, coinciding with the outcomes presented. Views and beliefs are as of the date of this Presentation, none of which should be assumed to be correct.

Confidential & Proprietary Altimeter Information — Unauthorized distribution, disclosure, reproduction, use, or possession is strictly prohibited.

ALTIMETER 4

图 4: 课件汇总的六组社会指标; 正文只采用“宏观伴随关系”口径, 不把组合图解释为单一因果证明

图源脚注: 视频画面时间区间 00:06:14–00:06:29。画面从 1920×1080 原视频中抽取, 并在字幕对齐区间内比较附近候选帧后选定。

相关性不等于单一因果

课堂展示的是宏观趋势及其伴随关系。GDP 上升与教育、健康或制度改善之间存在多重双向机制，不能仅凭这张图就证明“技术创新单独导致所有社会进步”。同样，把 GDP 翻倍称为“生活质量翻倍”是讲者用于建立直觉的类比，不是严格的福利测量等式。

2.3 科技份额与利润复利：为什么投资者预期 AI 会放大增长

宏观增长之后，Brad 把视角缩到技术部门。课件将科技占美国 GDP 的份额画为从 1998 年约 5% 上升到 2024 年约 13%，并以虚线预测 2030 年约 15% [00:06:45--00:07:08]。Brad 口述时将其简称为 global GDP，但画面标题和横轴来源明确写 US GDP；两者冲突时，本文以可见课件口径为准。2025E-2030E 属于 Altimeter 的预测，不是已实现数据。

Technology: 5% → 15% of US GDP




图 5: 科技占美国 GDP 份额的课件曲线：实线历史段与 2025E-2030E 虚线预测段必须区分
图源脚注：视频画面时间区间 00:06:44-00:06:55。画面从 1920×1080 原视频中抽取，并在字幕对齐区间内比较附近候选帧后选定。

随后的一张利润图把“份额变大”推进到“复利速度不同”。Brad 称，过去十年 NASDAQ 成分公司的每股收益年复合增长率约为 15%，非科技公司约为 6% [00:07:08--00:07:34]。若只解释复利机制，可以用：

$$E(t) = E_0(1 + g)^t.$$

- $E(t)$: 经过 t 个年度后的每股收益水平。
- E_0 : 比较起点的每股收益。
- g : 每股收益年复合增长率；课堂展示中 NASDAQ 约为 15%，非科技约为 6%。

- t : 复利经过的年数; Brad 的比较窗口为过去十年。

这条式子只是帮助读者理解“增长率差异会在多年累积后拉开结果”，并不补充课堂未给出的样本选择、幸存者偏差或指数构成。Brad 的投资判断是：科技企业之所以常获得更高估值，是因为其利润增长得更快，而 AI 可能进一步加速这种复利。这里的“可能”很重要——历史利润差异是讲者展示的数据，未来 AI 加速则是投资预测。




图 6: 科技与非科技的 15 年比较: 价格指数标签为 QQQ 17% CAGR、SPYxTech 8% CAGR; 标题的 15%/6% 对应两组 EPS CAGR, 不能混作同一口径

图源脚注: 视频画面时间区间 00:07:13–00:07:27。画面从 1920×1080 原视频中抽取, 并在字幕对齐区间内比较附近候选帧后选定。

2.4 从知识工作的市场规模落到 token

Brad 把 AI 的潜在影响范围指向全球知识工作, 称相关市场规模以数万亿美元计; 他又转述 Demis Hassabis 的判断, AI 的影响可能达到工业革命的十倍, 并以十倍速度展开, 即把一个世纪的变化压缩到约十年 [00:07:37–00:08:00]。这是高度概括且面向未来的判断, 本稿只保留其在论证中的位置: 如果 AI 真能作用于大量知识任务, 那么推理需求不会只是今天聊天机器人的请求量, 而会随着可执行任务的范围扩大。

AI Massively Accelerates - 10% of Knowledge Work = \$5T / Yr




图 7: 课件对 AI 与知识工作规模的投资叙事; “10% = 5 T/yr” 及引文中的 50 T 均是课件/讲者框架, 不是本笔记独立核实的预测

图源脚注: 视频画面时间区间 00:07:36–00:07:51。画面从 1920×1080 原视频中抽取, 并在字幕对齐区间内比较附近候选帧后选定。

Brad 同时提醒, 技术收益不会自动平均分配, 社会需要讨论 guardrails (风险护栏) 以及与快速转型相适应的制度变化 [00:08:00--00:08:15]。这使宏观论证避免停留在“算力越多必然越好”的单线叙事: 生产率可能提高, 但安全、分配与转型成本仍需单独治理。

最后, 讲者把宏观增长链条落到一个可操作的生产单位: token。他把 token 称作 AI 或智能的“原子单位”, 并指出其最底层输入是 compute [00:08:15--00:08:35]。更严谨地说, token 是模型处理或生成的离散单位, 不能直接充当“智能含量”的度量; 但在推理经济中, 它确实是连接工作负载、吞吐、成本和计费的常用单位。由此可以把本讲的生产链理解为:

token 工厂视角

芯片、内存、网络与电力提供计算能力; 计算能力生产 token; token 被模型与应用组织成回答、代码或行动; 只有当这些结果解决真实任务时, 技术吞吐才转化为经济价值。

这也自然引出下一章的问题: 既然 token 不是零成本复制出来的, 那么什么样的计算机, 才更适合高效地生产 token?

2.5 本章小结

本章建立了全讲的经济起点。传统软件的边际分发成本接近于零, AI 服务却会随请求持续消耗计算资源, 因此用户增长会直接碰到推理成本。Brad 用 GDP、社会指标、科技占比和每股收益复利说明技术创新为何可能创造巨大生产率剩余, 但这些图表只提供课堂趋势与投资判断, 不能替代因果识别或数据口径核查。最终, 宏观叙事被压缩为一条生产链: compute 是投入, token 是中

间产出，任务价值才是经济结果。

3 Groq 的起点：为推理重做计算机

3.1 当算法已经可行，而通用计算还不够强

有了“token 需要被生产”的问题，第二章转向生产工具。Sunny 回顾 Jonathan Ross 在 Google 的经历：Jeff Dean 曾介绍一种自动语音识别算法，算法思路已经出现，但当时缺少足够强的计算能力来运行。Jonathan 随后从不同的设计背景出发，用 FPGA 做出后来演变为 Tensor Processing Unit (TPU) 的早期原型 [00:09:34--00:10:03]。按照 Sunny 的讲述，Jonathan 离开 Google 创办 Groq，是因为他希望类似能力不只存在于 Google 内部 [00:10:03--00:10:12]。

这段历史故事的重点不在个人传奇，而在一个反复出现的系统规律：算法可行不等于产品可运行。当工作负载的计算结构已经不同于通用机器最擅长的模式时，继续等待通用硬件变快可能不是唯一选择；也可以围绕新算法重新设计数据路径、执行单元和编译工具。TPU 的起点如此，Groq 后来的推理路线也沿着同一种问题意识展开。

3.2 Groq 的核心不是孤立芯片，而是架构与编译器

Sunny 将 Groq 描述为采用 dataflow architecture（数据流架构）的芯片，并强调它与 deterministic compiler（确定性编译器）协同工作 [00:10:12--00:10:36]。按他的解释，编译器会预先确定计算在什么位置、以什么次序发生；芯片则按照数据依赖执行已经安排好的工作。这里的“确定性”首先应理解为调度与资源放置的可预测性，而不是笼统宣称整套云服务在所有输入、网络和故障条件下都绝对确定。

可以把讲者描述的机制拆成三步：

1. 模型计算图进入编译阶段；
2. 编译器预先安排操作的位置与时序；
3. 数据在预定的执行路径上流动，芯片按安排完成大量数学运算。

架构边界

Groq 的差异化主张不是“某个算术单元更快”，而是数据流架构与编译器共同定义计算如何被放置和调度。评价这条路线时，应把芯片与编译栈视为一个系统，而不是把性能归因于单一硅片。




图 8: 数据流架构与确定性编译器的协同：根据讲者在 00:10:12-00:10:36 的口述重绘

这也解释了为什么讲者反复把 token 生成称作“大量数学运算”。在 AI 推理中，硬件需要持续执行模型权重与中间状态相关的计算；如果调度、数据移动或存储访问浪费资源，芯片的理论峰值就不能自动变成稳定的 token 吞吐。

3.3 为什么 token 生成与数据库取数不是同一种负载

为了给计算量建立直觉，Sunny 以 Snowflake 一类数据库检索为参照：数据库任务可能是定位一条记录并返回；生成一个 token 则需要大量计算，其所需 cycles 或 FLOPs 在他看来高出多个数量级 [00:10:51--00:11:36]。这个比较不是严格 benchmark，因为数据库查询与模型推理的输入、硬件、缓存命中和服务目标都没有统一；它的教学价值在于提醒读者，AI 推理不能被理解为“从已经存好的答案表里取一行数据”。

Sunny 给出了一条口述近似，用来表达每个 token 的计算量如何随模型和上下文增长：

$$C_{\text{token}} \propto N_{\text{param}} L^2.$$

- C_{token} ：讲者所指的生成一个 token 所需计算量，可用 cycles 或 FLOPs 建立直觉。
- N_{param} ：模型参数量。
- L ：上下文长度。
- $\propto$ ：表示随右侧量级增长的近似比例关系，而不是给出带常数、硬件条件和算法实现的精确等式。

不要把 $N_{\text{param}} L^2$ 当作通用推理定律

这条式子是 Sunny 在 [00:11:13--00:11:22] 的口述简化。标准 Transformer 的 prefill attention 与逐 token decode 具有不同的计算和内存复杂度，缓存策略、批量、模型结构及稀疏性也会改变成本。正文仅用它忠实呈现讲者的量级直觉，不能把它推广为所有模型、所有推理阶段都成立的工程公式。

即使暂不采用这条具体比例式，讲者的更稳健结论仍然成立：模型参数、上下文和输出 token 数会共同放大服务计算负担。因此，当推理从偶尔的一次回答变成持续、多步骤的工作流时，需求增长会非常快。

3.4 为什么一项技术可以领先多年，却没有市场

技术路线成立，并不等于市场已经准备好。Brad 回顾，Groq 与 Cerebras 都曾长期开发快速推理硬件；到了接近第九年，两家公司仍在为生存而战，因为它们所面向的大规模推理市场尚未真正出现 [00:11:36--00:12:07]。这段经历揭示了专用硬件创业的时间错配：

- 研发需要提前多年投入；
- 芯片和系统一旦选定路线，迭代周期长；
- 真正决定需求的模型工作负载，却可能在硬件投入多年后才发生突变。

Brad 随后转述 Jensen Huang 在 BG2 播客中的判断：行业正从以预训练为中心转向 inference-time reasoning（推理时推理），推理需求可能增长十亿倍，而既有计算系统没有为即将到来的规模设计 [00:12:10--00:12:34]。这里的“十亿倍”是一项强烈预测，不是已经实现的吞吐、营收或请求量数据。它在本章中的作用，是标记市场预期的拐点：模型开始在回答阶段使用更多步骤和更多 token，专用推理基础设施由“过早的技术”变成潜在的关键瓶颈。

硬件创业的市场时钟

专用加速器同时受两只时钟约束：一只是缓慢的芯片研发与供应链时钟，另一只是快速变化的模型工作负载时钟。成功不仅要求架构有效，还要求产品在需求真正形成时具备可部署的系统和分发渠道。

3.5 GPU 的路径依赖：方便沿用不等于推理最优

Sunny 解释，NVIDIA GPU 之所以自然承接早期推理市场，是因为研究人员本来就在 GPU 上训练模型。按他的简化表述，推理对应训练中的 forward pass（前向传播），训练则还要进行 backpropagation（反向传播）；既然模型已在同一套硬件和软件生态里创建，部署时继续使用它是最自然的选择 [00:12:47--00:13:12]。

这是一种典型的路径依赖：已有工具链、模型兼容性、运维经验和可用容量会降低迁移成本，使“沿用训练平台”成为默认答案。但默认答案不必然是特定推理负载的效率最优解。Sunny 称 Groq 架构能够更高效地完成推理，并以 Groq V1 与 Hopper 的比较来说明这一点 [00:13:12--00:13:40]。字幕把 V1 的制程错误转写为“1914 nanometer”，原音与画面都不足以可靠恢复精确节点；因此本文不保留制程数值，只写“V1 采用明显更老的硅工艺世代，Sunny 仍称其推理表现具有竞争力”。

不要把可部署性和芯片效率混为一谈

GPU 的优势包含成熟生态与部署便利，专用架构的主张则可能集中在某类推理负载的效率。比较二者时必须同时给出模型、精度、批量、延迟目标、功耗与软件成熟度；“旧工艺仍有竞争力”不能自动推出跨场景全面领先。

3.6 Cloud API：先消除采购摩擦，再让开发者评价模型能力

Groq 面临的产品化难题是：即使硬件有效，也很难要求大量开发者采购、部署并学习一套新机器。Sunny 因而描述了一个关键转向——由 Groq 自己运营数据中心，把芯片放在云端，通过 API 提供开放模型以及 OpenAI Whisper 等可用模型 [00:13:40--00:14:13]。这样一来，开发者首先面对的是接口、模型与服务效果，而不是芯片采购决策。

这个策略把专用硬件的采用路径从：

“理解新架构 → 购买硬件 → 部署系统 → 迁移模型”

改成：

“调用 API → 评价速度、质量与成本 → 再扩大使用”。

这里的核心机制不是“开发者完全不关心底层硬件”，而是云 API 把高摩擦的资本采购和系统运维从首次使用中移除。架构创新因此需要与分发创新配合：前者降低生产 token 的资源成本，

后者降低用户尝试这种生产能力的采用成本。

Sunny 称 GroqCloud 上线几周后达到数十万用户，本讲录制时约有四百万用户；他又将其与 NVIDIA 用约十七年达到七百万用户作比较 [00:14:13--00:14:24]。这些数字应保留为讲者在录制时点的采用叙事。两家公司对“用户”的定义、产品阶段和统计窗口可能不同，不能据此直接计算同口径增长率或市场份额。

3.7 推理时推理把 token 曲线推向新的约束

市场真正转折的原因，是 workload 变了。Sunny 认为 reasoning models (推理模型) 在生成答案前会进行更深、多步的计算，因此比一次性回答的模型消耗更多 token；而这甚至发生在大规模 agents 到来之前 [00:14:24--00:14:41]。按他的描述，token 消耗曲线开始“抛物线式”上升，Groq 的云服务也出现承压 [00:14:41--00:14:50]。

Sunny 还以 OpenAI 与 Anthropic 各自只有约 1 GW 计算能力的说法，说明前沿实验室受到功率和算力上限约束 [00:14:50--00:14:56]。这个数字未给出口径，不能视为已核实的设施盘点；它更适合作为讲者对“需求增长快于可用基础设施”的说明。面对这一约束，他给出两个必须同时推进的方向：

1. 让模型以更少 token 或更少计算完成同等任务，即提高模型侧 token 效率；
2. 让硬件与系统以更少资源生产同样数量的 token，即提高架构侧 token 效率。

需求拐点的真正含义

Groq 的市场机会不只来自“芯片更快”，而来自推理工作负载从单次回答转向更深的推理过程。每个请求需要的 token 增多，用户与任务量也在增长，模型效率和系统效率因而必须同时改善。

到 00:15:02，讨论从单一架构与云分发转向一个更大的系统问题：曾被视为竞争者的 Groq 与 NVIDIA，能否把不同硬件放进同一推理工厂协作。下一章将从 prefill、decode 和内存瓶颈开始展开；本章不提前重复该机制。

3.8 拓展阅读

- Stanford 课程页列出的 [Acquired: Altimeter \(with Brad Gerstner\)](#) 可补充 Brad 的创业、投资与资本市场视角，但不应用来反向证明本讲 2026 年的 GPU 市场数字。
- 同一课程页列出的 [Groq Founder, Jonathan Ross: OpenAI & Anthropic Will Build Their Own Chips & Will NVIDIA Hit \\$10TRN](#) 可补充推理芯片、定制 ASIC、能源与竞争主题；标题中的估值和预测仍属于访谈判断，不是本讲已确认事实。

3.9 本章小结

Groq 的故事展示了一条从算法瓶颈到市场拐点的完整链条。首先，新算法可能迫使工程师重新设计计算机；其次，Groq 把数据流架构与确定性编译器作为一个整体，试图更可预测地安排大

量数学运算；再次，训练生态让 GPU 自然承接推理，却没有消除专用推理架构的效率空间；最后，Cloud API 降低了新硬件的采用摩擦，而推理时推理又突然放大了 token 需求。技术、工作负载与分发渠道必须在同一时点对齐，一项提前多年存在的架构才会获得真正的市场。

4 异构推理工厂：拆分 prefill、decode 与内存瓶颈

上一章说明，推理时推理（inference-time reasoning）让模型在回答时进行更深的计算并消耗更多 token，需求曲线随之变陡。若电力、机房和芯片供给都有限，单纯等待一块“全面更快”的芯片并不能充分解决问题。Sunny 在这里提出的系统思路是：先把推理拆成资源特征不同的阶段，再把每一部分交给更合适的硬件；优化对象由单芯片峰值性能变成整座推理工厂在固定约束下的 token 产出。

4.1 第一层拆分：prefill 与 decode

一次大模型推理通常先接收整段输入上下文，再逐步生成输出。前者称为预填充（prefill），后者称为解码（decode）。prefill 可以同时处理输入中的许多 token；decode 则按自回归顺序反复执行“读取当前状态、计算下一个 token、把新 token 加回上下文”的循环。两者的并行方式、延迟目标和资源访问模式并不相同，因此讲者称，业界已经开始让两组机器分别承担 prefill 与 decode，由此获得显著效率提升。

为什么拆开阶段可能更高效

如果所有阶段都被绑定在同一种机器上，系统必须同时为多种资源需求预留余量，某些时刻计算单元闲置，另一些时刻内存或通信成为瓶颈。拆分后，调度器可以分别控制批量、并发和硬件配比。不过，本讲没有给出具体模型、批量大小、延迟目标或状态迁移方案，因此这里应理解为系统设计原则，而不是“所有 workload 都应采用同一种拆分”的结论。

Sunny 随后把问题再向下拆了一层：即使只看 decode，内部也并非单一工作。有的算子更依赖计算吞吐，有的算子更依赖内存带宽。真正的设计问题因而变成：能否让不同算子在最匹配的部件上执行，同时把跨部件协作的开销控制在收益之下？

4.2 第二层拆分：计算密集与内存带宽密集

讲者用 GPU 与 Groq 芯片的资源配比说明互补性。按其口述，GPU 拥有大量计算资源，并配合芯片外部的高带宽内存（High Bandwidth Memory, HBM）；Groq 芯片的计算资源相对更少，但配置了大量片上静态随机存取存储器（Static Random-Access Memory, SRAM）。SRAM 的带宽和延迟优势使其适合承接某些频繁搬运数据的工作，而 GPU 的计算阵列适合承担计算强度更高的部分。

SRAM 与 HBM 不能只用“快、慢”二分

字幕里把 HBM 称为“slower”，语境是相对于片上 SRAM，而非说 HBM 本身是低带宽内存。SRAM 通常更低延迟、更高带宽，但单位面积昂贵、容量有限；HBM 容量大得多，适合保存模型权重和运行状态。讲者用 CPU 的 L1 cache 帮助建立直觉，也不代表 Groq 的 SRAM 与普通 CPU L1 在容量、组织方式和用途上完全等同。其“快一个数量级以上”的说法缺少访问模式和测量条件，正文不应泛化。

这一步很重要，因为它改变了比较芯片的方式。若只问“哪一块芯片更快”，容易把一个复杂工作负载压成单一排名；若问“哪一种资源适合哪一类算子”，竞争关系就可能变成互补关系。原先被视为 NVIDIA 竞争者的 Groq，由此提出了共同完成一次推理任务的可能性。

4.3 互联把互补部件变成一个系统

异构分工只有在芯片之间能够快速交换信息时才有价值。Sunny 将方案描述为：借助 NVIDIA 的 NVLink 互联协议及 NVLink Fusion，让 Groq 芯片与 NVIDIA 芯片通信；把 Groq 更擅长的部分放到 Groq 芯片上，其余部分留在 NVIDIA 系统中。讲者还以当时的系统规模说明 scale-up 的重要性：NVIDIA 的高速互联域可连接许多 GPU，Groq 也已有在数千颗芯片上运行模型的经验。这里的数字只反映讲者在录制时点的口径，不能脱离具体产品代际解读。

异构推理的核心

异构系统的价值不来自“把两种芯片放在同一机房”，而来自三件事同时成立：任务能够按资源特征拆分；互联与软件栈能够传递必要状态；拆分获得的计算或内存收益大于通信、同步和调度开销。

本讲没有展开中间状态如何迁移、编译器如何跨两套栈排程，也没有给出端到端延迟、批量和模型质量等条件。因此，NVLink Fusion 在本章承担的是“异构协作入口”的角色；它并不足以单独证明任何 workload 都会得到相同比例的加速。

4.4 固定功率下，多生产 token 才是经济目标

Brad 把这套系统设计翻译成了经济学语言：推理基础设施是一座 AI factory。电力、芯片、机房及其成本从一端进入，token 从另一端产出。若电力和建筑足迹固定，系统每个时段能生成的 token 越多，单位受限资源承载的服务能力就越高。


AI factory 的输入与输出（意译）

[00:18:53--00:19:23] **Brad**：工厂的一端投入电力和芯片，当然还有建筑与其他成本；另一端产出 token。若保持同样的电力和建筑足迹，却能生成两倍半的 token，经济结果就会完全不同。

为了把这个直觉写得更清楚，可以在固定观察时段内定义 token 能效：

$$\eta = \frac{N_{\text{tok}}}{W \Delta t}, \quad N_{\text{tok,hybrid}} \approx 2.5 N_{\text{tok,base}} \quad (\text{同一功率与观察时段, 按讲者口径}).$$

- η : 单位能量所对应的 token 产出, 可理解为 token 能效;
- N_{tok} : 观察时段内系统生成的 token 数;
- W : 系统使用的功率;
- Δt : 统一的观察时长;
- $N_{\text{tok,hybrid}}$: Groq 与 NVIDIA 混合系统的 token 产出;
- $N_{\text{tok,base}}$: 讲者所指基线系统的 token 产出。



收益必须扣除通信、同步、状态迁移与软件开销

图 9: 固定功率下的异构 token 工厂: 根据讲者在 00:16:03–00:19:32 的口述重绘; $2.5\times$ 仅是讲者所述条件化系统结果

讲者给出的结果是: 在相同功率足迹下, 混合系统可输出约 $2.5\times$ token。这个数值最适合被理解为一项带条件的系统结果, 而不是芯片本身的固定倍数; 本讲没有交代基线配置、模型、精度、批量、服务等级目标和测量周期。在真实业务里, 更多 token 还必须能被用户需求吸收, 并满足延迟与质量要求, 才会转化为收入或成本优势。

这也解释了为什么讲者反复强调世界的约束是 power 与 memory。市场需要的并非抽象的“更快推理”, 而是在受限电力、内存和机房条件下把更多可用 token 送到现实任务中。若需求正在增长, 提高 η 就相当于在不新增同等规模电站和园区的前提下扩大工厂产能。

4.5 从原型到交易: 系统整合本身就是证据

这段合作并非只靠一条短信完成。更完整的因果链是: 团队先提出异构拆分假设, 再让两家公司开始协作, 随后做出能与 NVIDIA 系统共同运行的原型。Sunny 认为, 原型证明了两套完全不同的技术栈可以协同并达到性能目标, 也向 NVIDIA 展示了团队的整合能力。Groq 官方将 2025 年安排界定为**非独家推理技术授权协议**: Jonathan Ross、Sunny Madra 等成员加入 NVIDIA, Groq 继续独立运营。视频约 200 亿美元的说法只作为讲者现场口径, 不被写成“NVIDIA 收购 Groq 公司”的交易金额。

NVIDIA 当时也已不再只以单块 GPU 为系统边界。讲者称, 其生态包含多种芯片和机架, 覆盖存储、CPU、计算与网络, 并已研究使用大量 SRAM 的 decode 专用芯片。竞争单位正在从“哪块 GPU 更强”上移为“哪套跨芯片、跨机架、跨软件栈的系统能以受限输入生产更多 token”。Groq 的差异化数据流架构和确定性编译器没有因为合作而消失; 恰恰因为它与 GPU 路线不同, 才更容易形成工程和团队上的互补。

4.6 拓展阅读

Stanford 课程页将 20VC 对 Jonathan Ross 的访谈列为本周补充材料：[Groq Founder, Jonathan Ross: OpenAI & Anthropic Will Build Their Own Chips & Will NVIDIA Hit \\$10TRN](#)。它可用于补充推理芯片、定制 ASIC、能源和竞争主题，但其中的预测与访谈判断不应被当作本讲已经验证的事实。

4.7 本章小结

本章完成了两次抽象升级。第一，从整段推理拆到 prefill 与 decode，再从 decode 拆到计算密集与内存带宽密集的函数；第二，从比较单芯片峰值，转向比较整座 AI factory 在固定功率、内存和建筑足迹下的 token 产出。SRAM/HBM 的互补和 NVLink Fusion 的互联只是实现手段，真正的系统原则是“按瓶颈分工，并把协作成本纳入端到端测量”。约 $2.5\times$ 的结果说明这种共设计可能具有巨大经济价值，但其适用范围仍取决于未公开的模型、配置与服务条件。

5 推理成本为何下降，却仍然稀缺

上一章展示了一次具体的系统效率提升，但紧接着出现了一个看似矛盾的现象：Brad 称，同等“智能单位”的推理成本在一年内下降约 90%，在两年至两年半内下降接近 99%；与此同时，H100 等资源的市场价格和获得难度并未自然消失。理解这个矛盾，需要把单位成本、模型计算量和总需求分开。

5.1 先问清楚：什么叫“成本下降”

现场问题把比较对象描述为 roughly like-for-like 的“一个智能单位”，但没有固定模型质量、任务难度、延迟、吞吐、批量、精度或总拥有成本口径。因此，90% 与 99% 只能作为讲者观察到的趋势，不能直接解释为任意模型、任意服务条件下的可复现实验结果。

开场的 OpenClaw 例子给出了需求侧背景：Brad 转述 Marc Andreessen 的社交媒体说法，称一些重度用户每天会消耗价值数百至上千美元的 token。该数字是二手 anecdote，不承担本章的定量证明；它只说明，当 agent 开始持续工作时，用户可能很快把单位价格下降转化为更多使用。

单位成本下降不等于总账单下降

“每 token 更便宜”“完成同等质量任务更便宜”“同一用户账单更低”和“全行业算力需求下降”是四个不同命题。只有先固定质量、延迟与任务边界，单位成本比较才有明确含义；即便单位成本确实下降，只要使用量增长得更快，总支出和资源稀缺仍可继续上升。

5.2 成本下降的三类输入

Sunny 把单位推理成本的驱动因素分为三类。

第一类是供应链能力，包括以台湾为中心的晶圆制造、先进封装，以及上游光刻技术。它决定可制造多少先进硅片、如何把芯粒与内存组织进封装，也决定扩产速度与良率约束。

第二类是工程创新。讲者随后列举了电路布局、内存带宽、量化和更低精度格式（如 NVFP4）等方向。这些优化需要与模型共同设计：同一算法若改变数据表示、访存方式或算子结构，硬件的有效利用率也会改变。

第三类是可用功率。即使芯片效率提高，数据中心仍必须获得稳定供电，并处理配电、散热和机房容量。功率既是成本项，也是约束可部署 token 产能的硬上限。

推理通缩来自整个系统栈

本讲的答案不是“摩尔定律会自动让推理变便宜”。单位成本下降来自制造与封装、芯片与内存、互联与电路、数值精度、编译/系统软件和可用功率的共同变化。任何单点改进都可能被另一个瓶颈限制。

5.3 光刻放缓后，封装与系统共设计接棒

讲者判断，光刻带来的传统制程缩放已经放缓，工程团队于是试图用更大的芯片与封装继续扩展可用硅面积。他以 Cerebras 的晶圆级（wafer-scale）路线作直观例子：器件可以接近“披萨盒”大小，与人们熟悉的 CPU 封装形成鲜明对比。重点不在外形，而在设计边界已从单一小芯片扩展到“一个封装能容纳多少硅、芯粒与互联”。

更大的封装也会带来新的问题，例如制造良率、供电、散热、通信和软件映射。视频只点出这些“有趣的问题”，没有给出工程解法；因此笔记应把 wafer-scale 作为越过单芯片缩放限制的一条路线，而不是默认它在成本或性能上必然胜出。

5.4 效率、模型规模与需求的三线竞赛

效率提升并不在真空中发生。Sunny 同时指出，模型还在变大，需求也在增长。他用据称正在讨论的 1-10 trillion 参数模型作例子，并把参数量连接到每个 token 所需的基础计算。这个范围来自现场口述且可能涉及传闻，不能写成已发布模型的确定规格；它的教学意义是：若每 token 的工作量本身增加，硬件效率提升可能先被模型规模吸收。

为了把本讲的三条曲线放在一个框架中，可以使用下面的笔记作者综合式。它不是视频给出的性能模型，只用于区分变量：

$$K \approx \frac{N_{\text{req}} T_{\text{req}} C_{\text{token}}}{\epsilon_{\text{sys}}}, \quad C_{\text{total}} \approx p_{\text{tok}} N_{\text{req}} T_{\text{req}}.$$

- K ：为全部请求提供服务所需的总计算负担；
- N_{req} ：请求或任务数量；
- T_{req} ：每个请求平均消耗的 token 数；
- C_{token} ：生成一个 token 所需的计算量；
- ϵ_{sys} ：芯片、内存、互联和软件共同形成的系统有效效率；
- C_{total} ：提供这些请求所产生的总直接服务成本；

- p_{tok} : 在既定质量与服务条件下的单位 token 成本;
- 两个式子中重复出现的 $N_{\text{req}}T_{\text{req}}$: 总 token 需求的近似量。

第一个式子说明, 系统效率 ϵ_{sys} 提高会压低计算负担, 但请求数、每请求 token 数或每 token 计算量的增长都可能抵消收益。第二个式子更直接地说明“更便宜仍然稀缺”: 假设 p_{tok} 降到原来的十分之一, 而总 token 需求增长超过十倍, 总成本与基础设施需求仍会上升。

Sunny 将这种局面概括为多因素同时变化、彼此相乘的难题。他称, 即便五年取得约 $50\times$ 的效率改进, 模型尺寸和需求也可能增长得更快; H100 的市场价格在某些创业公司可见的交易环境中反而上涨, 正是供需缺口尚未被填平的信号。这里的 $50\times$ 、参数范围和价格现象都高度依赖录制时点, 正文只能作为讲者观察使用。

化解表面矛盾

单位推理成本下降描述的是供给曲线向外移动; 资源仍然稀缺描述的是需求增长后新的市场均衡。二者可以同时成立。若更强模型、reasoning 和 agent 使 N_{req} 、 T_{req} 与 C_{token} 上升得比 ϵ_{sys} 更快, 行业会一边经历“每单位智能通缩”, 一边继续建设更多芯片、内存、电力和机房。




图 10: 效率、单任务负担与任务数量的三线竞赛: 根据讲者在 00:24:25–00:25:29 的口述重绘

5.5 本章小结

推理成本下降不是一个单变量故事。供应链与先进封装扩展可制造边界, 工程创新提高芯片和模型的有效效率, 功率决定可部署上限; 与此同时, 模型规模、任务数量和每任务 token 数仍在增长。因此, 单位成本下降不能推出总需求或总支出下降。这个结论自然把问题引向需求侧: 如果 agent 消耗更多 token, 用户为什么还愿意支付? 答案取决于它交付的任务价值是否增长得更快。

6 从回答到行动: 代理如何改写单位经济

供给侧只能解释 token 为什么会变便宜, 不能单独解释 AI 公司何时成为可持续生意。Brad 把早期前沿模型公司的赌注拆成两条同时变化的曲线: 一边是推理成本快速下降, 另一边是能力提高后用户愿意支付的价格上升。两条曲线的交点, 决定了负毛利服务能否变成正向单位经济。

6.1 负毛利起点：成本下降与付费意愿上升的双重赌注

讲者用一个简化例子描述 OpenAI 与 Anthropic 的早期状态：生产一单位服务要花 \$1，却只能以 \$0.20 售出。原因不只是推理昂贵，也在于当时产品能力有限，用户的 willingness to pay (WTP，付费意愿) 存在上限。公司融资扩张所押注的，是单位推理成本会显著下降，同时“单位智能”变得更有用，WTP 会显著上升。

毛利率的示意计算是：

$$GM = \frac{R - C}{R} = \frac{0.20 - 1}{0.20} = -4 = -400\%.$$

- GM ：毛利率；
- R ：该单位服务带来的收入，本例为 \$0.20；
- C ：该单位服务的直接服务成本，本例为 \$1；
- -400% ：由讲者示例推导出的示意结果，不是两家公司经审计的实际毛利率。

价格、价值与成本是三件事

成本下降提高了降价或改善毛利的空间；能力提高可能提升任务价值；用户是否愿意付费，还取决于替代方案、可靠性、风险和组织采购流程。本讲用 \$1 与 \$0.20 说明方向，不足以推出具体公司的真实毛利轨迹。

6.2 从 autocomplete 和问答，跨到可交付的行动

Brad 将 AI 的第一阶段概括为“产出答案”：代码工具主要完成 autocomplete/tab completion，聊天产品像更会组织语言的搜索入口。接下来的阶段则是 action：agent 不只告诉用户怎么办，而是尝试建应用、做网站、处理客服问题、推动销售或完成预订。现场还把“寻找癌症疗法”列入愿景清单；这应理解为任务价值上限的举例，而不是视频证明 agent 已经完成此类科学突破。

从答案到行动改变了 token 经济的计量单位。一次问答可能只需生成一段文本，一项真实任务却可能包含规划、工具调用、读取文件、检查结果、处理失败与再次尝试。讲者粗略称，完成行动所需 token 会增加约一个数量级，而交付给终端用户的价值可提高约 $100\times$ 。这两个数字是经济直觉，不是稳定常数；真正重要的是它们所表达的不等式：如果任务价值增长快于完成任务的成本，WTP 就可能上升，更多 token 也可以拥有更好的单位经济。

agent 的需求侧跃迁

评价 agent 不应只问“用了多少 token”，还要问“替用户完成了什么”。当计价对象从一段回答变成一项可验收行动时，token 消耗可以上升，用户剩余和付费意愿也可以上升；商业可持续性取决于价值增幅是否长期高于端到端服务成本增幅。

6.3 能力阈值：产品质量如何变成购买行为

Sunny 补充了一个未提供可核来源的例子：据其口述，一个未发布的 Anthropic 前沿模型发现了 BSD 代码中长期未被大量开发者注意到的缺陷。他据此主张，模型正开始完成某些超出既有手工检查能力的工作。由于模型名称、缺陷详情和比较基准都未在本讲中给出可核验来源，正文不把它写成“已证明超越人类”的事实；它在论证中的作用，是展示能力跨过阈值后，任务价值可能出现非线性变化。

[00:28:10--00:29:09]

Brad 用 Anthropic 的收入增长来说明一种“能力阈值”效应。低于阈值时，模型即使偶尔给出漂亮答案，用户仍需频繁复核、重做或亲自完成最后一步；模型节省的时间不稳定，组织也很难形成高付费意愿。当模型可靠到足以进入真实工作流，购买决策就可能突然加速：许多彼此独立的团队发现它能改善自己的业务，于是分别增加采购，而不必等一家厂商线性扩张销售队伍。

这里需要回指开场披露：Brad / Altimeter 是 Anthropic 与 OpenAI 的投资者。下述收入、资本承诺与毛利判断是带有明确观察位置的投资者解释，而非独立财务审计。

这类需求变化通常不是平滑直线。模型能力的小幅提高，如果仍未越过“可以托付任务”的门槛，商业价值可能变化有限；一旦越过门槛，使用方式会从偶尔咨询转成持续执行，任务数量、每项任务的 token 消耗和愿意支付的价格会同时上升。Brad 将 Claude Code 与 Cowork 作为例子，强调客户购买的不是抽象 token，而是 token 所承载的可执行能力。字幕中的 Cloud Code 应统一为正式名称 **Claude Code**；Cowork 的正式产品写法可用 **Claude Cowork**。

能力阈值

模型能力与收入之间不必是线性关系。真正的商业拐点可能发生在模型从“需要大量人类补救”跨到“能够稳定完成一类任务”的时刻；阈值之后，分散的用户会用购买行为表达价值判断。该机制是 Brad 对收入增长的解释，并非本讲给出的因果识别结果。

Brad 在 [00:28:00--00:28:10] 的跨界句中称，Anthropic 在 3 月的一个月“新增约 100 亿美元的年化收入”。这里最重要的是 **annualized**：它描述按当时收入速度折算的一年期运行率增量，并不等于 3 月当月实际确认了 100 亿美元收入，更不等于已经实现、经审计的全年收入。随后他又报出 1 月约 35 亿、2 月约 80 亿、3 月约 105 亿美元的“month”数字，但字幕没有定义它们究竟是各月总运行率还是各月新增运行率。因此，正文只保留“Brad 称 3 月单月新增约 100 亿美元年化收入”这一清楚口述；不把 3.5/8/10.5 三个数字画成收入曲线，也不据此计算估值。

运行率像速度表，不是里程表

若用某个月的收入速度简单年化，可写作 $R_{\text{run}}(t) \approx 12r_m(t)$ 。它回答“如果当前速度维持一年，会得到多大收入”，而不是“这一年已经赚了多少钱”。高速增长期的运行率尤其敏感，不能与实际年度收入、现金回款或利润混用。

6.4 收入增长能否承担算力扩张

[00:29:09--00:31:16]

能力阈值解释了需求为何可能突然出现，但资本市场还要追问第二层问题：收入增长能否持续覆盖极大的基础设施投入。Brad 回忆，他曾在自己的播客中用“约 1.4 万亿美元的支出承诺”和“约 130 亿美元收入”质询 Sam Altman。此处两个数字的期限与会计口径并不相同：多年期采购承诺、可选择或可重谈的合同，与某一时点的收入运行率不能直接相减。本讲也没有给出合同、融资、折旧或利用率数据，所以这段对话应当保留为问题意识，而不是据此宣布投资合理或泡沫破裂。

更好的分析框架是依次检查四件事：

1. **需求是否真实且可复购。**能力提升必须转化为持续使用，而非短期试用或一次性签约。
2. **服务每个任务是否产生正贡献。**收入要先覆盖推理、电力和运营等直接服务成本。
3. **基础设施是否得到充分利用。**即便单次推理有正毛利，闲置的芯片、机房和电力容量仍会拖累整体回报。
4. **收入与支出的时间是否匹配。**建设支出往往先发生，收入随后爬坡；融资成本、合同灵活性和建设周期都会影响生存能力。

Brad 将 Anthropic 的快速增长解读为“需求开始沿能力曲线扩张”的市场信号，并进一步声称这种收入可帮助支付每吉瓦约 500 亿美元的推理工厂。但 \$50B/GW 是他在本讲中的粗略口径，缺少土地、电力、设备、建设期和利用率边界，不应被写成通用造价。收入快速增长是资本开支可持续的必要证据之一，却不是充分证明。

资本开支的真正检验

“有人愿意买更多 token”只证明需求侧开始成立。要证明一座 AI factory 经济可行，还必须同时看到单位服务成本、持续毛利、设施利用率、融资与折旧，以及收入增长能否在足够长的时间内维持。

6.5 Harness：把一次问答变成长时运行的执行系统

[00:31:16--00:33:51]

Sunny 对“需求是否只是短期热潮”的回答，首先不是给出另一组收入数字，而是指出产品形态正在改变。他说，公众当时看到的模型大多还没有充分反映更新一代硬件带来的能力；这一判断没有公开测量作为支撑，因此更适合看作他的产品周期预期。更可观察、也更适合教学的变化，是模型外部出现了 **harness（执行外壳）**。

单独的聊天界面通常遵循“一问一答”：用户提交请求，模型生成结果，本轮结束。API 也只是提供模型调用能力。harness 则把模型嵌入一个能够保持状态、调用工具并持续推进的执行循环。根据 Sunny 在 [00:31:51--00:32:48] 的描述，这个循环至少包含：

1. 接收目标并把目标拆成若干步骤；
2. 读取文件、消息或其他工作上下文；

3. 调用工具执行步骤并检查结果；
4. 遇到真正阻塞时通知用户；
5. 获得反馈后从原状态继续，而不是重新开始；
6. 在较长时间内反复运行，直到任务结束。

因此，token 消耗不再只由“用户问了多少次”决定。一个夜间持续运行的 agent 会在规划、工具调用、结果检查、错误恢复和汇报之间反复生成与读取 token。它同时提高两个需求变量：每项任务所需 token 数上升，可交给系统处理的任务数量也上升。只有当这些额外循环交付了有价值的结果时，它们才代表生产活动；无效重试、失控循环和重复读取仍然是成本，需要用任务成功率、人工接管次数和单位成果成本来约束。

Sunny 以其所述的 NVIDIA 内部助手为例：该系统连接团队消息、电子邮件和文件，每天整理待办并可代为处理一部分沟通与审批。这个例子说明 harness 的经济价值不只来自模型回答得更漂亮，还来自它能跨系统取得上下文、在适当时机采取动作，并释放人的注意力。这里不应把内部案例扩写成公开产品规格，也不能从口述推断其权限、安全或部署范围。

更多 token 不自动等于更多价值

Agent 把一次查询扩展成持续循环，必然扩大 token 需求，但经济性取决于循环最终完成了什么。评估 agent 时，应把 token 消耗与可验证任务成果配对，而不能只把使用量上升视为成功。




图 11: harness 将一次回答扩展为可检查、可恢复的执行循环：根据 00:31:51–00:32:48 重绘

6.6 单位成本与单位价值从两端改善经济性

[00:33:51--00:34:57]

本章最后把供给侧和需求侧合在一起。供给侧上，Brad 认为训练成本、尤其推理成本正在快速下降；原因不是某一块芯片独自进步，而是电路、内存、互联、机架、编译器和模型等多个层面的共设计。他用“工厂，而非单芯片”概括这一点：AI factory 的优化目标是单位电力与单位总拥有成本能产出多少有用 token。

需求侧上，同样数量的 token 若能完成更复杂、更完整的任务，所交付的“单位智能”就更有价值，用户的付费意愿随之提高。当单位服务成本下降、单位成果价值上升，两条曲线会共同改善毛利，而不是只依赖降价或补贴扩大使用。

Brad 随后称 OpenAI 与 Anthropic 已从一两年前的负毛利转为“非常正”的毛利。由于本讲没有公开财务报表、成本分摊或审计来源，这只能写成他的投资者判断，不能作为已确认财务事

实。即使服务毛利转正，也不等于扣除研发、训练和巨额资本开支后的自由现金流已经转正。

6.7 本章小结

Agent 经济的核心变化，是 AI 从“回答问题”进入“持续完成任务”。能力跨过可托付阈值后，分散用户可能快速增加购买；harness 又把一次调用扩展为包含工具、状态、反馈和恢复的长时循环，令每项任务及可处理任务总量同时增长。与此同时，工厂级共设计降低单位 token 成本，任务能力提高则抬升付费意愿。这个双向改善解释了为何嘉宾对推理需求和毛利转为乐观，但收入运行率、资本承诺、设施造价和毛利仍需逐一校准口径，不能由一组高速增长数字直接推出长期回报。

7 100× 共设计、基础设施扩张与社会契约

前五章讨论的主要是已经可以观察的工程机制和商业行为。第 6 章开始进入预测：成本曲线还能下降多久，能力曲线还能上升多久，基础设施是否需要继续扩张，以及增长收益最终如何分配。这里必须把“已观察事实”“组织目标”“嘉宾预测”和“政策主张”分开，否则很容易把强烈信念写成已被证明的结论。

7.1 先把事实、传闻与预测分开

[00:34:57--00:36:12]

Brad 的提问列举了若干当时新近或尚未公开的模型、沙箱事件和硬件代号，然后把问题压缩成两条曲线：推理成本下降是否会持续，预训练与推理时推理带来的能力提升是否会持续。这些模型名称、训练平台与安全事件在字幕中缺少足够定义，部分还是录制时未公开信息。它们不是回答问题所必需的证据，因此正文不保留具体代号，也不复述“模型试图逃逸”等未经本讲验证的细节。

保留下来的教学问题更清楚：过去的效率和能力改善，是一次性的代际跳跃，还是会因跨栈优化而继续复合？Sunny 的回答主要提供组织与工程机制，而不是一条带置信区间的预测曲线。

7.2 “100×”是跨层共设计的组织挑战

[00:36:12--00:36:58]

Sunny 说，Jensen Huang 会要求团队不要带来只有小幅改善的方案，而要先追问能否实现“100×”。这句话更像高压工程文化中的目标函数：迫使团队重新检查问题边界，而不是承诺每个元件或每代产品都能实测提升 100 倍。

如果只优化一个局部，系统瓶颈会迅速转移。计算电路更快，可能卡在内存容量或内存控制器；内存更快，可能卡在互联、调度、供电或散热；硬件吞吐增加，如果编译器和模型执行方式不变，也未必转化为等比例的有用 token。因此，“100×”的实际方法不是寻找一颗神奇芯片，而是让电路、内存、互联、编译、机架和工作负载共同改变，并以端到端任务结果验证组合收益。

Sunny 还强调，Groq 团队进入资源更丰富的 NVIDIA 生态后，能够尝试创业公司阶段难以承担的设计空间。这里的机制是资源、工具链、供应链和团队协作扩大了搜索范围；不能把它简化成

“公司变大所以性能必然提高”。

端到端，而非局部峰值

共设计的目标不是让每个部件都各自达到最高规格，而是消除系统最限制任务产出的瓶颈。所谓 100× 应被理解为组织挑战和端到端探索方向，除非给出基线、工作负载、延迟、功率和质量条件，否则不能写成已实现指标。




图 12: “100×” 应被理解为跨层共设计的搜索目标，而非单一部件的已实现倍数；根据 00:36:12–00:37:12 重绘

7.3 AI 辅助芯片设计：递归创新与需求反弹

[00:36:58--00:37:30]

当 Brad 追问团队是否用 AI 设计下一代芯片时，Sunny 回答使用得很多，并说 Groq 在创业阶段也已这样做。这个回答确认的是 **AI 辅助进入设计流程**，并没有说明 AI 独立完成芯片设计，也没有给出覆盖的环节、节省的工时或性能增益。因此，最稳妥的机制描述是：AI 帮助工程师扩大方案搜索、自动化部分分析或加快迭代；更好的芯片又为下一代模型提供更多计算，从而形成递归创新回路。

这一回路还包含需求反弹。硬件效率提高后，模型开发者会训练更大的模型、尝试更多推理步骤并打开新的任务；能力提高又带来更多使用，于是总基础设施需求未必下降。它与“效率提高导致使用规模扩张”的反弹效应相似：每单位任务更省算力，并不保证全社会消耗的总算力减少。

7.4 基础设施的外溢与期权价值

[00:37:30--00:38:00]

Sunny 用 Google 为搜索和视频建设基础设施作类比：这些投入不仅服务最初产品，也为后来的内容分发和更广泛互联网服务铺路。这个类比要说明的不是所有资本开支都会自动变成公共收

益，而是通用基础设施可能具有 **外溢效应**和 **期权价值**。

AI 基础设施也不只是一批芯片。电力接入、冷却、网络、机房、软件栈、运维能力和供应链成熟后，未来尚未出现的模型与应用也可能复用它们。反过来，如果设施被绑定在过窄的工作负载、利用率不足或技术迭代过快，期权价值就会大幅折损。因此，基础设施论证仍要回到兼容性、复用性和实际利用率，而不能只用“未来需求很大”作保证。

7.5 从能力强预测转向社会契约

[00:38:00--00:40:43]

Brad 随后把讨论从工程扩张推到 AGI。他转述与多位 AI 公司领导者的私人交流，称这些人对能力接近某个“指数末端”有高度一致的判断，并用“我们已经有 AGI”描述当前阶段。这是本段风险最高的口述：它没有给出 AGI 定义、评测标准、可复现实验或受访者原话，也无法从私人谈话判断行业共识。本文不采纳“已经实现 AGI”作为事实，只把它记录为 Brad 用来解释政策紧迫感的主观前提。

同样，Brad 预测 Anthropic 与 OpenAI 在录制当年新增的算力将超过此前十年所有实验室之和，并在下一年再翻倍。这个预测没有说明“算力”按芯片数、FLOP、功率、资本开支还是训练有效计算衡量；应把它视为高增长压力情景，而不是确定路线图。它的教学用途，是提醒读者：如果能力和部署速度真按这一情景前进，社会适应时间会显著缩短，治理问题便不能等技术完全定型后再处理。

Brad 借 Dario Amodei 的观点提出一组关键对照：创造更多智能和财富也许会变得更容易，但分配问题可能变得更困难。技术可以扩大总产出，却不会自动决定谁拥有算力、谁获得低价服务、谁分享资本收益，也不会自动补偿岗位和技能快速变化的人群。这就把 GPU 经济从企业单位经济推进到社会契约：公共政策要同时关心创新速度、开放进入、教育与转型支持、资本与技术收益的广泛参与。

Brad 提到自己的 Invest America 工作作为一种政策回应，但本段没有解释制度条款，因此正文不替他补写具体方案。可保留的结论是：技术政策不应只问“能不能把模型做得更强”，还要问“增长收益如何被更多人获得，转型成本由谁承担，哪些安全与竞争规则能够在不冻结创新的前提下降低伤害”。

条件情景不等于事实结论

“接近 AGI”“算力两年急剧扩张”“丰裕时代到来”都属于嘉宾的预测或二手转述。它们可以用于压力测试政策准备，却不能作为视频已经证明的技术事实。任何总结都应使用“Brad 判断 / 预测 / 转述”，并说明本讲没有给出独立验证。

7.6 拓展阅读

- [Acquired: Altimeter](#) (与 Brad Gerstner)：用于理解 Brad 的投资框架和立场；不是本讲收入数字的独立审计来源。
- [Groq Founder, Jonathan Ross: OpenAI & Anthropic Will Build Their Own Chips & Will](#)

NVIDIA Hit \$10TRN: 用于补充专用推理芯片与产业竞争背景；不得把其中观点无标注地并入本讲原话。

7.7 本章小结

[00:40:21--00:41:03]

本章把“100×”还原为跨层共设计的组织目标：真正的性能来自电路、内存、互联、编译、模型与整座工厂的端到端协同。AI 又开始进入芯片设计流程，形成“更强工具帮助造更强硬件、更强硬件支持更强模型”的递归创新；但效率提升也可能通过更大的模型和更多任务反弹为更高总需求。基础设施因可复用能力而具有外溢与期权价值，却仍需接受利用率和兼容性的经济检验。

Brad 对 AGI 和算力扩张的判断应保持为条件情景。即使技术乐观成立，增长也不会自动完成分配；越快的能力与资本扩张，越需要提前讨论访问机会、劳动转型、安全边界和收益分享。Brad 最后把自己定位为乐观但并非无条件乐观：历史上的工业与数字革命都需要主动制度回应，本轮变化也一样。[00:40:43--00:41:03] 为致谢和转入问答，不含新的教学论点；00:41:10 起的学生问题归第 7 章处理。

8 人在智能商品化之后如何创造价值

上一章把技术加速最终落到了社会契约：生产更多智能相对容易，如何分配收益、帮助人们完成转型却更难。问答环节随即把同一个问题缩小到个人尺度。一位学生的问题有多处听不清，但核心焦虑很明确：当机器在认知任务上的边际能力持续上升，学生应如何定位自己，今天的学习会不会失去价值？

8.1 技术替代的是任务，人的价值会重新组合

Brad 先用工业革命建立历史直觉。过去的工匠可能从头到尾制作一个产品，大规模生产到来后，这种完整工作被分解、标准化并由新的生产体系替代。对被替代的个人而言，冲击是真实的；但社会并没有在旧职业消失后停止运转，劳动力逐渐转向新的服务和更高层次的活动。

讲者用“过去约八成人从事制造、农业等工作，而今天约七成人在服务业”说明这种迁移。这个比例没有给出国家、年份和分类口径，因此不宜作为统计结论；更可靠的教学重点是：职业不是不可分割的原子，技术通常先重组其中的任务，再改变人们创造价值的组合。教练、瑜伽教师等过去难以大规模负担的服务，也可能随收入和生产率提升而扩张。

历史类比不能自动保证平稳转型

“过去出现了新职业”不等于每个人都会无成本、同步地完成转岗。技能转换、地域、收入分配和制度支持都会影响谁先受益、谁承担损失。Brad 的类比回答了“人的价值不会必然归零”，却没有消除过渡期的现实摩擦。

8.2 智能民主化：把稀缺服务变成普遍能力

技术进步的积极情境并不仅是创造新职业，还包括把原本只对少数人开放的服务扩展给多数人。Brad 以专属辅导和 concierge medicine 为例：过去，个性化教师或高频、定制化医疗服务只属于支付能力较强的人；如果 AI 能以更低边际成本提供有用的辅导、信息整理和持续支持，更多人就可能获得接近个性化的服务。

“可访问”不等于“同等质量”

AI 可以降低一次建议或一次辅导的边际成本，但真正的服务质量还受数据、专业监督、责任边界和现实资源影响。尤其在医疗场景中，普及信息辅助不能被写成已经实现同等临床照护。本讲表达的是智能与访问机会民主化的愿景，而非效果已经得到验证。

这一点把个人问题和公共问题连接起来：如果机器使某些认知能力更便宜，个人不必只与机器争夺原来的同一项任务，也可以借助新能力服务此前成本过高、覆盖不足的人群。价值创造的空间会从“我能否比机器更快给出答案”移向“我能否定义值得解决的问题，并把能力组织成可靠服务”。

8.3 让自己成为 bionic：工具、创造与专业判断

给学生的直接建议（意译，00:43:17–00:43:44）

Brad: 让自己成为 bionic，成为创造者，找到你能增加价值的方式。使用手边最好的工具，让自己尽可能有效。

这里的 bionic 可以译为“工具增强型工作者”。Brad 以招聘为例：如果候选人坚持不用 AI、甚至不用电子表格而完全手工工作，这会被视为问题。评价标准不再是“有没有借助工具”，而是能否选择合适工具、检查其输出，并把节省下来的时间用于更高价值的判断和创造。

这个建议并不意味着专业基础可以省略。讲者在随后明确补充：“这并不表示你不需要学习这些东西。”只有理解领域问题、数据和失败模式，使用者才有能力发现模型的错误、判断结果是否可交付。bionic 的关键不是把责任交给机器，而是把人的专业判断与机器的速度、搜索和生成能力组合起来。

人的竞争单位从裸能力变成组合能力

未来更有意义的比较不是“人能否在白板上比机器更快”，而是一个人能否把领域知识、AI 工具、创造力、验证能力和执行责任组织成可交付结果。工具使用本身不是价值；选择问题、承担判断并完成闭环才是价值。




图 13: bionic 工作者的组合能力：根据讲者在 00:43:17–00:44:36 的建议重绘

8.4 IQ 商品化之后，关系与组织能力更重要

Brad 用一句具有修辞性的判断概括职业变化：“IQ gets commoditized, EQ becomes super valuable.” 他所说的 EQ 并非严格心理测量指标，而是更具体的社会能力：建立可信网络、说服他人、组建团队、协调分歧和带领组织行动。当标准化认知任务越来越容易被机器完成，仅凭“比房间里的其他人算得更快”形成的稀缺性会下降；将知识转化为共同决策和现实行动的能力则可能升值。

“IQ 商品化”不是“知识不再重要”

这句话描述的是部分标准化认知产出的边际价格可能下降，并不证明所有高阶判断都会自动化。领域知识仍是提出好问题、评估证据和承担责任的基础。更稳妥的个人策略，是同时提升工具能力、专业深度与人际协作，而非用所谓 EQ 取代学习。

8.5 从等待偶然发现，到主动扩大搜索空间

Sunny 为个人建议补上了创新层面的理由。他用牛顿与苹果的故事作类比：人类历史上的发现常依赖某个偶然观察触发理论思考；如果 AI agent 能持续搜索数学或科学空间、提出候选规律并帮助验证，人类便不必完全等待偶然事件，知识生产的搜索速度可能提高。

这段话应理解为未来机制，而非本讲已经证明“agent 可以无人监管地完成科学发现”。发现仍需要正确问题、实验或形式化验证、同行审查和责任主体。更忠实的结论是：机器可能扩大人类能够探索的假设空间，让专业人员把更多精力放在选择方向、设计验证和解释意义上。

8.6 本章小结

学生不应把选择压缩成“继续学习”或“把一切交给 AI”。历史经验说明，技术会淘汰具体任务并重组职业；AI 的积极潜力是降低专业服务的访问门槛，同时扩展搜索与创造空间。个人的可操作路线是成为工具增强型创造者：保留领域基础和验证能力，熟练使用最好的工具，并加强说服、协作、组队和领导能力。这里没有对无摩擦转型的保证，分配与再培训仍是上一章社会契约问

题在个人层面的延续。

9 边缘设备、安全治理与 NVIDIA 的竞争经济学

最后一组问答把讨论从个人重新扩展到产品和产业。四个问题看似分散——手机端 AI、安全沟通、训练设备的后续用途、NVIDIA 的长期经济模型——其实都在追问同一件事：当智能能力快速上升时，怎样把它放进受约束的真实系统，并让技术、资本与治理形成可持续闭环？

9.1 端侧与云端：隐私、能力和能耗的多目标权衡

在 Apple 相关问题中，Brad 把隐私描述为公司的核心消费者价值主张：若更强模型主要在云端运行，用户数据就可能需要离开设备；若坚持尽量在端侧完成计算，又会受到模型能力、内存、功耗和散热约束。于是产品没有单一最优答案，只能在隐私承诺与前沿能力之间权衡。

他给出的乐观情境是，设备生态足够有黏性，手机上的助手即使不是最强前沿模型，只要明显优于旧产品，对大多数用户也可能“足够好”；悲观情境则是其他厂商推出更自然、更 ambient 的设备形态，改变用户与智能服务的入口。Brad 同时表达了个人偏好，希望模型公司集中建设智能而非亲自制造设备。这些都是投资者在录制时点的判断，不是 Apple、Google 或 OpenAI 的正式产品路线结论。

Sunny 用一个极端例子强调端侧能耗：据其口述，一个相对较小的 8B 参数模型持续运行，可在约三十分钟内耗尽一部 iPhone 的电量。这个 anecdote 没有给出设备型号、量化精度、任务、利用率或测量方式，不能作为普适电池基准；它只说明把前沿推理直接推到边缘设备，会迅速碰到能耗与散热边界。

为了组织这一权衡，可以使用下式作为笔记作者的概念框架；它不是视频给出的测量模型：

$$U_{\text{edge}} = w_p P + w_l L + w_a A - w_e E - w_r R.$$

- U_{edge} ：某一端侧方案的综合效用；
- P ：隐私与数据控制收益；
- L ：本地响应、离线可用等端侧收益；
- A ：模型对目标任务的能力；
- E ：电池、功耗与散热成本；
- R ：设备端或云端引入的安全、可靠性与合规风险；
- w_p, w_l, w_a, w_e, w_r ：不同产品和用户对各因素的权重，不存在本讲给出的统一数值。

端侧 AI 不是单纯的模型压缩问题

是否在设备上运行，必须同时回答：用户数据能否离端、任务需要多强模型、可接受多大延迟、设备能提供多少内存与功率、失败由谁承担。较小模型可能换取隐私和离线能力，云端模

型可能换取更强能力；产品设计的任务是选择可接受的组合，而非宣称一端永远优于另一端。




图 14: 端侧—云端不是二选一，而是多目标执行边界：根据 00:45:53–00:47:36 重绘

9.2 安全沟通：真实风险与监管俘获之间的边界

另一位学生询问，当前沿实验室的负责人同时发布产品、讨论 AGI/ASI 与安全风险时，应该如何调整公开表达。Brad 的回答拒绝两个极端：一方面，他认为这些负责人可能真诚地看到能力曲线并担心漏洞；另一方面，如果以恐惧叙事阻止后来者进入，让领先者借规则固化地位，就可能构成 regulatory capture（监管俘获）。

Brad 举了一个录制时点的案例：某个未发布模型先在内部和多方合作环境中接受 sandbox 测试，团队发现浏览器漏洞后，用同类 AI 辅助修复和加固，再考虑公开发布。字幕中的模型名、项目名、漏洞数量与修复周期都需要独立核验，因此正文保留治理机制，不保留未经确认的专名和数字。

这一机制可以拆成五步：封闭评估能力与滥用路径；记录可复现漏洞；让产品方和外部伙伴共同修复；用回归测试验证加固；根据剩余风险决定发布范围。它体现的是“先发现、再修复、后开放”的受控迭代，而不是把安全等同于永久不发布。

双重约束下的安全治理

强大技术既可能带来巨大公共收益，也可能放大漏洞和滥用。可信治理必须同时防住两种失败：忽视真实风险而仓促开放，以及借风险话语排除竞争。sandbox、独立评估、多方协作、可验证修复和清晰发布门槛，是本讲给出的务实方向之一。




图 15: “先发现、再修复、后开放”的安全发布循环：根据 00:48:12–00:50:43 重绘；未采用字幕中未核实的项目专名与数字

讲者把这种双面性类比为原子技术：同一基础能力既能服务能源，也能制造武器。类比的作用是提醒读者，能力越强，收益与损害的上限都可能提高；它不能替代对具体模型、攻击面、概率和缓解措施的实证评估。Brad 所称的“市场化解决方案”也只是治理工具之一，不能推出公共规则或外部监督不再需要。

9.3 训练资产不会立刻报废：从训练集群转入推理服务

下一位学生的问题有大量听不清的数字，正文不尝试复原。Sunny 清楚的回答是：用于训练的大型集群在训练任务结束后，可以逐步转为推理设备。也就是说，一代训练资产的经济寿命不只包括“训练出模型”这一阶段，还可能继续承载模型部署和 token 生产。

可以用一个简化的生命周期关系表达这一点：

$$V_{\text{life}} = V_{\text{train}} + V_{\text{infer}} - C_{\text{convert}}.$$

- V_{life} ：硬件资产在整个生命周期内创造的价值；
- V_{train} ：用于训练新模型所产生的价值；
- V_{infer} ：转入推理服务后产生的价值；
- C_{convert} ：调整网络、软件栈、调度、功率与运维所需的转换成本。

这是笔记作者用来说明资产复用的概念式，不代表所有训练集群都能无损转为推理。训练和在线推理对延迟、可靠性、内存布局、网络和利用率的的要求不同；硬件代际、能效和服务需求也会决定旧集群是继续使用、降级部署还是退役。

Sunny 还强调，不能只比较“计算量增加了多少”，也要比较更大训练集群带来的能力变化。他转述一则 GPT-2 时期与当前计算规模的约 $50\times$ 对比，但基准、口径和能力指标都没有展开，因此这里不把它当成缩放定律。更稳妥的结论是：训练资产一方面生成能力更强的模型，另一方面可在之后进入推理阶段；AI 又开始辅助发现人类未注意到的软件和硬件优化，继续推动下一代系统效率。

资本开支的两类回报

训练集群的回报至少来自两条路径：其一，训练结果提高模型能力；其二，硬件在训练后继续承担推理。评估资本开支时应把模型产出、后续利用率和转换成本同时纳入，而不是把“训练结束”误判为“资产价值归零”。




图 16: 训练资产的生命周期与递归创新：根据 00:51:01–00:52:17 重绘；实际复用仍取决于转换成本和利用率

9.4 NVIDIA 必须继续竞争，而不是依靠既有优势

最后一个问题关注 NVIDIA 的高市场份额和利润能否持续。Sunny 先说明自己在 NVIDIA 任职，因此不适合直接回答；Brad 也披露自己是 NVIDIA 投资者。这个利益关系是理解其后乐观判断的必要背景。

Brad 的核心机制判断比具体估值数字更有教学价值：AWS Trainium、Google TPU、Cerebras、Groq 和各类定制 ASIC 都可能提供替代方案、争夺份额并压低价格。面对这种竞争，NVIDIA 只有两条基本路径：继续交付客户愿意支付溢价的更好产品，或者降低价格、接受利润率下降。既有生态和领先地位不能免除竞争。

与此同时，竞争者成功并不必然意味着 NVIDIA 的收入收缩。如果智能与算力的总市场扩张得足够快，多家替代芯片可以获得份额，而平台型供应商仍继续增长。可以用以下简化关系区分“市场、份额与利润率”：

$$R_i = S_{\text{market}} s_i, \quad G_i = R_i m_i = S_{\text{market}} s_i m_i.$$

- S_{market} ：相关算力市场的总收入规模；
- s_i ：公司 i 的收入份额；
- R_i ：公司 i 在该市场的收入；
- m_i ：公司 i 的毛利率；
- G_i ：公司 i 的毛利润；
- 下标 i ：可以代表 NVIDIA 或任一竞争者。

若竞争令 s_i 或 m_i 下降，但 S_{market} 增长得更快， R_i 甚至 G_i 仍可能上升；反过来，总市场增长也不能保证任何单一公司维持份额和利润率。这正是 Brad 最后一句的经济含义：Trainium、TPU、定制 ASIC 等方案取得成功，与 NVIDIA 在录制时点仍表现强劲可以同时成立，它们共同说明的也许是智能市场足够大，而不是某家公司已经免疫于竞争。




图 17: 市场扩张与份额竞争可以同时发生：根据 00:53:38–00:55:48 重绘

投资者判断不是课程已证结论

Brad 在回答中引用了 NVIDIA 当时的市值、盈利倍数、增长率、未来八个季度订单，并预测其将成为首家市值 \$10 trillion 的公司。这些数字高度时点化，且发言者披露持仓；交易口径、预订收入与已确认收入也不能混用。本文因此不保留这些精确市场数字，只记录“投资者看多且替代竞争持续”的机制判断，不能把预测写成必然结果。

Brad 将其乐观判断归因于团队、训练与推理的产品路线及迭代速度，同时承认替代方案会持续成功。课程到此结束，最后的致谢没有新增教学信息。忠实的收束不是“NVIDIA 必然获胜”，而是：AI 基础设施仍处于扩张早期，竞争将通过产品差异、价格和利润率重新分配收益；判断任何公司的长期经济性，都必须同时看总市场、份额、价格和成本。

9.5 本章小结

最后一章给出了四类现实约束。端侧部署必须在隐私、能力、能耗和风险之间取舍；前沿能力发布必须在真实安全关切与监管俘获之间建立可验证的治理；训练集群可以转入推理，资本资产应按全生命周期评估；NVIDIA 与替代芯片的竞争则要求把总市场扩张和单家公司份额分开。它们共同说明，技术能力只是起点，真正的经济结果取决于产品边界、治理机制、资产利用率和持续竞争。

10 总结与延伸

10.1 把全讲压缩成一条因果链

这节课从传统软件的边际复制成本出发，最终走到职业选择、安全治理与产业竞争。中间看似跨越了宏观经济、芯片架构、云服务、agent 产品和资本市场，实际始终围绕同一个问题：**有限的物理投入，怎样被组织成可付费、可持续且对社会有用的智能服务？**




图 18: GPU 经济的完整闭环：根据全讲机制综合

这条链上任何一段都不能被单独当作结论。芯片峰值高，不等于端到端 token 产出高；token 便宜，不等于总算力需求下降；agent 消耗更多 token，不等于它创造了更多价值；收入快速增长，也不等于资本开支已经产生长期回报；总市场扩大，更不等于任何一家公司的份额和利润率会自动维持。

10.2 五个最可迁移的分析框架

1. **先固定比较单位。**讨论“推理变便宜”时，要固定模型质量、任务、延迟、吞吐、精度和观察周期；讨论“更有价值”时，要固定可验收成果，而不只是 token 数。
2. **从单点规格上移到系统瓶颈。**计算、片上/片外内存、互联、编译、调度、供电和散热会轮流成为瓶颈。局部改善只有穿过整条数据路径，才会成为真实产能。
3. **把单位经济与总量需求分开。**单位 token 成本可以下降，而模型规模、每任务 token 和任务数量增长得更快；“通缩”和“稀缺”并不矛盾。
4. **把能力阈值与可靠交付连接。**用户不是为抽象模型分数付费，而是为可托付的任务、较少的人工补救与可验证结果付费。harness 的价值来自闭环，不来自无限循环。
5. **把技术收益与制度分配分开。**更高生产率可以扩大总剩余，但不会自动决定访问权、收入分配、安全责任和劳动转型。技术乐观必须与治理和社会契约同时成立。

10.3 给建设者、投资者与学习者的检查表

角色	优先追问	容易误判
系统建设者	固定功率和服务目标下，每项可验收任务的成本、延迟、质量与失败率如何变化？	用芯片峰值或单一微基准测试代替端到端系统结果。
产品建设者	agent 的额外 token 是否减少人工时间、提高成功率或完成原来不能完成的任务？	把调用量、运行时长或自主循环次数当作价值本身。
资本配置者	收入、贡献毛利、设施利用率、融资期限与资产复用是否处于同一口径？	把 ARR、预订、承诺和已确认收入混用；只看总市场不看份额与利润率。
政策制定者	谁获得能力、谁承担风险与转型成本，评估和发布门槛是否可验证？	在“完全放任”和“以安全之名冻结竞争”之间做错误二选一。
学生与工作者	哪些任务可以交给工具，哪些判断必须由自己理解、验证并负责？	把工具使用误写成专业基础的替代，或坚持不用工具来证明个人价值。

10.4 仍然开放的研究问题

- 异构 prefill/decode 系统在不同模型、批量、上下文、延迟与精度条件下，端到端收益如何变化？通信与状态迁移在何时抵消局部优势？
- 评价 agent 的最小可靠经济单位是什么：成功任务、节省的人时、降低的错误率，还是风险调整后的业务结果？
- 当单位 token 成本持续下降时，需求反弹的弹性有多大？哪些任务会被创造出来，哪些只会产生低价值循环？
- 训练集群转入推理后的真实利用率、转换成本和能效，如何进入资产折旧与基础设施融资模型？
- 端侧与云端的边界能否由可验证隐私、分级能力和混合执行动态决定，而不是由品牌立场预先固定？

- 如何建立既能发现高危漏洞、又不被领先者用于排除竞争的独立评估、sandbox 与分级发布制度？

10.5 补充材料的正确用法

Stanford 官方 [Week 2 materials](#) 为本周列出两段延伸访谈：[Acquired: Altimeter](#) (Brad Gerstner) 与 [Groq Founder Jonathan Ross](#) 访谈。它们适合补充两位嘉宾的投资框架、专用推理芯片、能源和竞争背景，但不能反向证明本讲中的时点化数字，也不能替代本讲字幕与画面证据。Groq 与 NVIDIA 的关系则以 Groq 官方所称的[非独家推理技术授权协议](#)为边界；本笔记不将其表述为 NVIDIA 收购 Groq 公司。

最后的判断

GPU 经济不是一场只由 GPU 决定的经济。真正的竞争发生在整条价值链上：物理资源能否被系统共设计转成更多 token，token 能否被产品组织成更高价值的任务，收入能否覆盖长期资本投入，而增长收益能否在安全、竞争和社会转型约束下被广泛分享。

10.6 本章小结

本讲最值得保留的方法，是始终把物理约束、系统效率、产品价值与社会分配置于同一张因果图中，同时不混淆它们的证据层级。读者面对新的芯片倍数、模型能力、agent 演示或收入数字时，都可以回到四个问题：比较单位是什么、条件是否一致、谁在承担成本、结果是否真正可验收。只有这些问题同时得到回答，更多 token 才可能转化为更好的经济与更可靠的社会价值。