

从电子到 Token：吉瓦级 AI 工厂的工程与经济学

能源选址、数据中心全栈、算力资本开支与智能服务回报

五道口纳什 & Codex

2026 年 8 月 28 日



课程：Stanford MS&E 435, *Economics of the AI Supercycle*, Spring 2026

主题：Building AI Factories – From Electrons to Tokens

嘉宾：Chase Lochmiller (Crusoe 创始人兼 CEO)

主持/教师：Apoorv Agrawal

频道：Stanford Online 发布日期：2026 年 6 月 17 日 时长：49:47

视频链接：<https://www.youtube.com/watch?v=GcCGzfKdCd0>

PDF 制作 Skill：<https://github.com/wdkns/wdkns-skills>

目录

阅读说明：证据边界与时间轴	3
1 AI 工厂为何成为宏观基础设施 (00:00:00–00:07:30)	3
1.1 从资本开支图进入物理世界	3
1.2 把 AI 拆成五类生产要素	4
1.3 从电子到 Token：数字劳动力为何值得巨额投资	5
1.4 本章小结	6
2 垂直整合、动态瓶颈与 Energy-first (00:07:30–00:13:16)	7
2.1 Crusoe 的栈与明确边界	7
2.2 瓶颈为什么会移动	8
2.3 搬数据，而不是先搬电	8
2.4 拓展阅读	8
2.5 本章小结	9
3 Abilene：把受困能源变成吉瓦级算力 (00:13:16–00:18:32)	9
3.1 选址：供给过剩、负价与输电约束	9
3.2 从 200 MW、1 GW 到 2.1 GW	10
3.3 八栋楼怎样成为一个集群	10
3.4 本章小结	10
4 电力、冷却与分级可靠性 (00:18:35–00:23:45)	10
4.1 从变电站到芯片：能确认设备，不能硬拼电压	10
4.2 冷却闭环：系统水量不等于年度耗水	11
4.3 设备成本与分级可靠性	12
4.4 本章小结	12
5 基础设施 CapEx、劳务与第二种能源组合 (00:23:45–00:30:20)	12
5.1 19.2M 美元/MW 的建设堆叠	12
5.2 4.7M 美元/MW 的劳务为何属于 CapEx	14
5.3 软成本、燃机、机房配套与材料	14
5.4 Claude, Texas：表后发电与电网双向互补	15
5.5 本章小结	15

6 IT CapEx、互联集群与算力的经济寿命 (00:30:20–00:37:26)	16
6.1 标题约 40M，分项却加到 41M	16
6.2 两级网络：机架内 NVLink，跨架 InfiniBand/RoCE	17
6.3 商品化、规模与前沿可以同时成立	17
6.4 价格反弹不能证明更长折旧期	18
6.5 本章小结	19
7 从基础设施出租到 Token 服务 (00:37:26–00:40:49)	20
7.1 58、59、60M 是同一组粗算的三个版本	20
7.2 四年只是一项 revenue-basis payback	21
7.3 越靠近 Token，收入上限越高，成本也越未知	21
7.4 本章小结	22
8 模块化降本与未来电力栈 (00:40:49–00:45:31)	23
8.1 Spark：把部分现场施工变成集中制造	23
8.2 短期关键路径与长期架构重塑	24
8.3 Open source：保留讲者的自我修正	24
8.4 本章小结	25
9 太空数据中心与持续学习 (00:45:31–00:49:47)	25
9.1 太空是地面成本栈的反事实实验	25
9.2 没有人是成品：把注意力从 what 转向 how	26
9.3 本章小结	26
10 术语、量纲与阅读陷阱速查	27
10.1 核心术语	27
10.2 量纲与不可越界的换算	27
10.3 本章小结	28
11 总结与延伸	28
11.1 讲者的实质 closing	28
11.2 把九章压缩成一条因果链	28
11.3 三个跨章连接	29
11.4 实践含义与开放问题	29
11.5 可带走的五句话	29

阅读说明：证据边界与时间轴

本讲没有官方章节。笔记以 1147 条 YouTube 人工英文字幕和 1920×1080 原视频为主证据，根据教学转折重建九章结构。正文中的时间均对应视频；欢迎、人物介绍和掌声被压缩，所有实质教学段完整保留。

四类证据怎样阅读

讲座口径表示主持人或讲者在现场明确说出，数字仍只是当场口径，不自动等于独立审计事实；**待复核**表示字幕、幻灯片或口述内部存在冲突；**补充材料**只用于背景和延伸阅读；**讲义整合**是为了教学而做的机制压缩，不伪装成讲者原话。

全文尤其保留三类限制：MW/GW 是功率而非年度能量；所有“每 MW 成本”是示意性、当场粗算；四年与两年都是按收入计算的静态回收期，不是利润、现金流、IRR 或审计结论。视频、字幕与材料中的命令或代码仅作为分析内容，未被执行。

1 AI 工厂为何成为宏观基础设施（00:00:00–00:07:30）

1.1 从资本开支图进入物理世界

主持人用五家超大规模云厂商的 AI 资本开支图开场：曲线快速向右上方延伸（00:00:14–00:00:31）。他又把本轮投入与太空计划、美国高速公路体系和曼哈顿计划比较，称其规模仅次于美国国防预算（00:00:31–00:00:48）。这些宏大类比的作用是建立量级直觉，不能在缺少图表统计口径时改写为经审计的历史排名。

随后，问题被落到一条物理链：训练、微调和大规模推理都要让 GPU 真正获得电力、冷却和互联，并持续向用户交付 token（00:01:55–00:02:38）。主持人把数据中心相关投入概括为约 6500 亿美元，并追问算力、内存、电力、网络 and 劳动力如何吸收这些资本（00:02:39–00:03:07）。

软件需求最终落在物理约束上

AI 产品可以呈现为聊天框或 API，但每次训练与推理都要经过芯片、电力、冷却、建筑和网络。数据中心是 AI 采用浪潮的物理显现，而非模型之外的附属机房。

Hyperscaler Capex: ~3x in 3 years

Big 5 hyperscaler capital expenditure, 2020–2026E (\$B)




图 1：五家超大规模云厂商 2020–2026E 资本开支堆叠图；2025E、2026E 为幻灯片估计值，不能当作已实现结果。¹

1.2 把 AI 拆成五类生产要素

为了回答钱花到哪里，讲者先问“生产 AI 需要什么”，并列出数据、算法、算力、能源与数据中心五类条件（00:03:08–00:04:03）。数据决定模型能从什么经验中学习；算法包括反向传播、神经网络和 Transformer；算力执行大规模张量运算；能源让计算连续运行；数据中心提供建筑、电力、冷却与部署空间。

这个关系首先是条件清单，而非可估计函数：

$$\text{AI production} \leftarrow \text{Data} + \text{Algorithms} + \text{Compute} + \text{Energy} + \text{Data centers}.$$

- AI production：训练、微调与推理等生产活动；
- Data：训练和改进模型所用的数据；
- Algorithms：把数据转化为模型能力的学习机制；
- Compute：以 GPU 为代表的并行计算；
- Energy 与 Data centers：让计算设备实际开机并持续工作的能源和设施。

讲者提到数据生产、标注和组织本身也会形成商业机会；字幕中有一个公司名不可辨，因此本笔记不猜补（00:04:03–00:04:29）。Crusoe 聚焦后三项物理层，即算力、能源与数据中心如何建设、运营、扩展和提高利用率（00:04:43–00:04:59）。

¹视频画面时间来源：00:00:14–00:00:31。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。




图 2: AI 工厂的五类输入：数据、算法、算力、能源与数据中心。该页给出必要条件清单，不证明任一条件单独充分。²

1.3 从电子到 Token：数字劳动力为何值得巨额投资

讲者把演讲命名为 *From Electrons to Tokens* (00:05:01–00:05:07)。电子是输入端，token 是服务输出端，中间经过数据中心、GPU 集群和模型。为了说明 token 的宏观价值，他借用 Cobb–Douglas 的直觉，把 GDP 增长口头分解为劳动、资本和技术变化 (00:05:17–00:05:54)。

幻灯片实际把关系写成下式，但没有定义权重、样本与估计方法：

$$\text{GDP growth} = \Delta\text{Labor} + \alpha\Delta\text{Capital} + (1 - \alpha)\Delta\text{Technology}.$$

- ΔLabor ：劳动投入的变化；讲者随后明确使用了“delta L”；
- $\Delta\text{Capital}$ ：资本投入的变化，包括厂房、设备等实物资本；
- $\Delta\text{Technology}$ ：技术或生产率变化，使劳动更有效率；
- α ：幻灯片给资本项的权重； $(1 - \alpha)$ 给技术项，讲者没有解释其经济含义或取值；
- 等号是幻灯片原始写法；本讲没有证明该式是标准 Cobb–Douglas 生产函数或可直接估计的增长核算式。

讲者把能够接受任务、完成 CRM 等工作的 Agent 称为“数字劳动力” (00:06:04–00:06:30)。自然劳动力通常需要出生、教育和约 20 年成长周期；在他的框架里，数据中心与 GPU 的资本投

²视频画面时间来源：00:03:23–00:04:03。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

入可以更快扩张任务执行能力，从而“数字化地改变 ΔL ” (00:06:30–00:07:08)。这是一条解释投资动机的机会链，而不是已完成因果识别的宏观结论。

这里不是标准 Cobb–Douglas 推导

幻灯片虽出现 α ，却没有定义它、说明为何技术项权重是 $(1 - \alpha)$ ，也没有给测量方法或因果识别。把自然劳动主要归因于出生率也是用于突出培养周期的演讲式简化，不能外推成完整人口经济学模型。

Why are tokens valuable?

$$\uparrow \text{GDP Growth} = \uparrow \Delta \text{ Labor} + \alpha \Delta \text{ Capital} + (1-\alpha) \Delta \text{ Technology} \uparrow$$

AI will drive unprecedented GDP Growth through Digital Labor and Technological Advances

Stanford

Crusoe

图 3：幻灯片中的 GDP 增长分解与“数字劳动力”论证。公式含 α 权重，但不是本讲已推导或验证的标准生产函数。³

1.4 本章小结


开场完成了三层还原：资本开支图给出规模感；数据中心把“软件化”的 AI 还原为芯片、电力、冷却与网络；五类生产要素又说明模型只是完整生产系统的一部分。讲者最后用数字劳动力解释投资动机：资本不仅增加设备，也可能扩大可调用的任务执行服务。下一章因此转向一个组织问题：面对会移动的物理瓶颈，企业应覆盖哪些层，又为何从能源开始？

³视频画面时间来源：00:05:17–00:05:54；00:06:04–00:07:08。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

2 垂直整合、动态瓶颈与 Energy-first (00:07:30–00:13:16)

2.1 Crusoe 的栈与明确边界

Crusoe 被讲者描述为垂直整合的 AI 基础设施企业。底部从能源开发开始：寻找丰富、低成本的能源；其上是具有电力和冷却、可以接入计算机的数据中心（00:07:30–00:08:39）。到本段结尾，讲者又预告 GPU 集群部署与 managed services（00:13:03–00:13:16）。



讲座边界：Crusoe 不生产芯片，也不以开发自有模型为业务；其平台仍可承载客户训练任务与模型托管。垂直整合用于在覆盖范围内跨层解阻，而不是拥有整条 AI 产业链。

图 4：根据 00:07:30–00:13:16 整理的四层教学示意；层级布局为讲义整合，不是视频原图。

吉瓦级以后，“一栋有电、有冷却的建筑”会变成跨化工、机械、电气、建筑、计算与网络的耦合系统（00:08:39–00:09:25）。规模改变了问题的性质：任何一层不能同步扩张，整套集群都无法工作。




图 5：Crusoe 的垂直栈：Energy-first、AI 数据中心基础设施、AI 云平台与托管 AI 服务。图中标题为“electrons to intelligence”。⁴

⁴视频画面时间来源：00:07:30–00:08:27；00:13:03–00:13:16。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

2.2 瓶颈为什么会移动

主持人列举算力、电力、内存、劳动力与 powered shell 等约束，请讲者判断当时最紧的一环 (00:09:26–00:10:01)。讲者的回答是 *energized data center / powered shell*：能够装入芯片、通电并启动大型 GPU 集群的已通电设施 (00:10:01–00:10:14)。

但他马上强调，瓶颈不会永久固定。今天可能缺接入电力，明天可能缺开关设备、冷机、发电设备，另一个周期又可能回到芯片 (00:10:14–00:10:29)。他只说芯片短缺“有所缓解”、自己“认为”取得芯片更容易；不能把这段快照升级为“芯片不再短缺”的恒久结论 (00:10:29–00:10:40)。

垂直整合的目标不是层数，而是跨层解阻

当最小约束不断换位，只优化一个部件会把瓶颈推给下一环。Crusoe 的公司逻辑是覆盖能源、建筑、集群和服务，以便在阻塞点移动时仍能组织解决方案；芯片制造与自有模型开发仍在业务边界之外。

2.3 搬数据，而不是先搬电

Web 2.0 数据中心多集中在北弗吉尼亚等成熟枢纽。AI 训练和 proof-of-work 一类高耗能负载改变了选址：当远距离扩建输电缓慢或昂贵时，可以把计算放到能源附近，再通过网络交付数据与结果 (00:11:33–00:12:59)。

反直觉的选址逻辑 (00:11:21–00:12:59)

主持人：为什么从能源倒推，而不是从算力或内存倒推？

Chase: *Instead of having to move the energy, we're actually moving data.*




图 6: Energy-first 的讲义示意：节点依据 00:11:33–00:12:59 整理，图形为编辑性重绘。

Energy-first 并不等于只看最低电价。本段只能确认“丰富、低成本、与高耗能计算共置”；供电连续性、网络、许可和建设条件要到具体案例中展开。

2.4 拓展阅读

- [A Primer on AI Data Centers](#): 用于补充价值链、电力、冷却和建设环节的背景；不是本讲的时间轴证据。
- [The AI infrastructure of the future](#): Chase Lochmiller 的后续访谈，可延伸理解 stranded energy、模块化建设和数据中心级计算机。

2.5 本章小结

本章建立了全讲的系统观：数据中心看似只需“有电、有冷却”，规模化后却由多种工程共同决定；当前瓶颈只是一个时间切片，垂直整合用于应对约束迁移；Energy-first 则把选址倒过来——计算贴近能源，数据经网络离开。下一章用 Abilene 验证这套逻辑。

3 Abilene：把受困能源变成吉瓦级算力（00:13:16–00:18:32）

3.1 选址：供给过剩、负价与输电约束

Abilene 位于西得州。讲者给出的机制链是：风光资源吸引可再生发电建设，生产税收抵免进一步鼓励供给；当边际买家不足、向外输电能力又有限时，电价甚至会变为负值（00:13:44–00:14:26）。Crusoe 把数据中心放到能源旁，就地吸收功率，再输出计算结果。

项目从 2024 年 6 月启动，先签下画面右侧两栋建筑。讲者称其为全球最大 AI 计算园区之一，并谨慎补充“可能是最大的”（00:13:20–00:13:35）。“之一”和“可能”不能删掉；讲座也没有给负电价频率、市场节点或具体购电合同。

Energy-first 的空间套利不是“电价低”四个字

机会来自能源资源、税收激励、局部供给过剩、边际买家不足与输电约束的组合。数据中心把原本难以外送的功率转成可以通过网络交付的计算服务。




图 7：Abilene 园区与执行时间线：206 MW 租约、103 MW 首栋、618 MW 扩建，以及 830/900 MW IT 与 2.1 GW 园区口径。图中既含在建/已签状态，也含未来扩展，不能全部视为已建成。⁵

⁵视频画面时间来源：00:13:16–00:15:37。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

3.2 从 200 MW、1 GW 到 2.1 GW

园区鸟瞰图上的两座变电站分别为 200 MW 与 1 GW。讲者称 1 GW 设施是美国最大的私有变电站，并以 Denver 全城用电功率作类比 (00:14:35–00:15:19)。这是讲者的量级说明，不是外部统计排名。

前八栋建筑服务 Oracle 和 OpenAI，第一批项目被讲者称为 Project Stargate；园区另建约 350 MW 天然气电站 (00:15:48–00:16:25)。南侧扩展面向 Microsoft，整个园区被概括为 2.1 GW (00:17:12–00:17:31)。这些只表示讲者当场描述的项目对应关系，不能推导土地、电站、园区或 Stargate 的完整所有权。

MW/GW 是功率，不是年度耗电量

1 GW = 1000 MW 描述容量或功率速率。若要计算年度能量，还必须知道运行时间与利用率；讲座没有给 GWh/MWh 数据，因此“相当于 Denver”不能改写成一年耗掉 Denver 一年的电。

3.3 八栋楼怎样成为一个集群

建筑多并不等于一个大计算机。讲者强调，八栋数据中心的芯片接入同一高性能后端网络，因而可作为 coherent cluster 运行，一个训练任务能够跨越所有建筑 (00:16:25–00:16:50)。讲座没有给拓扑、带宽、时延或故障域数据，因此只能确认“跨楼协同”这一工程主张，不能写成“没有通信开销”。

园区建设还是一项劳动力工程：5,000 个车位、每日约 9,000 名建设者，对应施工高峰；Abilene 人口约 120,000，长期运维岗位则被讲者估计为约 2,000 人 (00:16:50–00:18:32)。两组数字的时间属性不同，不能相加成永久就业。

3.4 本章小结

Abilene 把 Energy-first 从概念变成可观察的工程组合：能源供给受困，变电站和气电提供城市级功率，多栋建筑通过后端网络形成一体化训练集群，数千名建设者把资本转成实体资产。规模同时要求我们严格区分功率与能量、建设期与运营期、项目口径与所有权事实。

4 电力、冷却与分级可靠性 (00:18:35–00:23:45)

4.1 从变电站到芯片：能确认设备，不能硬拼电压

主持人把问题改写成“每 100 美元花在哪里”。讲者的教学顺序是先拆电站和数据中心，再看计算集群，最后讨论回报 (00:18:35–00:19:14)。PDC (power distribution center) 从变电站接收中压电并向建筑两侧的变压器和开关设备分配 (00:19:35–00:20:28)。

字幕先记录 34.5 kV，随后又出现“从 345 kV 降到 480/415”的口述；高清幻灯片没有电压标注，无法消解冲突。最安全的成文口径是：PDC 接入 34.5 kV；后续变换层级的 34.5/345 kV 存

在字幕或口述歧义，不能画成一台变压器直接完成全部变换。

电压链保留未知，不制造整齐答案

视频能确认 PDC、transformer、switchgear 与 UPS 的设备位置，却不能确认 34.5/345 kV 的完整单线关系。未经音频或电气图复核，不写“34.5 kV 升到 345 kV”，也不写“一台设备从 345 kV 直接降至 480/415 V”。

The Cost Anatomy of an AI Factory

25 MW Data Hall 3 MW Network Core



Crusoe, Blue Owl Capital, and Primary Digital Infrastructure enter second phase of \$15 billion joint venture to fund AI data center in Abilene, Texas

BLUE OWL

Electrical Equipment (Examples)

Switchgear	~\$0.5mm/MW
Transformers	~\$0.1mm/MW
Power Distribution Center	~\$0.1mm/MW
UPS	~\$0.7mm/MW

Mechanical Equipment (Examples)

Chillers	~\$0.5mm/MW
Fan Walls	~\$0.3mm/MW
Cooling Distribution Unit	~\$0.2mm/MW

Base Building (Examples)

Steel	~\$0.4mm/MW
Site Work	~\$1.8mm/MW
Concrete/Foundation	~\$0.5mm/MW

Power Infrastructure

Gas Power Plant	\$1.8-3.0mm/MW
Generators	\$0.2mm/MW

Stanford

图 8：Abilene “Cost Anatomy”：数据大厅、网络核心、PDC、变压器、发电机、风墙、冷机与 CDU 等设备位置及示例成本；局部单项不是完整且互斥的预算。⁶

4.2 冷却闭环：系统水量不等于年度耗水

GPU 的输入功率最终大多变成热。讲者描述一条冷水循环：冷水进入 GPU 机架吸热，升温后流向风冷冷机；空气吹过铜盘管把热排出，降温后的水再回到机架（00:20:28–00:21:21）。CDU（cooling distribution unit）在数据中心内把主冷水管路分配到各 GPU 机架（00:22:21–00:22:37）。




图 9：根据 00:20:28–00:22:37 重绘的闭环冷却示意；讲座未给流量、温度或 PUE。

⁶视频画面时间来源：00:19:50–00:20:21；00:22:02–00:23:45。画面从 1920×1080 原视频抽取；时间区间接人工字幕定位。

讲者称每栋建筑的冷却系统首次约需 100 万加仑水；闭环运行后，年度新增用水约与一户住宅相当（00:21:34–00:22:02）。“接近零用水”是演讲式强调，不能覆盖初始充水和少量补水。更准确的说法是“系统存水量很大，但增量补水低”。

4.3 设备成本与分级可靠性

“Cost Anatomy”幻灯片把 switchgear、transformer、PDC、UPS、chiller、fan wall、CDU、钢材、场地工程、混凝土、气电站和发电机列为示例成本。它帮助读者把建筑位置映射到每 MW 成本，但示例项并非完整、互斥预算，不能与后面的 19.2M/MW 堆叠图再次相加。

UPS 用电池平滑供电；部分柴油备电则优先保护核心存储与网络，使灾难时仍能读取 checkpoint、迁移工作负载（00:22:04–00:23:45）。字幕中的“five nines”句子损坏；可以确认的是分级可靠性原则，不能声称园区整体达到经过测量的 99.999% SLA。

可靠性按恢复价值分级

与其给所有 GPU 负载做同等级全容量备份，不如优先保护存储和网络，让 checkpoint 可读取、任务可迁移。这里讲的是工程取舍，不是完整 SLA 指标。

4.4 本章小结

AI 工厂在 GPU 开机前就需要一条长链：PDC、变压器、开关与 UPS 完成配电，CDU、管路与风冷冷机完成排热，材料和场地工程让设备可安装。链路中仍有电压字幕冲突和可靠性术语不确定；可靠笔记应把未知保留下来，而不是为求整齐拼出错误单线图。

5 基础设施 CapEx、劳务与第二种能源组合（00:23:45–00:30:20）

5.1 19.2M 美元/MW 的建设堆叠

讲者用 “Illustrative Data Center Cost Build-Up” 把带表后气电的数据中心归一到每 MW。高清画面合计为 19.2M 美元/MW；它覆盖电站、建筑、机电、材料、软成本与施工劳务，但仍不包含 GPU 和后续 IT 设备（00:23:45–00:27:39）。

成本项	M 美元/MW	结构占比（讲义计算）
施工劳务	4.7	24.5%
软成本	1.5	7.8%
燃气电站	3.0	15.6%
Tenant fit-out	2.6	13.5%
电气设备	1.8	9.4%
机械设备	1.7	8.9%
材料	3.9	20.3%
合计	19.2	100%

表 1：讲座示意图中的基础设施 CapEx 分项。比例仅由可见数值计算，不是独立预算审计。

数值可直接做一致性检查：

$$4.7 + 1.5 + 3.0 + 2.6 + 1.8 + 1.7 + 3.9 = 19.2 \quad (\text{M USD/MW}).$$

- M USD/MW：每兆瓦百万美元，用来把不同规模项目放在同一功率口径上；
- 19.2：幻灯片七项之和；讲者随后把它粗略称作为 20M 美元/MW；
- 该加法只校验图内分项，不能证明科目完整、互斥或适用于所有项目。




图 10：示意性基础设施成本堆叠：七项合计 19.2M 美元/MW。该口径包括表后气电与施工劳务，但不包括 GPU 等 IT 设备。⁷

把同一口径换到吉瓦尺度， $19.2 \text{ M USD/MW} \times 1000 \text{ MW/GW} = 19.2 \text{ B USD/GW}$ ；讲者把它口头取整为约 20B 美元/GW (00:27:39–00:28:00)。这是同一示意表的数量级换算，不是新增预算科目。

5.2 4.7M 美元/MW 的劳务为何属于 CapEx

施工劳务是最大单项。4.7M 美元/MW 线性换算到 1 GW，就是 4.7B 美元/GW (00:23:56–00:24:41)：

$$C_{\text{labor,GW}} = 4.7 \text{ M USD/MW} \times 1000 \text{ MW/GW} = 4.7 \text{ B USD/GW}.$$

- $C_{\text{labor,GW}}$ ：1 GW 建设容量对应的施工劳务资本开支；
- 1000 MW/GW：功率单位换算，不包含规模经济或分期差异；
- 若假设 1 GW 在一年上线，这笔钱可在施工期一年内发生；它仍是资本化建设劳务，不是永久年度 OpEx。

讲者列出电工、焊工、管工和建筑工短缺，说明瓶颈已经从芯片延伸到熟练工种 (00:24:43–00:25:14)。这一问题稍后会回到 Spark 的集中制造与模块化方案。

建设期的一年，不等于每年永久重复

4.7B 美元/GW 来自容量换算；只有在“1 GW 一年上线”的假设下，才能称为施工期一年内的劳务支出。长期运维岗位、工资与持续 OpEx 是另一套口径。

当主持人追问约 20M 美元/MW 的成本是在上升还是下降时，讲者判断当时方向向上，主要受到燃气发电设备、其他基础设施设备与熟练劳务需求推动；不同类别的价格通胀幅度并不相同 (00:28:01–00:28:32)。这只是现场方向性判断，讲座没有给时间序列或可外推的涨幅。

5.3 软成本、燃机、机房配套与材料

软成本约 1.5M 美元/MW，包含保险、建设贷款、选址和 commissioning 等，但不是完整融资成本 (00:25:14–00:25:33)。燃气电站口述约 2–3M 美元/MW，图中取 3.0；讲者称燃机价格约从过去 1M 上升到 3M 美元/MW，原因是供应商和扩产能力有限、AI 项目争夺设备 (00:25:33–00:26:17)。这是现场粗略市场判断，不构成报价或投资建议。

Tenant fit-out 约 2.6M 美元/MW，包括数据大厅内部的 remote power panel、热通道封闭、fan wall 与 CDU；电气、机械和材料继续完成 GPU 进场前的“动力壳体” (00:26:29–00:27:30)。字幕把 hot aisle containment 错记成近音词，本笔记采用工程语境中的规范术语，但不把字幕损坏掩盖成逐字可靠。

⁷视频画面时间来源：00:23:45–00:27:30。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

5.4 Claude, Texas：表后发电与电网双向互补

另一处画面标题明确写作 *Claude, Texas – 1,000 MW / 6 Building Campus*；字幕中的“Quad”是错听（00:28:32–00:29:04）。现场约有 3500 名建设者，而小镇人口约 1500；这些都是讲者口径，缺少统计日期。

园区附近风电场直接供电；太阳能、电池和燃气被讲者明确说成计划（00:29:04–00:29:43）。项目又与公共电网互联：现场发电富余时售电，风光不足或设备检修时从电网取得 firm power（00:29:43–00:30:13）。讲者把这种关系称为 *across the meter*，借此强调 Energy-first 可以与大电网互补，而非孤岛运行。

Claude 是地名，不是客户披露

讲者明确拒绝透露客户。不能因为项目位于 Claude, Texas 就推断客户为 Anthropic；也不能把计划中的太阳能、电池和燃气写成已经建成。

Crusoe AI Factories

3.5+ GW of Total IT Capacity Under Construction / Contract

Claude, Texas: 1,000 MW / 6 Building Campus



Crusoe

图 11：Claude, Texas 的 1,000 MW、六栋楼园区页。画面可见风机，但没有太阳能、电池或燃气设施文字标签；后者只能按讲者口述讨论。⁸

5.5 本章小结

基础设施层的近 20M 美元/MW 由劳务、软成本、燃机、机房配套、机电与材料共同构成，GPU 尚在账外。最大单项劳务又是新瓶颈，解释了为何后文要讨论模块化。Claude 案例进一步表明，Energy-first 并非脱离电网，而是把现场能源与电网的多样性组合起来；状态、客户与因果边界必须分别写清。

⁸视频画面时间来源：00:28:32–00:29:04。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

6 IT CapEx、互联集群与算力的经济寿命 (00:30:20–00:37:26)

6.1 标题约 40M，分项却加到 41M

物理设施就绪后，讲者才把 IT 设备放入建筑。幻灯片标题和口述都概括为约 40M 美元/MW，脚注称其为 illustrative GB300 capex BOM；可见分项如下 (00:30:27–00:32:54)：

分项	M 美元/MW	作用或限制
GPU	30	训练与推理的主加速器
网络	4	机架内外组成高性能集群
CPU 与存储	3	工作负载编排、控制与数据
机房内 CapEx	3	讲者怀疑可能与前页双计
部署劳务与运输	1	设备运输、安装与部署

表 2: IT CapEx 的讲座示意口径。

$$C_{IT,parts} = 30 + 4 + 3 + 3 + 1 = 41 \text{ M USD/MW}.$$

- $C_{IT,parts}$ ：把可见 IT 分项直接相加的结果；
- 41 与标题“约 40”并存，说明数字以近似和示意为主；
- 讲者还说机房内 CapEx 可能 double count，不能擅自删除某一项来制造精确平衡。

CPU 与存储并未因 GPU 时代消失。讲者认为 agentic workflows 需要大量 CPU 编排，从而形成他观察到的新增 CPU 需求 (00:32:07–00:32:35)；讲座没有提供订单或利用率数据。

保留 40/41，而不是替讲者修表

标题与口述约 40M，分项相加为 41M，且某项可能双计。可靠写法是“约 40M”，同时公开算术与边界；把 41 写成精确总额或删除项凑成 40 都会制造假确定性。




图 12: IT CapEx 示意: 标题为 40M 美元/MW, 五项可见数字却合计 41M; 脚注称其为 illustrative GB300 capex BOM。⁹

6.2 两级网络：机架内 NVLink，跨架 InfiniBand/RoCE

讲者指着最新一代整机架设计，称 72 个 GPU 位于同一 NVLink domain，铜背板支持机内高速共享（00:31:11–00:31:52）。多个机架之间还需另一层后端网络，可使用 InfiniBand 或 RoCE（RDMA over Converged Ethernet）（00:31:52–00:32:07）。字幕把 RoCE 记成“rocky”；术语可规范，字幕疑误仍应被记录。

讲者自己说画面可能是 GB300 或 GB200，“不确定”。成本表脚注只说明 BOM 以 GB300 为示意，不能借此替产品照片定型。

网络成本购买的是“协同”，不只是连通

NVLink 组织机架内 GPU，InfiniBand/RoCE 连接多个机架。两层网络共同把许多芯片转化为能够运行大任务的集群；讲座没有给带宽、延迟或效率，不能从一张产品照推导性能。

6.3 商品化、规模与前沿可以同时成立

讲者拒绝把“算力会商品化吗”压成一个答案（00:32:54–00:33:52）：老代际可能降价；超大规模交付仍难复制；最新代际总会有溢价。三者对应不同时间、产品和规模，可以同时成立。

他又用高度不确定的口径猜测成熟硅片毛利也许约 60%，NVIDIA 当时约 80%（00:33:56–00:34:20）。这只是带有“I think / probably / I don’t know”的现场判断，不应进入单位经济模型或投资结论。

⁹视频画面时间来源：00:30:20–00:32:54。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

“商品化”不是单变量命题

旧代际的价格压力、超大集群的交付稀缺和最新代际的技术溢价可以同时存在。讨论算力经济性必须先说明代际、规模与时间尺度。

6.4 价格反弹不能证明更长折旧期

Bloomberg H100 spot pricing 图被用来反驳一个强直觉：新代际发布不等于旧设备立刻归零。讲者称 H100 价格下降后因 agent 需求回升, Crusoe Cloud 也观察到类似变化 (00:34:55–00:35:50)。SemiAnalysis 的 B200/Blackwell 图随后展示相似走势 (00:37:07–00:37:26)。

两页标题都写 “since Dec '26”，但横轴只到 2026 年 3 月，存在明显日期冲突。本笔记保留 “价格先降后升” 的可见趋势，并把标题日期标为幻灯片疑误，不擅自替换成 Dec '25。




图 13: H100 租赁价格曲线：可见走势为先降后升；标题 “since Dec '26” 与横轴 2025–2026 的范围冲突，疑为幻灯片日期错误。¹⁰

¹⁰视频画面时间来源：00:34:59–00:35:50。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。




图 14: B200 租赁价格曲线同样先降后回升，并带误差棒；标题日期与横轴冲突，只报告疑误，不自行改字。¹¹

当主持人问折旧是否应超过五或六年，讲者直接回答： *I don't know. It's like my honest answer.* (00:35:50–00:36:06)。他能确认的策略是，只要设备仍对自己或别人有价值，就尽量继续使用。服务抽象也能隐藏 A100、H100、MI300 等硬件差异，让客户购买结果而不是特定芯片 (00:36:12–00:37:07)。

租赁价格证据与会计折旧是两回事

价格反弹只说明特定时期需求未按“新代发布即归零”的路径发展。它不能确定六年以上使用寿命、残值、未来价格或会计折旧；讲者对更长年限的答案就是“不知道”。

6.5 本章小结

IT CapEx 以 GPU 为主，但网络和 CPU/存储把设备组织为可调度服务。40/41M 的算术差、GB200/GB300 型号不确定和 H100/B200 日期冲突都说明这是教学示意而非采购审计。更重要的是，讲者对商品化与折旧都保留条件：代际、规模和前沿应分开看，价格反弹也不能替代寿命模型。

¹¹ 视频画面时间来源：00:37:07–00:37:26。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

7 从基础设施出租到 Token 服务 (00:37:26–00:40:49)

7.1 58、59、60M 是同一组粗算的三个版本

讲者把数据中心、电站和 IT 设备重新合并。总账页标题写 58M 美元/MW，柱状分项 19+30+10 合计 59M，口述则四舍五入为约 60M (00:37:26–00:37:45)。它们不是三个独立估计，而是同一组现场粗算的内部不一致。

持续 OpEx 在画面约为 1.1M 美元/MW/年，口述放宽为约 1–2M，包含电力、保险、部分现场劳务与设备维修 (00:37:45–00:38:09)。讲者随后承认工程团队等额外劳务未计，因此实际 OpEx 更高；融资、税费、利用率、停机和服務层新增成本也没有进入图表 (00:39:09–00:39:20)。

模型制作状态 (00:37:38–00:39:22)

Chase: 这张表里可能有 double count；幻灯片是今天下午才整理的。工程团队等费用也还没有全部纳入。

总账必须与自我限定同屏出现

正文可用“约 60M 美元/MW”概括，但必须同时说明标题 58、柱 59、口述 60，讲者承认可能双计、OpEx 有漏项、且这是第一次讲这组当日下午制作的幻灯片。




图 15：基础设施与 IT 总账：标题写 58M 美元/MW，柱图 19+30+10=59M；年度 OpEx 标题约 1M、图中约 1.1M。¹²

¹² 视频画面时间来源：00:37:26–00:38:09。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

7.2 四年只是一项 revenue-basis payback

纯基础设施出租被讲者估为年收入约 15M 美元/MW (00:38:09–00:38:33)。把约 60M 前期投入除以 15M 年收入，得到约四年：

$$T_{\text{rev,IaaS}} = \frac{C_{\text{total}}}{R_{\text{IaaS}}} \approx \frac{60 \text{ M USD/MW}}{15 \text{ M USD/MW/year}} \approx 4 \text{ years.}$$

- $T_{\text{rev,IaaS}}$ ：按收入计算的静态回收年数；
- C_{total} ：约 60M 美元/MW 的前期 CapEx；
- R_{IaaS} ：约 15M 美元/MW/年的基础设施年化收入；
- 分母没有扣除完整 OpEx，因此结果不是利润回收、现金流、IRR 或 NPV。

幻灯片把收入脚注归于 SemiAnalysis 对 2026 年 4 月五年期 GB300 合同价格的估计；它不是已披露客户合同。讲者在 00:39:00–00:39:07 明确补上 “on a revenue basis”，这个限定不可省略。




图 16: IaaS 情景：59M 美元/MW 前期投入、约 15M 美元/MW/年收入与约 1.1M 美元/MW/年 OpEx。收入来自外部估计，不是已披露合同现金流。¹³

7.3 越靠近 Token，收入上限越高，成本也越未知

讲者把服务分成两个抽象层：managed compute cluster 仍让客户管理节点、VM 或 Kubernetes；model hosting/API endpoint 则让客户只面对模型请求和响应 (00:39:24–00:40:28)。抽象层越高，供应商承担的运行责任越多，也可能捕获更多收入。

¹³ 视频画面时间来源：00:38:09–00:38:33。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

口述称服务层每 MW 每年可增加约 5–15M 美元；画面则把 managed AI 总收入写为 15–30M。两种范围共同确认的是非常乐观的上限约 30M（00:40:28–00:40:48）：

$$R_{\text{managed,optimistic}} \approx 30 \text{ M USD/MW/year}, \quad T_{\text{rev,managed}} \approx \frac{60}{30} = 2 \text{ years}.$$

- $R_{\text{managed,optimistic}}$ ：非常乐观情景的总年收入上限；
- $T_{\text{rev,managed}}$ ：仍然只按收入计算，不是利润或现金流回收期；
- 新增模型授权、软件、工程和推理运营成本没有被量化。

从电子到 Token 的价值提升

越靠近 token，客户购买的越不是裸芯片时间，而是可直接调用的模型服务。讲者认为这可能把每 MW 年收入推高到极乐观的 30M 上限；价值提升同时带来本讲未量化的服务成本与执行风险。




图 17：Managed AI Services 情景：画面给出 15–30M 美元/MW/年总收入；口述 5–15M 是服务层 uplift，两者不是同一口径。¹⁴

7.4 本章小结

总账页闭合了本讲的经济链，却也最需要克制：CapEx 有 58/59/60 三个版本，OpEx 有漏项，IaaS 收入口径来自外部估计，四年与两年都只是收入基准静态回收。服务层把价值从裸基础设施推向 token，但本讲没有证明新增收入必然转化为利润。

¹⁴ 视频画面时间来源：00:39:24–00:40:48。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

8 模块化降本与未来电力栈 (00:40:49–00:45:31)

8.1 Spark：把部分现场施工变成集中制造

当劳动力成为成本和进度约束，Crusoe Spark 尝试把部分项目制施工转移到集中、标准化制造环境。讲者把它描述为模块化、自包含的 AI 数据中心单元，可运输到现场并成组部署 (00:41:00–00:41:31)。

讲者估称可节省 30%–50%，并以约 19M 美元/MW 的前章基础设施成本作口头参照 (00:41:31–00:41:40)。但 “depending on overall cost” 没有定义分母；不能把比例直接套到全栈 60M/MW，也不能据此推算审计后的 Spark 单价。

风冷单元为 500 kW，液冷单元为 2 MW；多个单元通过 fleet deployment 扩展 (00:41:40–00:42:12)。播放部署视频失败的黑屏不提供证据，真正有价值的是可辨认的静态模块照片。

模块化回应的是劳务和重复建设

Spark 的机制是集中制造、自包含单元和成组部署。单元容量不是园区总容量，30%–50% 也只是讲者的条件化估算，节省基准未定义。




图 18: Crusoe Spark 模块示意：画面列出 scalable、proven、fast、powerful，并写明集成电力、冷却、监控、消防与机架；500 kW/2 MW 容量只来自口述。¹⁵

¹⁵ 视频画面时间来源：00:41:00–00:41:40；00:41:40–00:42:12。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。





图 19: Crusoe Blackwell Deployment – Iceland: 机架走廊、设备背板和园区航拍。照片只展示部署形态，不能据此读取 GPU 数量或网络拓扑。¹⁶

8.2 短期关键路径与长期架构重塑

主持人把问题问成“做多/做空哪一层”，讲者则把答案放回时间尺度（00:42:13–00:43:09）。短期，高压电经过多级变换和分配，Eaton、Schneider 等传统设备仍处于关键路径；长期，固态电力电子、固态变压器与新配电架构可能压低成本。如果既有企业不创新，长期价值分配可能改变（00:43:46–00:44:43）。

讲者又把 345/765 kV 的高压侧与机架 900 V DC 的未来端点相连，称中间路径是巨大的电气工程机会（00:44:43–00:45:07）。他没有给具体拓扑，不能画成一台设备直接从 765 kV 变到 900 V DC。



短期：传统设备仍在关键路径

长期且有条件：固态变压器与电力电子可能减少级数和成本

图 20: 根据 00:43:09–00:45:07 整理的端点与时间尺度示意；中间拓扑并非讲者已给出的方案。

8.3 Open source：保留讲者的自我修正

讲者先说“open source is winning”，随即主动收窄：不是已经获胜，而是他认为 open source 会表现良好，并从 closed-source model players 获得更多份额（00:45:17–00:45:29）。本讲没有定义

¹⁶视频画面时间来源：00:41:00–00:41:16。画面从 1920×1080 原视频抽取；时间区间按人工字幕定位。

开放权重与严格开源许可证，也没有给时间或份额；可靠正文只能采用修正后的弱断言。

这不是股票建议，也不是确定胜负

传统电力设备公司、NVIDIA 与 open/closed 模型的表述都来自课堂问答。必须保留 near term、long term、if they do not innovate 与讲者自我修正，不能压缩成买卖结论。

8.4 本章小结

Spark 从供给侧尝试减少重复现场施工；未来电力栈则说明规模会反过来催生部件和架构创新。两者共同延续“瓶颈会移动”的主线。短期需求与长期重构可以同时成立，开放模型判断也只能保留条件化版本。

9 太空数据中心与持续学习 (00:45:31–00:49:47)

9.1 太空是地面成本栈的反事实实验

讲者称 Crusoe 与 Starcloud 合作，并按现场口径说后者把首批 H100 发射到太空 (00:45:46–00:46:00)。这只能写成讲者的公司表述；人物镜头本身不能证明发射事实。

太空场景逐项反转地面成本：混凝土基础、部分电力许可和大量现场光纤插接可能减少 (00:46:02–00:46:34)。但省下一组约束，会换来另一组更难的约束：热管理、持续运维、GPU reseat/RMA、不可维修故障造成的容量衰减，以及 payload cost (00:46:36–00:47:23)。字幕中的 RMA/Jensen 与 “natural depreciation” 均不可靠，本笔记只保留确定语义：送回供应商维修在太空很难，物理故障会让可用容量逐步下降。

可能减少的地面项	新增或加重的太空约束
混凝土基础与部分现场工程	真空环境中的热管理与散热器需求
部分地面许可、审批与土地约束	发射与有效载荷成本
大量现场光纤插接与人员施工	故障部件难以 reseat、维修或更换
地面园区的一部分布线复杂度	不可维修失效造成的容量衰减与冗余需求

表 3：根据 00:46:02–00:47:23 整理的约束交换；不是完整太空数据中心成本模型。

讲者把经济性部分系于发射成本能否下降两个数量级；当被追问时，他明确回答不知道 (00:47:11–00:47:23)。随后给出的时间判断必须完整保留：未来五年可能不具实质影响，十年也可能仍不重要，但更长期可能发挥重要作用 (00:47:23–00:47:39)。

5 年、10 年与长期是三层判断

“长期可能重要”不能覆盖“5 年可能不 material、10 年也可能不 material”。这不是近期落地承诺，而是对时间尺度高度谨慎的可能性判断。

9.2 没有人是成品：把注意力从 what 转向 how

最后一个问题回到学生该学什么。讲者先说具体内容没有那么重要，马上又补充这些内容仍然重要；真正更重要的是学习过程（00:48:02–00:48:22）。因此，这不是“知识无用论”。

Crusoe 的 *infinite growth loop* 把每个人看作持续变化的 work in progress：学习、实践、获得反馈、改进，再进入下一轮。讲者把每天的小进步描述为长期指数复利，并同时强调 hard work、grit、grinding 与主动使用 AI 工具（00:48:22–00:49:06）。




图 21：根据 00:48:22–00:49:36 重绘的 infinite growth loop；循环结构为讲义压缩，不是量化增长模型。

讲者承认自己不知道 AI 大规模采用后五年的工作会怎样变化。正因为静态岗位与工具不可预测，他建议少押注单一的“what”，更多训练“how”——如何学习、如何工作、如何借助 AI 工具组织工作与生活（00:49:04–00:49:36）。“每人仿佛可调用百万劳动力”是强调 Agent 杠杆的修辞性设想，不是就业预测。

具体知识仍重要，学习过程更重要

面对不确定未来，稳健策略不是选中一项永远不变的技能，而是形成持续学习、韧性、艰苦工作和使用新工具的能力。讲者的 closing 把 AI 工厂的规模问题最终带回人的适应能力。

9.3 本章小结

太空数据中心说明成本不会消失，只会重新组合：少了地基、部分许可和现场布线，却多了热、维修、失效与发射成本。讲者因此给出分层而非乐观承诺的时间判断。最后，他把应对未知未来的答案放在持续学习过程上，使开头的“数字劳动力”与结尾的“人如何适应更大杠杆”形成首尾呼应。

10 术语、量纲与阅读陷阱速查

10.1 核心术语

英文	建议中文	本讲语境
from electrons to tokens	从电子到 Token	从能源输入，经建筑、集群与模型服务，到可售 token 的完整价值链
energized data center / powered shell	已通电数据中心 / 动力壳体	芯片可以装入、通电并启动大型集群的设施
energy-first	能源优先	先寻找丰富、低成本、受输电约束的能源，再与计算负载共置
coherent cluster	一体化集群	多栋建筑中的芯片经统一后端网络运行同一训练任务
behind / across the meter	表后 / 跨表协同	现场发电与公共电网双向买卖和保供的组织方式
tenant fit-out	租户机房配套	数据大厅内部为 GPU 供配电、冷却与部署所需设施
NVLink domain	NVLink 互联域	同一整机架内 GPU 的高带宽互联范围
RoCE	基于融合以太网的 RDMA	跨机架后端网络方案，字幕误作 rocky
revenue-basis payback	收入基准静态回收期	CapEx 除以年收入，不扣完整费用，不代表利润/现金流
modular data center	模块化数据中心	集中制造、自包含、可成组部署的 Spark 单元

表 4：本讲核心术语的统一译法。

10.2 量纲与不可越界的换算

量纲	含义	主要陷阱
kW/MW/GW	功率； $1\text{ GW} = 1000\text{ MW}$	不能直接写成年度耗电量
MWh/GWh	能量； $E = P \times t$	讲座没有运行小时和利用率，不能自行计算
M USD/MW	每 MW 的百万美元 CapEx	不同页存在重叠与双计，不能机械相加
M USD/MW/year	每 MW 每年的 OpEx 或收入	必须写出“每年”，不能与一次性 CapEx 混用
V/kV/DC	电压与直流口径	34.5/345 kV 有字幕冲突；765 kV 到 900 V DC 不是一步变换
gallon	系统水体积	初始 100 万加仑不等于每年耗水

表 5：贯穿全文的量纲边界。

讲座没有给出的关键变量

PUE、FLOPS/W、完整利用率、电价、融资成本、税费、残值、硬件失效率、碳强度和模型服务实际毛利均未被完整量化。它们是后续研究问题，不能从现有每 MW 表格反推。

10.3 本章小结

统一术语能把能源、建筑、计算和服务放在同一张地图上；统一量纲则防止把功率、能量、一次性资本开支和年度收支混为一谈。多数事实偏差并非来自复杂公式，而是来自边界、单位和时间尺度被悄悄删掉。

11 总结与延伸

11.1 讲者的实质 closing

讲者没有把结论停在 60M 美元/MW 或两年、四年回收。模块化说明供给方法仍可改变；传统电力设备短期关键、长期可能被固态电力电子重塑；open source 只能保留“可能获得更多份额”的弱判断；太空数据中心则被明确放在“5 年可能不 material、10 年也可能不 material、长期可能重要”的时间框架中（00:41:00–00:47:39）。

最后，他承认无法预测五年后的工作形态，把建议转向 infinite growth loop、hard work、grit 与 AI 工具使用。具体知识仍重要，学习过程更重要；少把全部筹码押在静态的 what，多练习可迁移的 how（00:48:02–00:49:36）。

11.2 把九章压缩成一条因果链




图 22：全讲机制压缩：从电子到 Token，再由需求与收入反馈到下一轮基础设施投资。

最核心的竞争能力是协调移动瓶颈

AI 工厂的优势不等于拥有某一台 GPU 或发电机，而在于当约束从能源移到设备、劳务、网络、芯片、服务与资本回收时，仍能跨层协调。垂直整合应对瓶颈迁移，模块化把重复建设产品化，服务抽象则延长异构资产的经济价值。

11.3 三个跨章连接

1. **数字劳动力与物理资本是一体两面。**开头的 Agent 杠杆只有经过电力、冷却、GPU 和网络才能兑现；因此所谓“软件价值”并没有脱离物理约束。
2. **规模既制造稀缺，也制造创新动机。**1–2 GW 园区让劳务、燃机和开关设备成为瓶颈，同时也推动集中预制、模块化、固态电力电子和新的服务抽象。
3. **回收模型与学习建议共享同一逻辑。**当技术寿命、服务需求和未来工作都不可精确预测时，稳健策略不是假装确定，而是保留选择权：基础设施通过抽象调度异构芯片，人则通过持续学习适应新工具。

11.4 实践含义与开放问题

对工程团队，最先要做的是建立跨层接口和量纲一致的成本账：功率、能量、一次性 CapEx、年度 OpEx 与服务收入必须分开。对经营者，任何回收期都应加入利用率、融资、税费、故障、残值与服务成本后再进入决策。对学习者的，应把具体工具放进“理解机制–实践–反馈–迭代”的循环，而不是追逐孤立名词。

本讲留下的开放问题包括：完整利用率与 PUE；可再生与电网组合的容量价值；模块化节省的真实分母；GPU 代际残值与故障率；900 V DC 的实际拓扑与部署节奏；模型托管新增收入对应的新增 OpEx；在轨热设计、冗余、维修和发射成本；开放模型份额应如何定义和测量。

11.5 可带走的五句话

1. Token 的供给链始于电子，AI 产品的上限受物理系统约束。
2. 在必要条件串联系统中，瓶颈会移动；优化单点只会暴露下一约束。
3. 讲者的每 MW 数字是教学粗算，边界与不确定性比小数点更重要。
4. 越靠近模型服务，潜在收入越高，但未量化的运营责任也越多。
5. 面对技术和工作的不可预测性，持续学习与保留选择权比押中一个静态答案更稳健。