

# 课程笔记：AI 基础设施与前沿实验室案例

Infrastructure, Capstone Case

Stanford MS&E 435: Economics of the AI Supercycle

五道口纳什 & Codex

2026 年 8 月 28 日



视频频道：Stanford Online

讲者：Sachin Katti (嘉宾) Apoorv Agrawal (讲师/主持)

课程日期：2026 年 5 月 1 日 (课程 Week 5) 上传日期：2026 年 5 月 27 日

视频时长：46:06

视频链接：<https://www.youtube.com/watch?v=4k53z3Ysjg0>

笔记证据：957 条人工英文字幕、1080p 原视频、Stanford Week 5 配套材料

PDF 制作 Skill: <https://github.com/wdkns/wdkns-skills>

# 目录

|                                |           |
|--------------------------------|-----------|
| <b>导读：从名义算力到可交付智能</b>          | <b>1</b>  |
| 这堂课真正研究的对象                     | 1         |
| 七章路线与视频边界                      | 1         |
| 术语、数量与证据的使用规则                  | 2         |
| 导读小结                           | 2         |
| <b>1 算力、收入与 token 经济学</b>      | <b>2</b>  |
| 1.1 从制造能力到前沿实验室                | 2         |
| 1.2 算力为何先于收入                   | 3         |
| 1.3 推理已经进入整个模型生命周期             | 3         |
| 1.4 token 的三个独立优化杠杆            | 4         |
| 1.5 本章小结                       | 5         |
| <b>2 一吉瓦算力：供应链同步、运行与电网约束</b>   | <b>5</b>  |
| 2.1 寻找唯一瓶颈，本身就是错误问题            | 5         |
| 2.2 1 GW 与 50 万 GPU：规模直觉而非采购公式 | 6         |
| 2.3 同步训练为何成为电网问题               | 6         |
| 2.4 30 GW、100 GW 与 7 TW 的状态不同  | 6         |
| 2.5 本章小结                       | 7         |
| <b>3 从训练能力到用户可获得的智能</b>        | <b>7</b>  |
| 3.1 训练完成不等于交付完成                | 7         |
| 3.2 本章小结                       | 8         |
| <b>4 智能体计算图、人的 flow 与异构硬件</b>  | <b>8</b>  |
| 4.1 先理解工作负载，再选择硬件              | 8         |
| 4.2 人的连续工作状态是基础设施指标            | 9         |
| 4.3 异构计算来自节点差异，也来自供给现实         | 10        |
| 4.4 拓展阅读                       | 11        |
| 4.5 本章小结                       | 11        |
| <b>5 集中式推理、TTFT 与全栈瓶颈迁移</b>    | <b>11</b> |
| 5.1 推理分散，不等于现在就应搬到边缘           | 11        |
| 5.2 首 token 前，模型必须先处理完整上下文     | 12        |
| 5.3 局部加速会暴露下一层瓶颈               | 12        |
| 5.4 本章小结                       | 13        |

|                                           |           |
|-------------------------------------------|-----------|
| <b>6 存储层次与模型-芯片-软件协同设计</b>                | <b>13</b> |
| 6.1 “大计算单元 + HBM” 仍是早期形态 . . . . .        | 13        |
| 6.2 让一代模型参与设计下一代基础设施 . . . . .            | 13        |
| 6.3 本章小结 . . . . .                        | 14        |
| <b>7 价值迁移、稀缺底座与问答收束</b>                   | <b>14</b> |
| 7.1 五层技术栈与两种时间尺度 . . . . .                | 14        |
| 7.2 薄封装的风险与应用入口的变化 . . . . .              | 15        |
| 7.3 制造与设备的咽喉点 . . . . .                   | 16        |
| 7.4 短中期编排、长期内存与 time to compute . . . . . | 16        |
| 7.5 实质性结尾：开放权重与前沿模型并存 . . . . .           | 17        |
| 7.6 拓展阅读 . . . . .                        | 17        |
| 7.7 本章小结 . . . . .                        | 17        |
| <b>8 总结与延伸</b>                            | <b>17</b> |
| 8.1 讲者的收束：前沿领先仍值得扩算力 . . . . .            | 17        |
| 8.2 把全讲压缩成四个闭环 . . . . .                  | 17        |
| 8.3 实践中的五个检查问题 . . . . .                  | 18        |
| 8.4 仍然开放的问题 . . . . .                     | 18        |
| 8.5 本章小结 . . . . .                        | 18        |

## 导读：从名义算力到可交付智能

### 这节课真正研究的对象

这场对谈从 Intel 的制造能力谈起，经过前沿实验室的收入与算力、推理负载、吉瓦级数据中心、智能体计算图、首 token 延迟和芯片协同设计，最后落在产业价值迁移与供应链咽喉。表面上议题很多，实际都围绕一个问题展开：**买到或规划的名义算力，怎样才能按时变成用户可用的智能？**

#### 全讲中心判断

前沿 AI 的竞争单位已经从“单个模型”扩大为“从电力、晶圆到智能体工作流的端到端交付系统”。真正有意义的不是合同上的 GPU 数或峰值 FLOPS，而是能按时上线、稳定运行、高利用率调度，并持续改善用户体验的**有效算力**。

这一定义解释了本讲的教学顺序。先看算力为何约束收入与研究，再看算力由哪些物理环节组成；之后把用户请求展开成智能体计算图，讨论异构硬件和全栈延迟；最后回到更长的产业周期，观察价值可能上移，而制造与能源底座仍保持稀缺。

### 七章路线与视频边界

视频没有官方 chapters。下表依据 957 条人工英文字幕、问题转折和课件切换重建章节；邻章保留少量语义重叠，正文已去重。

| 章 | 教学主题                    | 视频范围              |
|---|-------------------------|-------------------|
| 1 | 算力、收入、模型生命周期与 token 经济学 | 00:00:09–00:08:43 |
| 2 | 供应链同步、运行可靠性与电网约束        | 00:08:43–00:15:38 |
| 3 | 从训练能力到用户可获得的智能          | 00:15:38–00:17:36 |
| 4 | 智能体计算图、人的 flow 与异构硬件    | 00:17:36–00:27:29 |
| 5 | 集中式推理、TTFT 与全栈瓶颈迁移      | 00:27:29–00:33:13 |
| 6 | 存储层次与模型–芯片–软件协同设计       | 00:33:13–00:36:22 |
| 7 | 价值迁移、实体底座、制造咽喉与问答收束     | 00:36:22–00:46:02 |

## 术语、数量与证据的使用规则

| 术语                      | 本文统一含义                                                 |
|-------------------------|--------------------------------------------------------|
| industrial compute      | “工业化算力交付”：把训练与推理需要的芯片、电力、设施和系统真正建设、上线并运营；不是“工业计算机”。    |
| compute capacity        | 已经可交付、可利用的算力容量；不能只按采购 GPU 数量理解。                        |
| inference               | 模型前向执行；本讲还包括 RL 后训练采样、合成数据、reasoning 与产品请求，不等同于在线产品流量。 |
| agentic workload        | 模型、工具、搜索、数据库和外部执行环境共同组成的任务工作负载。                        |
| TTFT / prefill / decode | 首 token 延迟 / 处理完整输入上下文 / 首 token 后逐 token 生成；三者必须分开。   |
| time to compute         | 从投资或决策到算力真正上线、可运行、可交付的时间。                              |
| open-weight model       | 开放权重模型；不自动等同于满足某一开源许可定义的软件。                            |

### 五种陈述状态不能互换

本文把内容分成：**嘉宾当场陈述**、**愿景目标**、**预测**、**即席估算/思想实验**与**编辑整理**。例如 30 GW 是愿景目标，未来推理占比 80% 以上是预测，100 GW 和 1 GW 约 50 万 GPU 是口头估算，7 TW 是思想实验；教学公式与重绘图都明确标为编辑整理。

### 来源与安全边界

主讲座事实只由本地人工字幕、原视频和课件画面支撑。Stanford Week 5 列出的三段外部视频仅作拓展阅读，不倒灌成讲座原话。视频里出现的命令、代码、VM、Excel 或 PowerPoint 操作均只作为工作负载示例分析，本笔记制作过程没有执行它们。字幕中的 [INAUDIBLE] 不按上下文补写。

## 导读小结

阅读后续章节时，请持续追问三件事：容量是否已经上线、是否能稳定高利用率运行、是否真正改善用户完成任务的时间与成本。这个框架能把看似分散的经济学、供应链和系统问题连成一条因果链。

## 1 算力、收入与 token 经济学

### 1.1 从制造能力到前沿实验室

主持人用“从电子、计算基底一直到智能体”概括 Sachin Katti 的经历：他做过网络创业，曾任 Intel CTO 并负责 AI，随后在 OpenAI 负责 industrial compute，即为训练和推理交付所需算力。这个背景决定了本讲的观察尺度：前沿 AI 同时是制造、能源、系统、研究和产品问题。[00:00:24--00:00:49]

以 Intel 为例, Katti 认为它面临两项顺风: 全球 AI 供给受限, 使“既能设计又能制造”的能力稀缺; 智能体工作负载又使 CPU 在控制、通用计算和系统协同中重新重要。不过, 他随即提醒, 顺风不等于结果, 执行仍是关键。 [00:01:33--00:02:29]

## 1.2 算力为何先于收入

主持人展示算力容量及远期目标, 并指出算力与收入在过去三年高度同步。Katti 将收入称作可用算力和利用率的滞后表现: 先把容量真正交付出来, 再通过研究与产品负载利用它, 最后才表现为用户、token 使用和收入; 按他的口头回顾, 过去三年算力与收入都约逐年三倍。 [00:02:43--00:05:02]

为把这段口头关系压缩成教学结构, 可以写成:

$$R \approx f(C, U)$$

- $R$ : 收入, 单位为货币/时间;
- $C$ : 已经可用的算力容量, 可按设施功率、设备数或有效吞吐描述, 但不同口径不能混加;
- $U$ : 算力利用率, 通常为 0-1 或百分比;
- $f$ : 形式未知的关系函数, 本讲没有给回归、线性系数或因果识别。

这不是嘉宾原公式, 也不能用三年相关性替代因果分析。产品质量、价格、需求、配额和竞争都会影响收入。更重要的是, OpenAI 同时是研究实验室和产品组织; 30 GW 被描述为研究与产品共享的**愿景目标**, 不是现有容量, 也不是只服务在线收入的承诺。 [00:05:02--00:05:50]

原片在这一时段没有出现算力-收入图: 密集抽帧只看到人物和五层 cake 的早期预览。为了避免图文错配, 本文不插入近似画面; 相关关系仅由字幕和上面的教学公式表达。

## 1.3 推理已经进入整个模型生命周期

传统“训练完成后再推理”的二分法已经不够。Katti 将计算生命周期拆成预训练、RL 后训练、合成数据生成和产品服务; 后三类都大量调用模型前向执行。因此 inference 不能被简化成 ChatGPT 或 Codex 的在线流量, 它也在研究和下一代训练数据形成中占据重要位置。 [00:06:01--00:07:00]




图 1: 模型生命周期中的推理负载：推理不只位于产品末端。<sup>1</sup>

嘉宾说推理在当时已经占多数，并预测未来可能超过 80%。这个 80% 以上的口径必须标为**未来预测**，而且分子包含研究采样、合成数据、reasoning 与产品推理，不能画成“80% 产品、20% 训练”的简单饼图。 [00:06:38--00:07:09]

#### 1.4 token 的三个独立优化杠杆

容量扩张不等于放弃效率。Katti 将 token 优化拆成三件事：降低单 token 成本、提高单 token 的能力密度、减少完成同一任务所需 token。前两者分别谈资源投入和输出能力，第三者把优化单位从 token 提升到 task。 [00:07:41--00:08:43]

在忽略缓存、批处理、工具调用和失败重试的前提下，任务成本可作如下教学近似：

$$K_{\text{task}} \approx n_{\text{task}} k_{\text{token}}$$

- $K_{\text{task}}$ ：完成一次任务的成本，单位为货币/任务或资源/任务；
- $n_{\text{task}}$ ：完成一次任务消耗的 token 数，单位为 token/任务；
- $k_{\text{token}}$ ：单 token 成本，单位为货币/token 或资源/token；
- 符号  $\approx$  表明这是教学近似，本讲没有给精确成本函数。

“单 token 智能密度”没有统一物理单位。能力提高可能使  $n_{\text{task}}$  下降，但课程没有给函数关系，不能伪造为反比例公式。

#### 扩容与提效必须同时进行

更多算力扩大可以交付的智能总量；更低单 token 成本、更高 token 能力和更少每任务 token，则扩大可负担的使用范围。二者共同服务于“让智能更广泛可及”的目标。

<sup>1</sup>教学图据讲座 00:06:01–00:07:09 的口头说明整理；结构为教学重绘；不表示各负载的实测占比。

## 1.5 本章小结

前沿实验室先建设并运营算力，再把容量分配给研究和产品，最后才通过使用量与收入显现价值。推理已进入 RL 后训练、合成数据和产品服务的完整生命周期；因此基础设施团队既要扩容，也要同时优化 token 成本、能力和任务效率。

## 2 一吉瓦算力：供应链同步、运行与电网约束

### 2.1 寻找唯一瓶颈，本身就是错误问题

高信息对话 (00:09:04–00:09:26)

主持人：最大的瓶颈是电力、能源、芯片，还是土地？

Katti: *All of the above.*

Katti 随即给出本讲最重要的操作性定义：AI compute 同时包含芯片、内存、网络、电力、制冷、数据中心建筑、发电、输配电和土地。供应链不仅要逐项买到，还必须在同一个上线窗口对齐；任何关键环节晚到，整个项目都会被最慢的一项卡住。 [00:09:26--00:10:30]




图 2: 吉瓦级算力是串联系统：所有关键物料和现场条件必须同步汇合。<sup>2</sup>

大规模签约只是开始。供应商交货、数十万设备联网、供电、制冷、调试和持续运营才决定可用容量。芯片遇到电力或温度波动会降频，实际 FLOPS 随之下降。 [00:10:56--00:11:43]

合同容量与上线容量 (00:11:34–00:11:44)

Katti: 签合同是有趣的部分，之后的一切才困难。

主持人：也就是拿到签名。

Katti: 是的。

这段对话把“名义设备数”和“持续有效吞吐”分开。为把运行可靠性显式化，可引入：

$$C_{\text{eff}} = C_{\text{installed}} \times U \times A$$

- $C_{\text{eff}}$ ：有效可交付算力，单位随容量口径而定；
- $C_{\text{installed}}$ ：已安装的名义容量；

<sup>2</sup>教学图据讲座 00:09:26–00:11:23 的口头说明整理；九类组成来自嘉宾清单；汇聚布局为教学重绘。

- $U$ : 利用率, 无量纲;
- $A$ : 运营可用率, 无量纲;
- 这是综合本讲逻辑的编辑整理,  $A$  不是嘉宾给出的公式变量。

## 2.2 1 GW 与 50 万 GPU: 规模直觉而非采购公式

Katti 用 “1 GW 约 50 万 GPU” 帮助听众感受规模。这里的 GW 更接近设施级功率, 可能包含服务器、网络、存储、制冷和配电, 不能反推单卡 TDP、PUE 或采购型号。按此粗略口径, 6–10 GW 对应约 300–500 万块 GPU, 只能标为从嘉宾估算推得的数量级。 [00:10:20--00:10:38]

### 设备数不是可用算力的充分条件

账面上的 GPU 仍可能因网络、电力、制冷、故障或调度问题而无法接近设计吞吐。峰值 FLOPS、设备数量和持续有效 FLOPS 是三个不同概念。

## 2.3 同步训练为何成为电网问题

吉瓦级设施不仅受公共基础设施约束, 也会反过来改变电网。同步训练会让许多设备的计算强度一起变化, 使电网在短时间内面对数百 MW 的负载波动; 既有电网并非为这种巨型、快速同步负载设计。Katti 把极端情形描述为电网可能失稳, 甚至引发州级停电, 并把设计目标表述为避免 AI 设施对国家其他基础设施造成 collateral damage。这是嘉宾提出的条件性风险场景, 不是已经发生的事实或确定预测。 [00:12:20--00:13:20]

Katti 所说的去风险包括把逻辑和内存制造分布到不同地点、减少对既有电网的完全耦合, 并探索天然气和未来核能。它是一种方向判断, 不等于本讲完成了环境影响、成本、监管与建设周期比较。 [00:13:20--00:13:56]

## 2.4 30 GW、100 GW 与 7 TW 的状态不同

为了把 30 GW 放回长期尺度, Katti 提出 “每人一块 GPU 等效智能” 的思想实验。他先给出每块 1–2 kW 的口头范围, 但 7 TW 的结果实际采用 1 kW 下界:

$$7 \times 10^9 \text{ people} \times 1 \text{ kW/person} = 7 \times 10^{12} \text{ W} = 7 \text{ TW}$$

- $7 \times 10^9$ : 思想实验采用的全球人口数量;
- 1 kW/person: 人均等效功率, 采用口头范围 1–2 kW 的下界;
- 7 TW: 由上述假设得到的全球总功率;
- 整个关系是思想实验, 不是部署预测、能源政策目标或终端形态承诺。

7 TW 是 7000 GW, 约为 30 GW 的 233 倍, 接近 2.37 个数量级; 嘉宾口语概括为 “两数量级更多”。他又在明确没有准确值的前提下, 估计美国 hyperscalers 规划合计可能约 100 GW, 并

占电网容量的显著双位数比例。后者只能保留为即席估算，不能写死为确定的 20%。 [00:14:02--00:15:25]



图 3: 三种功率口径的数量级比较；状态标签比柱长更重要。<sup>3</sup>

## 2.5 本章小结

一吉瓦算力是一项供应链和运营工程：芯片到土地必须同步到货、集成、上线并保持可靠运行。它还是一种新的电网负载，动态波动与平均功率同样重要。30 GW、100 GW 和 7 TW 分别是愿景、估算和思想实验，只有保留状态标签，数量比较才不会误导。

## 3 从训练能力到用户可获得的智能

### 3.1 训练完成不等于交付完成

在用户侧，所谓算力优势表现为复杂模型能否稳定调用、token 配额是否宽松、限额是否频繁触发。Katti 用一次当时的产品体验说明容量如何影响可用性，但模型版本“5.5”的正式名称没有被字幕可靠确认，*no limits* 也与随后提到的频繁重置限额存在语境张力；因此本文只保留机制，不写成永久产品政策。 [00:15:38--00:16:50]



图 4: 从训练能力到可交付智能，中间不能省略服务容量与运营策略。<sup>4</sup>

Katti 将基础设施目标归纳为两部分：既要帮助“build the intelligence”，也要准备足够的 usable compute，把这种智能大规模分发并尽量减少人为限制。课堂获得 Codex 订阅的故事只是一次具体经历，不是面向所有课程或用户的普遍承诺。 [00:16:50--00:17:36]

#### 训练智能与交付智能

训练决定模型能做什么；可用推理容量、服务可用率、峰值管理与配额策略决定多少人能在何时真正用到它。trained intelligence 与 delivered intelligence 不能画等号。

<sup>3</sup>教学图据讲座 00:14:02--00:15:25 的口头说明整理；采用对数尺度教学示意，不代表已建成容量或精确电网占比。

<sup>4</sup>教学图据讲座 00:15:38--00:17:19 的口头说明整理；结构为教学重绘；不代表某一订阅方案的长期配额。

## 3.2 本章小结

模型能力只有穿过上线、推理服务、调度和用户配额这条链，才成为产品能力。这个区分为下一章铺路：当一次请求扩展成工具、搜索、数据库和执行环境共同参与的智能体任务，交付系统必须围绕一张更复杂的计算图来组织。


## 4 智能体计算图、人的 flow 与异构硬件

### 4.1 先理解工作负载，再选择硬件

主持人问 GPU、CPU、内存、网络 and ASIC 为什么需要共同工作。Katti 没有从品牌或器件清单回答，而是先解释工作负载演化：chatbot 近似一次推理；reasoner 在输出前进行更多推理；agent 则调用搜索、数据库、软件和 VM/外部执行环境，观察结果后再次判断，直到任务完成。

[00:17:36--00:20:10]

### AI Evolution



MS&E 435 | Economics of the AI Supercycle

Source: Path to AGI as laid out by OpenAI in Bloomberg (2024).

图 5: 课件把工作负载演化概括为 Chatbots、Reasoners、Agents、Innovators、Organizations。本章只把前三列作为讲者当段论证的视觉锚点；后两列及 2026 fully autonomous 属于课件中的未来判断。<sup>5</sup>

<sup>5</sup>视频画面时间区间：00:18:05–00:18:52（抽帧点 00:18:08）。画面从 1920×1080 原视频中抽取；完整全屏课件，无裁剪；已比较 00:18:08、00:18:10、00:18:12 及区间密集候选。




图 6: 三类工作负载：从一次推理到包含外部节点的智能体执行图。<sup>6</sup>

Katti 同时使用“闭环”和 directed acyclic graph。两者可通过时间展开统一：业务逻辑会依据结果反复决策；一次具体运行中，每次重试和新推理都实例化为新节点，于是有限执行轨迹仍可表示为 DAG。字幕中的 RL VM 无法从画面确认，本文降级为“VM/外部执行环境”，不自行扩成强化学习虚拟机。

## 4.2 人的连续工作状态是基础设施指标

智能体可能思考、等待工具并运行数分钟甚至数小时。用户转去做别的事后，系统再回来请求判断，会迫使人重新恢复任务背景。Katti 因而把目标说成“make the human the bottleneck”：让人的时间花在 steering、judgment 与 acceptance，而不是等待模型、工具或调度。[00:22:02--00:23:30]

<sup>6</sup>教学图据讲座 00:18:05–00:21:17 的口头说明整理；图中 VM/环境只表示讲座示例，不执行任何代码或操作。

## The goal is to make the human the bottleneck


Time should be spent on judgment and steering — not waiting on the system.

### Today



Shift the time mix

### Target



Illustrative split

Success condition: the user is waiting on their own decisions, not on model inference, tool hops, or scheduler delays. Ensure the human is in flow

Stanford

MS&E 435 | Economics of the AI Supercycle

图 7: 从 Today 到 Target: 减少 AI think/tool wait, 把时间转向人的 steering、judgment 与 acceptance。课件底部把成功条件定义为人不再等待模型、工具跳转或调度。<sup>7</sup>

### 保持在 flow 中 (00:22:43–00:23:30)

**Katti:** 目标是让人类成为瓶颈。更准确地说, 是让人与 AI 一起工作时保持 flow: 交互快速, 系统不断回来请求人的判断, 而不是让人等待并反复切换上下文。

这不是要“拖慢人”, 而是把延迟预算绑定到人的认知成本。墙钟时间相同的两次等待, 如果其中一次让用户离开任务并重新加载上下文, 实际代价更高。

## 4.3 异构计算来自节点差异, 也来自供给现实

仅靠 GPU 很难经济地覆盖整张 agent graph。模型推理、通用控制、搜索/数据库、外部环境和长状态任务具有不同延迟、吞吐、内存与通用性需求。嘉宾举 Cerebras 作为快速推理例子, 也提到为长上下文和大量状态设计的加速器; 这些是方向性例子, 不构成固定的品牌-负载最优表。

[00:23:30--00:24:42]

<sup>7</sup>视频画面时间区间: 00:22:02–00:23:30 (抽帧点 00:22:10)。画面从 1920×1080 原视频中抽取; 完整全屏课件, 无裁剪; 已比较 00:22:08、00:22:10、00:22:12, 其中 00:22:12 有画面破损而被拒绝。

| 节点需求         | 可能的资源类型         | 证据边界                       |
|--------------|-----------------|----------------------------|
| 大规模模型推理      | GPU 或专用加速器      | 本讲只主张多类硬件共存，不给产品规格。        |
| 快速推理         | 嘉宾以 Cerebras 举例 | 不能外推具体 tokens/s 或 TTFT 倍数。 |
| 长上下文/大状态     | 较多内存状态的专用设计     | 只说明设计方向，不指定厂商或实现。          |
| 工具、控制、数据库与环境 | CPU、服务与外部执行资源   | 这是按节点属性做的教学归类，不是嘉宾逐项分配。    |

多芯片世界还有供应侧原因。Katti 认为供应链不能 single-threaded；TSMC 也有动力让多个客户成功，而非把收入和产能过度押在单一大客户上。晶圆分配给多家公司会形成多种加速器，对 Google、Amazon、OpenAI 等规模需求方而言，多硬件适配因此也是容量现实。[00:25:35--00:27:29]

主持人口头称 Trainium 的 run-rate revenue 约为 500 亿美元，随后表示自己忘记的是 Alphabet 的对照数字，并未撤回前述 Trainium 数字。由于该口头数字没有得到讲座画面或外部一手资料核验，本文不把它作为核心事实；多芯片论证也不依赖这一高风险口径。

#### 4.4 拓展阅读

Stanford Week 5 将 *Scaling AI at the Speed of Openness: From Silicon to Systems* 列为补充材料。它可用于继续理解 inference-first、低延迟、内存编排与机架级系统；但该外部演讲发布时的视频身份标注仍为 Intel 高管，不能把其中观点倒灌成这场讲座的 OpenAI 官方策略。

#### 4.5 本章小结

chatbot、reasoner 与 agent 的差异首先是计算图差异。智能体把模型、工具、搜索、数据库和环境编成一张任务图，要求系统按节点特征映射多类资源，并以人的 flow 检验端到端优化。工作负载异构性与晶圆供给结构共同推动多芯片世界。

### 5 集中式推理、TTFT 与全栈瓶颈迁移

#### 5.1 推理分散，不等于现在就应搬到边缘

训练通常依赖同步大集群，推理流量则更尖峰化、更难预测，因此“把小集群放到靠近用户的边缘”是自然猜想。Katti 的回答是：方向上可能如此，但当前建设经济性与模型执行特征仍偏向集中式站点。[00:27:29--00:29:52]

按其口头比较，单点建设 1 GW 的每 MW 成本低于分散建设许多 50 MW 小块；美国还缺少建设这类设施的劳动力，把关键人员集中到大项目更现实。1 GW = 20 × 50 MW 只是功率换算，不能被误读为成本恰好相差 20 倍。集中式描述地理与设施规模，异构式描述站点内部计算类型，两者可以同时成立。

## 5.2 首 token 前，模型必须先处理完整上下文

Katti 称 agentic workload 的 time to first token 约为 400–500 ms，主要因为第一个输出 token 之前要处理任务上下文。这个数量级大于把计算搬近用户可能节省的网络传输时间，所以短期内边缘化收益有限；若未来高智能模型被蒸馏得足够小，经济性才可能改变。 [00:29:02--00:29:52]

为区分各速度指标，可以把当前路径作教学近似：

$$T_{\text{TTFT}} \approx T_{\text{other}} + T_{\text{prefill}}$$

- $T_{\text{TTFT}}$ ：请求到第一个输出 token 的时间，单位 ms；本讲场景约 400–500 ms；
- $T_{\text{other}}$ ：应用处理、token 化、网络、负载均衡和路由等，单位 ms；嘉宾只说合计为数十 ms；
- $T_{\text{prefill}}$ ：处理完整输入上下文的预填充时间，单位 ms；嘉宾称为数百 ms、是当前主要部分；
- 这是教学近似，不是精确 p50/p95 拆账，实际还可能有排队、缓存和调度。

Codex 示例中，用户 prompt 与代码库形成约 400k-token 上下文；模型先通过 attention 完成 prefill，之后才出现第一个输出 token。400k tokens 与口头所说的“数百 MB”不能固定换算，也不代表每次请求都会占满上下文窗口。 [00:30:17--00:31:13]




图 8: TTFT、prefill 与 decode 的边界；条宽只表达相对主次，不是精确拆账。<sup>8</sup>

### 三个速度指标必须分开

TTFT 衡量第一个输出 token 何时出现；prefill 是其重要组成；decode throughput 衡量首 token 后持续生成的 tokens/s。三者相关，但不是同一个指标。

## 5.3 局部加速会暴露下一层瓶颈

嘉宾说 Cerebras 让系统 “generating tokens faster”，直接支持的是 decode 生成加快。随后应用和 API 中原本不显眼的延迟变得突出，团队必须继续优化其余层并调整 API infrastructure。课程没有给 Cerebras 的具体 tokens/s、prefill 倍数或 TTFT 降幅，因此不能把三项速度合并。

[00:31:43--00:32:38]

这是一条普遍的系统工程规律：串联路径中一个主导阶段缩短后，其余阶段的相对占比会上升。Katti 将其比作持续“打地鼠”，并判断每减少 30–50 ms 都可能改善 engagement、revenue 与 retention；后半句是经验判断，不是本讲证明的因果定律。 [00:32:38--00:33:13]

<sup>8</sup>教学图据讲座 00:29:02–00:31:43 的口头说明整理；只保留“数十 ms、数百 ms、约 400–500 ms”的讲座口径。

### 体验只认端到端结果

峰值芯片性能只有穿过应用、API、网络、路由、prefill、decode 和工具链，才会变成用户真正感到的速度。局部 benchmark 不能替代端到端任务时间。

## 5.4 本章小结

当前集中式推理由设施规模经济和长上下文 prefill 共同支撑；未来模型蒸馏可能改变边缘经济性。首 token 前等待与首 token 后吞吐必须分开，而局部加速会把瓶颈推向应用和 API 等下一层。这正是下一章协同设计的动机。

## 6 存储层次与模型-芯片-软件协同设计

### 6.1 “大计算单元 + HBM” 仍是早期形态

Katti 将今天的 AI 系统概括为大计算单元连接一层 HBM。与数十年通用计算演进相比，这仍很简单：CPU 系统后来逐步形成多级缓存、flash 和磁盘等不同速度、容量和成本的层次。这个类比不意味着把 CPU 层次原样复制到 GPU，而是说明 AI 也需要围绕数据放置、带宽、延迟、能耗和软件调度建立更丰富的 memory hierarchy。 [00:33:39--00:34:28]




图 9: 从单层 HBM 视角走向更丰富的存储层次；下半图是方向性教学重绘。<sup>9</sup>

### HBM 不等于 memory hierarchy

HBM 是特定高速内存技术；memory hierarchy 是用不同速度、容量、成本和访问路径组织数据的系统概念。本讲没有宣布缓存级数、部件规格或确定的未来产品架构。

### 6.2 让一代模型参与设计下一代基础设施

更深的变化是“AI 生成下一代 AI infrastructure”。Katti 指越来越多地用最新模型参与下一代芯片及低层软件设计。这里的 recursion 是形象类比：一代模型帮助寻找更适合下一代模型的硬件和软件组合，不是课程定义的递归算法，也不表示芯片设计已经完全自动化。 [00:34:32--00:35:28]

<sup>9</sup>教学图据讲座 00:33:39-00:34:28 的口头说明整理；flash/硬盘来自嘉宾的 CPU 历史类比，不是具体 AI 产品路线。




图 10: 模型-芯片-系统-软件协同设计闭环。<sup>10</sup>

传统流程往往是先训练模型、独立设计芯片、交付后再调通。嘉宾希望模型在训练期间就帮助判断适合运行的芯片、系统和软件，从而缩短 compute time cycle。他把芯片从构想到量产概括为约三年，并认为这难以跟上模型变化；三年是行业量级估算，不是所有项目的固定周期。[00:35:03--00:36:22]

#### 方向性判断不是自动化承诺

字幕只支持“越来越多地使用模型参与设计”以及“离那样的世界不远”。不能写成模型已独立完成芯片设计，也不能虚构三年周期已经缩短到某个数字。

## 6.3 本章小结

AI 基础设施的下一阶段同时是层次化和协同化：更丰富的内存/存储体系解决数据供给问题，模型-芯片-系统-软件共同设计则减少三年硬件周期与快速模型演进之间的错配。优化对象从单颗芯片扩展到整个技术代际的交付周期。

## 7 价值迁移、稀缺底座与问答收束

### 7.1 五层技术栈与两种时间尺度

主持人以 Jensen Huang 所称的 AI five-layer cake 开启最后一轮：energy、chips、infrastructure、models、apps。这是产业栈分类，不是固定利润分配公式。[00:36:26--00:36:37]

<sup>10</sup>教学图据讲座 00:34:32-00:36:22 的口头说明整理；闭环为教学整理；讲座未量化自动化率或周期缩短幅度。




图 11: AI 五层栈: Energy、Chips、Infrastructure、Models、Applications。品牌仅是课件示例, 层次结构才是本章讨论对象。<sup>11</sup>

Katti 用移动互联网作历史类比: 早期利润先流向电信与基础设施, 之后转向应用和云服务; 他判断 AI 当前利润更集中在基础设施, 长期可能更多上移到平台和应用。这个结论是**预测性历史类比**, 不是确定的投资定律。 [00:37:02--00:37:40]

这与他随后“看多最底层”并不矛盾。价值上移谈产业成熟后的利润池; 看多底层谈当前扩张期最稀缺、最难复制的建设能力。嘉宾特别提到大型变压器、电池、发电与输配电、制冷和系统组件, 并以自己在 Stanford 的教学经历提醒学生, 晶体管、材料等底层工程方向仍极其关键。

[00:38:14--00:39:52]

### 价值上移与底层稀缺是双轴结论

长期价值可能走向平台和应用; 当前算力能否按时上线, 却仍由能源、制造、冷却、材料和关键设备决定。两个判断观察不同时间尺度, 不应互相抵消。

## 7.2 薄封装的风险与应用人口的变化

Katti 说自己会“short”纯 model wrapper, 因为模型能力快速内化任务, 缺乏独特能力的薄封装难以保持差异。他同时明确, 这不等于 OpenAI 或 Anthropic 会建设所有应用; 更深的问题是, 用户未来是否仍要逐个进入传统 app, 还是直接表达结果并让智能体完成。 [00:39:54--00:41:08]

因此, 稳妥结论不是“所有垂直应用都会消失”, 而是: 没有独特数据、 workflows、执行环境或分发优势的薄封装更脆弱; 能拥有任务闭环和领域资产的应用仍与简单 wrapper 不同。后半句是为澄清机制做的编辑整理。

<sup>11</sup> 视频画面时间区间: 00:36:22--00:37:40 (抽帧点 00:36:32)。画面从 1920×1080 原视频中抽取; 完整全屏课件, 无裁剪; 已比较 00:36:28、00:36:30、00:36:32, 其中 00:36:30 有转场破损而被拒绝。

### 7.3 制造与设备的咽喉点

当被问及最大的结构性问题，Katti 指向逻辑与内存 fab capacity：逻辑侧只集中在少数厂商，内存侧同样集中；更深一层，这些制造商又共同依赖 ASML 的关键设备。他把 ASML 称作供应链的单一 choke point。 [00:41:42--00:42:17]




图 12: 供应链向下游需求扩散、向上游制造与设备集中。<sup>12</sup>

#### 咽喉判断的证据边界

“ASML 是最深的 choke point”是嘉宾当场判断，不是本笔记对全球供应链的独立审计。正文不补入课程未给出的份额、制裁、产能或交期数字。

### 7.4 短中期编排、长期内存与 time to compute

学生问题多处 [INAUDIBLE]，能可靠使用的是嘉宾回答。他把短中期改进放在 orchestration software、harness 和 token efficiency，把更长期突破放在新的 memory architectures，并附加条件：除非 Transformer 被新范式取代。 [00:42:27--00:43:19]

在 Stargate 问答中，他用“1 GW 约 700 亿美元、约 50 万 GPU”强调建设规模。两项均为嘉宾口头估算，不能反推单卡价格、功耗或 PUE。更关键的指标从 amount of compute 转为 time to compute：不只看最终承诺多少容量，而看它多久能完成供应链、建设、集成和运营并真正上线。

[00:43:23--00:44:44]




图 13: 从“拥有多少算力”转向“多久能把算力上线”。<sup>13</sup>

他偏好大块集中容量，是因为许多分散小块更难快速运营上线。这与异构硬件并不冲突：设施可以集中，内部仍由多种计算资源组成。

<sup>12</sup>教学图据讲座 00:41:42-00:42:17 的口头说明整理；只表达嘉宾关于集中度的判断，不添加市场份额、产能或地缘信息。

<sup>13</sup>教学图据讲座 00:43:36-00:44:44 的口头说明整理；各阶段未分配虚构时长；图只整理嘉宾的交付指标。

## 7.5 实质性结尾：开放权重与前沿模型并存

最后一问涉及开放权重模型。虽然学生问题部分听不清，嘉宾回答的主线完整：开放模型在生态中有角色；他仍认为前沿智能需要数量级更多算力、规模定律继续成立；开放权重模型会通过蒸馏等方式追赶并把能力带到更紧凑的形态；而六个月的智能领先在他看来已经“enormous”，因此没有理由降低对前沿智能的投入。 [00:44:45--00:46:00]

### 结尾不是二选一

嘉宾没有说开放权重模型会取代前沿模型，也没有否定开放生态。其判断是双轨共存：前沿能力继续以更大算力向前推进；开放权重模型通过蒸馏把已有能力压缩、传播并追赶。六个月领先的价值是战略判断，不是固定竞争周期。

## 7.6 拓展阅读

- [OpenAI x Broadcom – The OpenAI Podcast Ep. 8](#): 模型工作负载反推定制加速器与网络系统的外部案例；如引用 10 GW 或部署计划，须明确来自 [OpenAI 2025-10-13 官方公告](#)，不是本讲时间轴中的数字。
- [Scaling AI at the Speed of Openness](#): 补充 inference-first、内存编排和机架级系统；发布时身份与本讲不同。
- [The Supply and Demand of AI Tokens](#): Dylan Patel 访谈视角，适合继续追问 token 需求与物理供给；其中预测和数字不是 Stanford/OpenAI 官方结论。

## 7.7 本章小结

价值可能随产业成熟从基础设施上移到平台和应用，但当前扩张仍由能源、制造、冷却、材料和关键设备决定。短中期依靠 harness、编排与 token 效率，长期关注内存架构；项目管理则从名义容量转向 time to compute。开放权重与前沿算力是共存关系，而非简单替代。

# 8 总结与延伸

## 8.1 讲者的收束：前沿领先仍值得扩算力

嘉宾在最后两分钟没有停在“开放与封闭谁赢”的口号上。他把生态扩散与前沿推进拆成两种机制：蒸馏帮助更小、更紧凑的开放权重模型传播能力；前沿实验室则继续投入数量级更多算力以推动智能边界。按他的战略判断，哪怕只有六个月的智能领先，也足以构成继续投资的理由。

[00:45:03--00:46:00]

## 8.2 把全讲压缩成四个闭环

1. **经济闭环**：容量上线与利用率支撑研究和产品；使用增长形成收入；收入与战略目标再支持扩建容量。

2. **物理闭环**：芯片、内存、网络、电力、制冷、建筑和土地必须同步；运营波动又反过来要求电网与设施升级。
3. **任务闭环**：模型调用扩展为推理、工具、搜索、数据库和环境共同执行；异构计算与全栈延迟决定人能否保持 flow。
4. **代际闭环**：当前模型参与下一代芯片、系统和低层软件设计；更适配的算力再训练与运行下一代模型。

四个闭环共享一个评价函数：**有效算力是否按时、可靠、经济地转化为任务结果**。这比单独比较峰值 FLOPS、GPU 数、模型参数或某个 benchmark 更接近本讲的系统视角。

### 8.3 实践中的五个检查问题

1. 讨论“多少算力”时，口径是设施功率、设备数量、峰值吞吐，还是持续有效吞吐？
2. 讨论“推理占比”时，是否包含 RL 采样、合成数据和 reasoning，而非只看产品请求？
3. 讨论“更快”时，测量的是 TTFT、prefill、decode tokens/s，还是完整任务墙钟时间？
4. 讨论“多芯片”时，原因是节点需求异构、供应链韧性，还是两者兼有？
5. 讨论“价值上移”时，是否同时考虑当前底层制造和能源仍是交付咽喉？

### 8.4 仍然开放的问题

本讲提出方向，却没有给出所有答案：怎样量化有效算力而不把功率、GPU 数与 FLOPS 混为一谈？如何在训练负载波动与公共电网安全之间建立可执行的协调机制？不同 agent 节点的调度目标如何同时纳入成本、延迟、可靠性和人的认知切换？模型辅助硬件设计能否真正缩短三年周期，缩短多少？开放权重模型的蒸馏扩散与前沿模型扩算力会形成怎样的长期分工？这些问题都需要超出本讲的工程数据和实证研究。

#### 最终带走的判断

AI 基础设施不是 GPU 仓库，而是从能源、制造、设施、系统软件到智能体工作流的连续交付链。只有能按时上线、可靠运行、被正确调度并改善用户任务体验的容量，才是有经济意义的算力。

### 8.5 本章小结

全讲最终把“模型更聪明吗”改写为一个更严格的问题：产业能否持续构建合适的物理和软件系统，把更强智能按时交付给更多人。前沿模型、开放权重、异构硬件、集中式设施与价值上移并非互斥选项；它们处在同一端到端系统的不同层级和时间尺度上。