

课程笔记：解锁企业内部知识

从通用模型、可验证强化学习到持续学习

Stanford MS&E 435: Economics of the AI Supercycle

五道口纳什 & Codex

2026 年 8 月 28 日



视频频道：Stanford Online

主讲与嘉宾：Apoorv Agrawal；嘉宾 Yash Patil

课程日期：2026 年 5 月 8 日 上传日期：2026 年 5 月 22 日

视频时长：48:10

视频链接：<https://www.youtube.com/watch?v=LRGX-gTegVA>

配套材料：[Stanford MS&E 435 Course Materials](#)

笔记证据：1511 条英文自动字幕、1080p 原视频、Week 6 两份指定阅读

PDF 制作 Skill：<https://github.com/wdkns/wdkns-skills>

目录

导读：怎样使用这份笔记	1
章节地图	1
1 问题从哪里来：通用模型为何不懂企业	2
1.1 从模型评测到企业落地	2
1.2 为什么讲者先回顾模型史	2
1.3 本章小结	3
2 现代模型能力的形成：从表征学习到推理模型	3
2.1 AlexNet：从手工特征到数据驱动表征	3
2.2 Transformer、预训练与扩展定律	4
2.3 RLHF 与推理模型：训练时扩展之外的新轴	4
2.4 瓶颈迁移：突破会制造新的稀缺资源	5
2.5 为什么代码和数学成为 RLVR 的第一前沿	5
2.6 幻灯片例子：从“能生成”到“生成得好”	6
2.7 本章小结	6
3 从预训练到后训练：数据墙之后如何继续扩展	7
3.1 预训练与后训练解决不同问题	7
3.2 数据墙：公开互联网之后还有什么	8
3.3 RL 环境：从“读代码”到反复完成任务	8
3.4 本章小结	8
4 Eval 定义山峰：企业专用化的训练闭环	9
4.1 Eval 为什么决定研发路线图	9
4.2 从实验室 eval 到企业 eval	10
4.3 DoorDash 菜单：把业务标准变成学习信号	10
4.4 为什么不能只等下一代通用模型	11
4.5 后训练算力：小比例不等于不重要	11
4.6 性能、成本与时延的帕累托前沿	11
4.7 Model、context 与 harness 的协同	12
4.8 本章小结	12
5 持续学习：把生产反馈变成能力增量	12
5.1 从稀疏奖励和下游后果中学习	12
5.2 Cursor Composer：隐式反馈怎样形成训练步	13

5.3	离线可回放与线上动态环境	13
5.4	从历史经验提炼 context	13
5.5	三个更新面: weights、context、harness	13
5.6	本章小结	14
6	技术与商业边界: 架构、算力和数据市场	14
6.1	Transformer 与替代架构: 经验配方和一阶原理	14
6.2	算力、能源与芯片经济	14
6.3	数据市场的成功悖论	15
6.4	视觉生成: 知识还需要可消费的界面	15
6.5	本章小结	15
7	总结与延伸: 从内部知识库到企业经验闭环	16
7.1	讲者的实质收束	16
7.2	教学综合: 六步闭环	16
7.3	Week 6 配套阅读的两条延伸线	16
7.4	开放问题与落地检查表	17
7.5	本章小结	17
A	统一术语与符号速查	17
	符号表	18
B	来源与复核说明	18

导读：怎样使用这份笔记

这份笔记不是字幕的逐句翻译，而是一份按教学逻辑重组、同时保留时间证据的中文讲义。视频没有官方章节，因此目录来自对 1511 条自动字幕的完整梳理；章节边界按语义转折而非固定时长划分。正文中的灰色时间标记，例如 [00:23:57--00:25:33]，指向原视频的证据区间。

全讲的一句话主线

通用模型提供能力底座；企业用自己的 eval 定义要攀登的山；奖励与环境把业务标准变成学习信号；专用模型、上下文与 Agent 运行框架共同交付结果；生产反馈再形成下一轮经验。

三类来源，全文严格分开

- **视频原有**：讲者或主持人在视频中明确表达的内容，附字幕时间段；未经外部核验的公司案例和数字会标为“据讲者介绍”或“口头近似”。
- **教学重构**：为帮助理解而补写的公式、表格和流程图。它们遵循讲座语义，但不是视频中展示的原式。
- **配套阅读**：Stanford Week 6 页面指定的两份材料，仅用于最后的延伸，不会倒灌成讲者原话。

元数据与自动字幕的已知边界

嘉宾姓名以视频简介的 **Yash Patil** 为准，自动字幕的“Patel”是听写误差。视频简介与发言使用 **Applied Compute**，课程材料页却把本讲列作“Applied Intelligence”；两者关系未由现有来源解释，本笔记不自行合并。自动字幕还无法可靠还原结尾视觉产品名，因此正文只写已被画面和语义确认的功能。

章节地图

时间	章节	核心问题
00:00–05:43	第一章	通用模型已经很强，为什么仍然不懂一家具体企业？
05:44–17:22	第二章	从 AlexNet 到推理模型，能力扩展的瓶颈怎样迁移？
17:22–23:57	第三章	公开数据趋于饱和后，训练信号还能从哪里来？
23:57–35:42	第四章	企业怎样用 eval、纠错和系统编排形成专用化闭环？
35:43–40:08	第五章	生产中的稀疏、延迟反馈怎样转成持续改进？

时间	章节	核心问题
40:08– 47:55	第六章	架构、算力与数据市场怎样限制下一轮扩展？
47:55– 48:05	第七章	怎样把整场讲座压缩为“企业经验闭环”？

1 问题从哪里来：通用模型为何不懂企业

1.1 从模型评测到企业落地

主持人先介绍 Yash Patil 的经历：他在 OpenAI 参与模型评测，随后接触推理模型、竞赛数学、Agent 式编码与长时程任务。这段履历的教学价值不在人物传记本身，而在它把三个问题连起来：能力必须先被评测定义；推理能力可以通过工具进入长任务；一旦进入企业，公开 benchmark 上的“聪明”并不等于业务可用。 [00:03:42--00:05:00]

讲者把通用模型比作一个很聪明、却对你的业务一无所知的天才。它掌握广泛的语言、代码和推理模式，却不知道某家公司的私有数据、历史决策、操作规范，以及这家公司怎样判定“做得好”。与此同时，最有区分度的数据往往恰好沉淀在企业内部，而不在公开互联网里。 [00:05:07--00:05:40]

需要拆开的两个问题

1. **通用能力问题**：模型是否具有语言理解、推理、代码生成和工具使用等基础能力？
2. **企业适配问题**：模型是否掌握当前组织的私有信息、任务边界、质量标准与业务后果？

更强的通用模型会抬高第一项的下限，却不会自动补齐第二项。企业知识也不只是“把文档接进检索”，还包括本地 eval、人工纠错、工作轨迹、奖励信号与生产反馈。

1.2 为什么讲者先回顾模型史

讲者没有立即给出企业方案，而是回到 AlexNet、Transformer、预训练、扩展定律、RLHF 与推理模型。原因是：每一轮技术进步都解决了上一阶段最稀缺的资源，又把新的瓶颈推到前台。若公开数据和通用训练已经把基座能力推得很高，企业下一份有效学习信号就必须来自更局部、更接近任务后果的地方。 [00:05:44--00:14:16]




图 1: 企业经验闭环：全文的教学重构总图¹

1.3 本章小结

本章只建立起点：企业专用化的必要性并非来自通用模型“没有能力”，而是来自通用能力与局部业务知识之间的结构性距离。评测经历让讲者看到能力要先被定义；长时程 Agent 让他看到能力可以进入真实 workflow；企业实践则暴露出私有标准与生产后果仍在通用训练分布之外。下一章将沿模型史追问：这些能力究竟怎样形成，瓶颈又为何逐步迁移到可验证环境与持续学习。


2 现代模型能力的形成：从表征学习到推理模型

2.1 AlexNet：从手工特征到数据驱动表征

AlexNet 的意义不只是视觉比赛分数更高，而是明确展示了一种新范式：不再要求研究者预先枚举“哪些特征最重要”，而是让神经网络从大规模数据中学习内部表征。讲者用 AlexNet 以前的手工边缘等特征，与 GPU、ImageNet 和神经网络结合后的路线作对比。增加数据与计算后，大量参数共同形成难以逐项人工解释、但对预测更有效的表示。[00:06:14--00:07:48]

What is deep learning?

Lets machines learn useful representations from data instead of relying on hard-coded rules



MS&E 435 | Economics of the AI Supercycle

图 2: AlexNet 前后：从人工特征与分类器的两段式管线，转向端到端学习表征²

² 视频帧：00:07:07–00:07:09（抽帧点 00:07:08；字幕证据 00:06:14–00:07:48）；原始分辨率 1920 × 1080；相邻三帧比选，整帧未裁剪。

讲者把这一时刻概括为“我们开始不再理解模型具体做了什么”。更稳妥的理解不是神经网络从此完全不可分析，而是能力不再对应一张由人手写、可逐条审阅的规则清单。研究问题从“人能否列对特征”变成“能否提供足够的数据、计算与优化，让模型自己学到有用表示”。

¹ 教学重绘；综合视频 00:05:07–00:05:40、00:23:57–00:29:17、00:35:43–00:40:08。视频未展示此整合图。

2.2 Transformer、预训练与扩展定律

Transformer 的核心价值在本讲中被压缩为两点：自注意力可以利用长距离上下文；训练更适合在 GPU 上并行扩展。架构准备好以后，大规模预训练通过下一 token 预测，把语言规律逐步压进参数。 [00:08:13--00:09:28]

Foundational Research Milestones




图 3: 从 Transformer、预训练与扩展定律，到 RLHF、ChatGPT 与 GPT-4 的研究里程碑³
³ 视频帧: 00:08:19-00:08:21 (抽帧点 00:08:20; 字幕证据 00:08:02-00:10:49); 原始分辨率 1920 × 1080; 相邻三帧比选, 整帧未裁剪。

把讲者的口头说明标准化，可写成下面的预训练损失。**这是教学重构，视频没有展示或推导该公式。**

$$\mathcal{L}_{\text{pre}}(\theta) = - \sum_t \log p_{\theta}(x_{t+1} | x_{1:t})$$

- $x_{1:t}$: 截至位置 t 已观察到的 token 序列; x_{t+1} : 语料中的真实下一 token。
- $p_{\theta}(x_{t+1} | x_{1:t})$: 参数为 θ 的模型给真实下一 token 分配的条件概率。
- θ : 模型的可训练参数; $\mathcal{L}_{\text{pre}}$: 预训练损失; t : 序列位置。

Kaplan 扩展定律强调增大模型规模能持续改善性能; 讲者把 GPT-3 视为重要验证。Chinchilla 随后强调计算最优配比: 模型参数增大时, 训练数据量也要相应增长。要点不是背诵一个固定比例, 而是模型、数据与计算开始成为可系统配置的工程变量。 [00:09:26--00:10:05]

2.3 RLHF 与推理模型：训练时扩展之外的新轴

纯粹的下一 token 预测器未必是好助手。它可能延续文本，却不主动澄清问题，也不天然符合安全与偏好要求。RLHF 和偏好训练在基座能力上进一步塑造行为，使模型更适合普通用户交互；

预训练主要学习“什么可能出现”，对齐训练则更多学习“什么回应更合适”。[00:10:05--00:10:49]

随后，推理模型把**测试时计算**带到前台：除了训练阶段投入更多计算，回答时也可以花更多预算进行中间推理、尝试和修正。测试时计算不是评测集上的“测试”，而是推理阶段的计算。讲者认为，思维链式行为是在受约束的强化学习环境和较大计算预算中涌现出来的；这是一项机制判断，应保留“讲者认为”的来源边界。[00:10:49--00:11:37]

推理与工具使用结合后，模型可以搜索、写代码、调用工具并持续完成任务。能力尺度由一次性答案延伸到完整轨迹，训练信号也必须评价整条行动链，而不只是一个 token。[00:11:37--00:11:52]

Recent Breakthroughs

2024-2025+



MS&E 435 | Economics of the AI Supercycle

图 4: 推理模型与 Agent 产品：画面中央明确并列预训练、后训练和测试时三种扩展⁴

⁴ 视频帧：00:11:00-00:11:02（抽帧点 00:11:01；字幕证据 00:10:49-00:11:52）；原始分辨率 1920 × 1080；相邻三帧比选，整帧未裁剪。

2.4 瓶颈迁移：突破会制造新的稀缺资源

主持人把优秀模型的要素列为数据、计算、人才和算法。讲者的回答可整理为一条迁移链：

训练算力 → 可扩展架构 → 互联网数据 → 偏好对齐 → RL 环境 → 持续学习

这不是说旧资源不再重要，而是它们的边际收益发生变化。当架构、算力与公开数据已经把通用能力推到较高位置，能够反映具体任务成败的环境与反馈就开始决定模型还能学会什么。讲者用“碰一次烫炉子就知道不该再碰”的类比说明持续学习的数据效率目标：现实反馈可能稀疏，却能承载强烈后果；困难在于识别、归因并安全地转成更新。[00:11:53--00:14:16]

2.5 为什么代码和数学成为 RLVR 的第一前沿

可验证奖励强化学习（RLVR）需要可靠判断结果是否正确。代码可以编译、运行单元测试，数学题可由答案检查器或形式规则判断，因此这些领域更容易反复提供稳定奖励。代码还拥有大量

互联网 token，任务和测试也相对容易合成。 [00:14:42--00:15:24]

按讲者所述机制，最简的验证奖励可教学重构如下；**视频没有展示或推导这一公式**：

$$r_{\text{ver}}(\tau) = \begin{cases} 1, & \text{轨迹结果通过验证器,} \\ 0, & \text{轨迹结果未通过验证器.} \end{cases}$$

- τ ：模型完成一次任务的完整轨迹，可含推理、代码、工具调用与最终结果。
- $r_{\text{ver}}(\tau)$ ：验证器对结果给出的奖励；1 与 0 只是二值教学简化。

验证器的边界

通过已有测试只说明通过了被覆盖的检查，不保证在所有情形下正确。讲者还提出“许多任务可归结为编码”的强观点；它解释代码为何像通用行动语言，却不是“所有现实任务本质上都是代码”的已证实定理。

2.6 幻灯片例子：从“能生成”到“生成得好”

主持人用幻灯片生成追问非纯代码任务。程序可以建立表格、设置标题和生成文件，但结构可执行并不等于视觉结果令人满意。现实奖励至少包含硬约束与软偏好：执行器检查文件与结构，偏好模型评价清晰度、协调性和审美。 [00:15:53--00:17:22]

按此语义可教学重构为：

$$R(\tau) = \alpha r_{\text{exec}}(\tau) + \beta r_{\text{pref}}(y(\tau))$$

- τ ：生成任务的完整轨迹； $y(\tau)$ ：最终渲染结果。
- r_{exec} ：执行与结构正确性奖励； r_{pref} ：对视觉结果的偏好评分。
- α, β ：两类目标的权重； R ：联合奖励。

该式不是视频原式，也不暗示两种质量一定能被完美相加。真正的教训是：企业任务经常需要复合奖励，而奖励模型偏差、规则覆盖不足都可能造成“分数上升、真实质量下降”。

2.7 本章小结

现代模型能力来自一组连续扩展机制：AlexNet 展示数据驱动表征；Transformer 释放并行训练；预训练与扩展定律组织模型、数据和计算；RLHF 把续写器塑造成助手；推理模型与工具使用把能力延伸到长时程轨迹。与此同时，瓶颈逐步迁移到能反复提供反馈的 RL 环境。代码与数学因可验证、易合成、先验数据丰富而先行；幻灯片例子则提醒我们，现实成功往往要同时满足硬约束与人的偏好。


3 从预训练到后训练：数据墙之后如何继续扩展

3.1 预训练与后训练解决不同问题

讲者把预训练描述为一次互联网规模的模式学习：以万亿计 token、大量算力和 Transformer 共同训练神经网络，使语言、事实关联和一定程度的世界规律编码进参数。把这一过程称为“压缩”只是教学直觉，并不表示模型逐字保存互联网。 [00:17:41--00:18:25]

Pretraining

Unsupervised Learning + Compression + Learns Patterns + Data Wall



During pretraining, the model predicts the next token, computes cross-entropy against the true token, and updates its weights so loss falls over many training steps.

Stanford

MS&E 435 | Economics of the AI Supercycle

图 5: 预训练四步管线：训练序列、前向计算、交叉熵损失与反向传播更新⁵

⁵ 视频帧：00:19:57–00:19:59（抽帧点 00:19:58；字幕证据 00:18:57–00:20:37）；原始分辨率 1920 × 1080；相邻三帧比选，完整最终态，整帧未裁剪。

后训练则把广泛能力塑造成可交互行为。讲者举例：用户问“我应该邀请谁吃饭”，纯续写器可能直接生成名字；合格助手会意识到缺少候选名单并先追问。SFT 给出理想示范，RLHF 或偏好优化表达相对偏好，RLVR 在可可靠判定结果的任务上使用验证器。 [00:18:25--00:20:56]

阶段	主要输入与信号	主要学习问题	关键边界
预训练	大规模静态 token；下一 token 损失	语言与世界模式怎样出现	广泛能力不自动等于助手行为
SFT	人或模型提供的示范答案	合格输出长什么样	覆盖受示范数量与质量限制
RLHF / 偏好优化	人类比较或奖励模型	哪个输出更符合偏好	偏好可能含噪，未必等于结果正确
RLVR	任务环境与验证器	哪些行动可靠完成任务	只适合可验证或近似可验证目标

表 2: 训练阶段的角色边界（教学重构）

3.2 数据墙：公开互联网之后还有什么

Chinchilla 语境下，模型扩大需要相应增加训练数据；但高质量、易取得的公开 token 并非无限，超大规模预训练又需要巨额资本。讲者讨论了三条路径：继续数字化纸本和稀有资料；从已有材料合成更多 token；提高模型从同一语料中学习的效率。 [00:19:24--00:22:47]

三条路径仍主要围绕静态语料：扩大原始文本、扩大表达变体、提高吸收效率。它们没有自动回答更深的问题：模型能否通过行动、失败和结果反馈产生新经验？这正是 RL 环境与静态数据集的分界。

3.3 RL 环境：从“读代码”到反复完成任务

在预训练中，模型阅读代码 token；在 RL 环境中，模型收到“实现这个功能”的任务，产生数百或数千条不同轨迹，再由测试或其他验证器判断结果。每次尝试都生成新的行为与反馈，因此增加计算也增加可学习的经验。 [00:22:47--00:23:57]




图 6: 静态 token 学习与环境交互的差别⁶

一批轨迹的平均验证奖励可以最简写成：

$$\hat{J}(\theta) = \frac{1}{N} \sum_{i=1}^N r_{\text{ver}}(\tau_i)$$

- $\hat{J}(\theta)$: 参数为 θ 的模型在这一批轨迹上的平均奖励估计。
- N : 轨迹数量； τ_i : 第 i 次任务尝试； $r_{\text{ver}}(\tau_i)$: 其验证奖励； i : 轨迹索引。

这是解释“多次尝试形成奖励分布”的教学重构，并未指定某种 RL 优化器，也不意味着奖励只能是 0/1。

3.4 本章小结

预训练从静态语料建立广泛能力，后训练再用示范、偏好或可验证结果塑造行为。公开数据趋于饱和后，行业一方面继续寻找稀有资料、合成数据与更高的数据效率，另一方面转向 RL 环境：模型通过行动和失败产生新经验。环境只解决“怎样练”，却没有自动给出“往哪里练”。下一章的 eval 正是方向来源。

⁶教学重绘；依据视频 00:22:47–00:23:57。视频未展示此并排图。

4 Eval 定义山峰：企业专用化的训练闭环

4.1 Eval 为什么决定研发路线图

评测 (eval) 不是训练结束后的报表，而是在任务上定义“什么算能力”。讲者用山峰类比：eval 先定义目标，训练管线再用结构相近、却不与评测数据直接重合的任务优化。否则模型只会记住评测点，分数上涨也不能证明能力泛化。 [00:23:59--00:25:33]

讲者以一个编码 benchmark 说明模型如何围绕公开目标竞争，并称早期版本有缺陷、后来出现更好的评测。自动字幕首次记作 SWE-bench，后一次却写成“TreeBench”；关键帧没有显示专名。本文依据同段上下文按 SWE-bench 记述，但明确保留“未获画面确认”的边界，不制造第二个 benchmark。

Evals

- Codify a task into an environment
- Measurable outcomes that you can optimize towards. Gives you a hill to climb.
- The companies with the best evals will best deployers of AI
- Slippery slope - need to avoid train/test mismatch

Stanford

MS&E 435 | Economics of the AI Supercycle

图 7: Eval 把任务编码成环境，并提供可以优化的“山峰”⁷

⁷ 视频帧：00:24:31–00:24:33（抽帧点 00:24:32；字幕证据 00:24:17–00:25:33）；原始分辨率 1920 × 1080；相邻三帧比选，排除解码异常候选，整帧未裁剪。

Eval、reward 与 verifier 不是同一件事

- **Eval**：定义要观察和比较的任务、数据与指标，是路线图和验收口径。
- **Reward**：训练时反馈给模型的优化信号，可来自规则、验证器或奖励模型。
- **Verifier**：产生某类可验证奖励的具体检查机制，如编译器、单元测试、答案检查器。

三者应尽量对齐，却不能互相替代。RL 很擅长沿已定义指标爬坡，因此错误的 eval 会高效地把系统带向错误方向。

4.2 从实验室 eval 到企业 eval

通用 benchmark 只能描述企业共享的一部分能力。不同金融机构即使属于同一行业，操作方式、风险边界和“合格结果”也不完全相同，因此需要各自的 eval。模型实验室推动通用能力，企业用内部 eval 表达本地标准；据讲者介绍，Applied Compute 的位置是在两者之间帮助企业完成专用化。[00:25:33--00:26:08]

通用模型因而像 workhorse，提供可用能力的“下限”；企业的私有数据、标准与系统设计决定同一起点之上能达到的“上限”。这是一项产品战略判断，不是绝对性能定律。[00:26:08--00:27:22]

4.3 DoorDash 菜单：把业务标准变成学习信号

据讲者介绍，新商户向 DoorDash 提交菜单图片等非结构化信息，平台要把它们转换成结构化店面。难点不只是 OCR：菜品、modifier、加料与组合关系必须符合平台内部规范。一个 VLM 即使读对文字，也未必组织对业务结构；讲者称当时仅使用通用模型与 prompting 未达到要求。[00:27:21--00:28:38]

From Base to Post-trained Model




图 8: DoorDash 案例：从非结构化菜单画面到结构化商品与 modifier 界面⁸

⁸ 视频帧：00:27:34--00:27:36（抽帧点 00:27:35；字幕证据 00:27:21--00:29:17）；原始分辨率 1920 × 1080；相邻三帧比选，完整最终态，整帧未裁剪。

他们采用的闭环可抽象为五步：模型先生成结构化菜单；人工按规范修正；修正版成为 ground truth；差异被汇总成误差或奖励；训练再直接降低这些错误。[00:28:36--00:29:17]

$$\mathcal{L}_{\text{ent}}(\theta) = \frac{1}{N} \sum_{i=1}^N d(f_{\theta}(x_i), y_i^*)$$

- x_i : 第 i 份菜单图片； $f_{\theta}(x_i)$: 模型生成的结构化菜单。
- y_i^* : 人工按业务规范修正后的 ground truth； d : 任务特定的结构差异函数。

- N : 样本数; i : 样本索引; θ : 模型参数; $\mathcal{L}_{\text{ent}}$: 企业任务平均误差。

该式是教学重构。视频没有规定 d 的实现; 真实系统可能分别统计漏项、字段关系、modifier 归属与格式约束。案例的重点不是“做一个更强 OCR”, 而是**内部规范定义 eval, 人工纠错生产 ground truth, 差异函数把规范变成训练信号**。

4.4 为什么不能只等下一代通用模型

主持人问: 如果未来的“GPT-17”开箱即用就能完成今天的专用任务, 为何现在训练? 讲者给出三层回答: 企业关心每个时间点的能力前沿, 等待会放弃今天已经可取得的回报; 世界的数据分散在不同组织和系统中, 许多正确行为依据不在通用训练分布; RL 使专用训练在具体任务上更具数据与算力效率。[00:29:16--00:31:04]

这些是讲者对当前实践和未来的判断, 不应升级为“一个通用模型永远不可能覆盖企业任务”的定理。稳妥结论是: 只要私有标准、数据与后果仍无法进入通用训练, 企业专用化就有现实时间价值。

4.5 后训练算力: 小比例不等于不重要

讲者现场援引 DeepSeek: V3 预训练约用 240 万至 250 万 H800 GPU 小时, 通向 R1 的 RL 训练约 15 万, 并口头概括为“约 5%”。按这些字幕数字直接计算是约 6.0%–6.25%, 两组统计边界是否可比也未解释。[00:31:16--00:31:45]

不要把口述近似改成行业常数

本笔记保留“讲者口头约 5%”与数字算术不完全一致这一事实, 不默默修正, 也不推导“所有 RL 都只需预训练 5% 算力”。真正的教学点是三条可独立扩展的轴: 预训练计算 C_{pre} 、后训练计算 C_{post} 与测试时计算 C_{test} 。

讲者观察到后训练的批量、轨迹数量和计算投入正在迅速上升, 并用推理模型、编码 Agent 和 deep research 说明更多 RL 计算与更好表现之间的经验关系。这里没有统一单位或固定函数。

[00:31:46--00:33:01]

4.6 性能、成本与时延的帕累托前沿

据讲者介绍, Applied Compute 为 Cognition / Windsurf 部署过代码 bug 检测模型: 开发者保存文件后, 模型在约两秒内检查代码。大型通用模型可能更强, 却常更慢、更贵; 针对单一任务训练的小模型则可能在接近任务性能的同时降低成本和时延。[00:33:14--00:33:58]

性能 P 、成本 K 与时延 L 不应被随意相加为一个分数。帕累托前沿表达的是: 若不牺牲任何一项, 就不能继续改善另一项。专用模型的产品位置不是“参数越小越好”, 而是在明确业务约束下找到更合适的组合。

4.7 Model、context 与 harness 的协同

企业系统并非只由一次模型调用组成。讲者把能力拆成三层：模型提供推理；context 提供当前任务需要的企业资料、历史与状态；Agent 运行框架（harness）负责工具、流程、编排和状态管理。更强的编排模型还可以把任务路由给多个专用子模型。 [00:34:08--00:35:42]




图 9: 企业 Agent 的三个协同层（教学重构）⁹

这解释了为什么企业专用化不必全部写进权重。变化快、需审计的知识更适合 context；稳定且重复的能力可以考虑权重更新；跨工具约束和流程策略则落在 harness。系统优势来自三层共同设计，而不是只比较单个模型的 benchmark。

4.8 本章小结

RL 环境提供训练机制，eval 决定优化方向。企业 eval 把本地标准显式化，DoorDash 案例进一步展示人工纠错如何成为 ground truth 和训练信号。专用化的商业价值既来自今天的时间价值，也来自私有数据不在通用训练分布；后训练、测试时计算与小型专用模型还提供新的成本—性能—时延组合。最终交付能力由 model、context 与 harness 共同决定，这也为下一章的持续学习埋下关键伏笔：系统上线后，三个层都可能继续更新。

5 持续学习：把生产反馈变成能力增量

5.1 从稀疏奖励和下游后果中学习

讲者把持续学习描述为：模型进入生产后，能从使用过程、稀疏奖励以及行动的下游后果中不断变好。一个动作可能当下看似合理，真正结果却在数分钟、数天后出现；反馈也可能只覆盖少量轨迹。因此持续学习首先是信用归因和证据质量问题，而不只是“更频繁地训练”。 [00:35:53--00:36:35]

讲者预计它会渐进实现，而不是突然由某个神奇算法解决。先决条件是企业能够取得正确数据、完整上下文和代表性反馈：若看不到动作之后发生了什么，任何算法都无法从真实后果学习。

[00:36:35--00:37:16]

⁹教学重绘；依据视频 00:34:08-00:35:42、00:39:55-00:40:08。视频未展示此分层图。

5.2 Cursor Composer：隐式反馈怎样形成训练步

据讲者介绍，Cursor Composer 会观察用户是否接受生成内容、是否随后撤销或修改，并把这些遥测作为隐式奖励。系统持续收集交互，按批次形成训练数据，再做在线更新。[00:37:16--00:38:04]

“接受”并不必然等于业务成功，“撤销”也可能只是需求变化。隐式反馈规模大、成本低，却含噪并受界面设计影响。讲者估计整个循环可能以数天或数周推进、单步训练耗时数小时，同时明确说自己不知道精确条件；本笔记因此只保留为粗略量级。[00:38:04--00:38:34]

5.3 离线可回放与线上动态环境

离线 RLVR 中，任务和验证器相对稳定，同一道题可并行 rollout 数百或数千次。生产环境却持续变化：用户状态、代码库、组织政策和下游系统都会移动，昨天的轨迹不能无损回放为今天的环境。线上系统因此需要聚合许多真实会话来降低噪声，再做方向性更新。[00:38:29--00:39:16]

维度	离线可回放 RLVR	线上持续学习
任务状态	相对固定，可重复初始化	用户、系统和政策不断变化
轨迹获取	同一任务可大量并行采样	主要来自真实生产交互
奖励	测试或验证器较稳定	接受、撤销、修改、下游后果等含噪信号
主要风险	奖励投机、测试覆盖不足	归因错误、分布漂移、隐私与不可逆更新
验证方式	固定回归集与环境复现	分层灰度、回滚、长期业务指标与审计

表 3: 离线环境与线上持续学习的差别（教学重构）

大批次可以降低随机噪声，却不能自动消除系统性偏差。如果产品界面让“接受”更容易，或少数用户的失败被多数样本淹没，更多数据可能让错误目标估计得更稳定。因此必须同时检查反馈代表性、业务后果和分群回归。

5.4 从历史经验提炼 context

讲者还介绍了 Applied Compute 的一个离线案例：分析文档以及历史的人—Agent 轨迹，从中抽取能改善下游表现的经验，再把这些经验供未来任务使用。自动字幕把名称听写成“context base”；在正式名称没有可靠来源时，本笔记只描述机制，不把听写词当产品名。[00:39:17--00:39:57]

这个案例表明，持续学习不必每次都修改模型权重。历史经验可先被物化为可检索规则、示例、操作记忆或任务上下文；它更容易审计、更新和撤回。只有当经验跨任务稳定、收益明确且回归验证充分时，才值得进入更难回滚的权重更新。

5.5 三个更新面：weights、context、harness

讲者最终把创新面并列为模型权重、context 与 harness。按系统视角可教学重构为：

$$(W_{t+1}, C_{t+1}, H_{t+1}) = \mathcal{U}(W_t, C_t, H_t; E_t)$$

- W_t : 时刻 t 的模型权重; C_t : 可用上下文、记忆与检索资产; H_t : 工具、流程和编排构成的运行框架。
- E_t : 截至时刻 t 收集的文档、生产轨迹、反馈与下游后果。
- $\mathcal{U}$: 经过验证、发布控制与回滚保护的系统更新过程; $t+1$ 表示下一学习周期, 不代表每次请求后立即更新。

视频没有给出该式。它的作用是提醒: 系统改进可以选择不同可回滚面; 越难撤回的改变, 越需要更强证据。

5.6 本章小结

持续学习把训练的观察窗口从离线数据集延伸到生产后果。Cursor 案例说明接受、撤销等遥测可以提供大规模隐式反馈, 但动态环境、噪声和延迟归因使线上学习不同于可回放 RLVR。历史经验还可以先进入 context, 而不是直接改变权重。真正的闭环对象是 weights、context 与 harness 三层系统; 数据可达、反馈质量、验证与回滚比“有没有一个神奇算法”更先决定它能否安全成立。

6 技术与商业边界: 架构、算力和数据市场

6.1 Transformer 与替代架构: 经验配方和一阶原理

主持人用飞机与鸟的类比提出争论: 飞机的飞法未必像鸟一样高效, 但基础设施已经围绕飞机形成; 类似地, Transformer 可能不够节能, 却已得到算法、软件、训练集群和芯片的共同优化。Mamba 等非 Transformer 架构能否替代它, 取决于效率优势能否跨越这套路径依赖。[00:40:11--00:40:49]

讲者的立场是: 只要扩展 Transformer 仍能可靠带来能力提升, 就继续沿简单配方规模化; 他甚至猜测, 更强的 AI 可能帮助人类发现下一种架构。反方的一阶原理是: 人类学习语言并不需要互联网规模的数据, 因此当前架构的数据效率不太可能是终点。[00:40:49--00:42:10]

三种不同层次的判断

“现路线继续有效”是经验观察; “更高效架构应当存在”是一阶原理启发; “基础设施围绕现路线优化”是路径依赖。行业继续投资 Transformer, 不等于它已被证明是最终或全局最优架构。

讲者补充, 芯片与大规模基础设施已为现有架构优化, 转向像让巨轮掉头。主要实验室仍在扩建当前路线, 也保留对新架构的研究。这是讲者的个人判断, 不是课程对架构未来的定论。[00:42:08--00:42:38]

6.2 算力、能源与芯片经济

当主持人问如果不做 Applied Compute 会创业做什么, 讲者首先指出 AI 公司普遍感到算力短缺, 因而看好供能创新与更高效芯片。他同时坦言自己没有硬件或芯片设计背景, 所以这是一项

方向判断，并非具体硬件方案。 [00:42:47--00:43:51]

在“long / short”问题中，他一方面看好 NVIDIA 继续服务主要实验室，另一方面指出大型客户每年投入巨大，若外购芯片毛利很高，就会产生自研芯片、共同优化软硬件的经济动机。视频中的毛利与相对效能均为口头近似，不能当作已核验财务事实。 [00:43:48--00:45:10]

稳妥结论是：成熟生态、供给能力和软件兼容形成领先优势；客户规模越大、采购成本越高，自研潜在回报越大。最终取舍还受设计能力、良率、部署规模和总拥有成本影响，而视频没有逐项分析。

6.3 数据市场的成功悖论

讲者相对不看好当前形态的数据市场，并非认为数据失去价值，而是指出一个“成功悖论”：供应商构造 RL 任务、帮助模型变强后，下一批仍有学习价值的任务就必然更难，制作与验证成本随之上升。 [00:45:10--00:45:57]

第二个压力来自**生成—验证难度差**：生成正确解答可能很难，验证候选结果却相对容易。代码任务可保留单元测试，让模型自动尝试并验证；更强模型也更能参与合成数据流水线，减少部分逐条人工标注。 [00:45:56--00:46:23]

数据价值不是消失，而是迁移

模型变强同时改变需求侧与供给侧：它需要更难的新任务，也更能自动生成和验证训练数据。讲者判断数据市场会转向更难取得的机器人交互、第一视角（egocentric）和真实环境数据，而不是简单归零。 [00:46:21--00:46:57]

6.4 视觉生成：知识还需要可消费的界面

讲者最后谈到一款视觉生成产品：它能把论文转成视觉化讲解，帮助不擅设计或偏好视觉学习的人。主持人随后展示了把课程 syllabus 转成视觉 artifact 的成品。自动字幕无法可靠还原产品名，因此本笔记不借配套阅读猜名。 [00:46:55--00:47:55]

这段把课程主线从“模型怎样学习”带回“人怎样消费结果”。视觉布局可以降低信息获取成本，但漂亮不等于正确；只有事实、层级与图文关系都一致，视觉化才真正提高理解。

6.5 本章小结

讲座末段看似是快速问答，实则围绕能力扩展的三重约束：架构决定计算怎样转成能力，芯片与能源决定计算供给，数据与验证器决定新增计算能学到什么。讲者主张在 Transformer 尚未撞墙时继续规模化，但承认数据效率质疑与路径依赖；算力短缺让能源和芯片效率具有长期价值；模型变强又迫使数据市场向更难获得的现实经验迁移。最终，能力还必须被交付成事实可靠、结构清晰的人类界面。

7 总结与延伸：从内部知识库到企业经验闭环

7.1 讲者的实质收束

视频最后十多分钟留下四个相互连接的判断。第一，持续学习受制于数据、上下文和反馈可达，改进面同时包含 weights、context 与 harness。第二，在 Transformer 扩展仍有效时继续规模化，但替代架构与更高数据效率仍是开放问题。第三，算力需求超过供给，使能源、芯片效率和大客户自研动机长期存在。第四，合成数据不会让数据市场消失，而会把价值推向机器人、第一视角和真实环境经验。视觉生成则代表能力如何被人消费。 [00:35:53--00:47:55]

7.2 教学综合：六步闭环

全文可以压缩成以下因果链：

1. **基座能力**：通用模型提供推理、语言、代码与工具使用的起点。
2. **企业 eval**：组织把私有流程、风险边界和质量标准显式化。
3. **奖励与环境**：验证器、偏好、人工纠错与任务环境把标准转成学习信号。
4. **专用系统**：模型、context 与 harness 共同执行真实工作，而非孤立模型调用。
5. **生产经验**：工作轨迹、用户修正和下游业务后果提供新的观察。
6. **受控更新**：经验经过评测、审计与回滚保护，更新权重、上下文或运行框架。

企业内部知识因此至少有三种形态：文档回答“组织声称怎样做”，轨迹回答“实际怎样做”，后果回答“这样做是否有效”。只有三者能可靠连接，企业才可能形成比一次性微调更持久的能力复利。

7.3 Week 6 配套阅读的两条延伸线

Karpathy：从 RLVR 到应用层与视觉界面

《2025 LLM Year in Review》把 RLVR 视为训练栈的重要变化，也强调应用价值来自上下文工程、多模型编排、领域 GUI 与合适的人类介入程度。它可补强本讲的 model-context-harness 视角，并用“LLM GUI”概括图片、幻灯片、白板和网页等空间输出。但“jagged intelligence”、“autonomy slider”与“LLM GUI”属于阅读材料，不是讲者在视频中完整提出的术语。

Silver 与 Sutton：从短任务反馈到长期经验流

《Welcome to the Era of Experience》把下一阶段 Agent 学习概括为长期经验流、丰富动作与观察、环境依据的奖励，以及关于经验的规划与推理。它解释为什么生产后果可能比静态标签承载更多信息，也提示现实奖励会更稀疏、延迟和开放。论文讨论的价值函数、探索、世界模型与时间抽象并未在视频中展开，应当作为开放研究问题而不是讲者已经给出的方案。

7.4 开放问题与落地检查表

问题面	上线前必须回答的问题
Eval 覆盖	评测是否代表真实目标？是否与训练数据隔离？是否覆盖关键失败和少数用户？
奖励可靠性	接受、点击或短期完成是否真的对应长期业务成功？奖励是否会被投机？
反馈归因	延迟后果应归因到哪个动作、哪个模型、哪段 context 或哪条工作流？
更新稳定性	权重更新怎样避免遗忘和回归？context 怎样过期、撤回、审计？harness 怎样灰度与回滚？
隐私与权限	生产轨迹能否用于训练？采集是否得到同意？不同组织和角色的数据能否交叉使用？
成本与时延	专用模型带来的性能增益是否覆盖训练、部署、验证与维护成本？
数据所有权	机器人与第一视角数据由谁拥有？如何处理旁观者、商业秘密和跨区域合规？

7.5 本章小结

本讲把“企业内部知识”从静态知识库问题提升为学习闭环问题：企业用自己的 eval、私有数据和生产后果，把通用能力专用化，并在 weights、context、harness 三个层面持续更新。配套阅读一端解释 RLVR 与新应用层如何改变能力形状，另一端把长期环境经验视为未来训练数据。最稳妥的结论不是“持续自我进化已经解决”，而是企业已经能构造局部反馈闭环，而反馈质量、可回放性、稳定更新、算力成本、隐私与验证覆盖仍决定它能走多远。

A 统一术语与符号速查

English	统一中文	本文使用边界
foundation/general model	基座模型 / 通用模型	训练起点称基座模型；与企业模型对比时称通用模型。
specialized model	专用模型	可按企业或任务专用，不限于行业“垂直模型”。
post-training	后训练	总类；包含 SFT、偏好优化、RLHF、RLVR 等。
RLHF	人类反馈强化学习	奖励来自人类偏好或其模型化。
RLVR	可验证奖励强化学习	测试、答案检查器等能较可靠验证结果。

English	统一中文	本文使用边界
rollout	轨迹采样	模型在环境中完成一次任务尝试的全过程。
reward model	奖励模型	学习对输出评分; 与确定性验证器区分。
verifier	验证器	编译器、单元测试、答案检查器等结果检查机制。
eval	评测 (eval)	定义能力目标和验收口径, 不等于训练 reward。
test-time compute	测试时计算	推理时增加思考或采样预算, 不是 eval 的测试集。
continual learning	持续学习	从连续生产交互和后果中更新系统, 不等于定期微调。
telemetry	遥测数据	接受、撤销、修改等生产行为信号。
context	上下文	当前任务所需私有数据、历史、配置与检索结果。
harness	Agent 运行框架	工具、流程、路由、状态与安全边界; 不是测试框架。
Pareto frontier	帕累托前沿	性能、成本、时延不能无代价同时改善。
generator-verifier gap	生成-验证难度差	生成正确解难、检查候选结果相对容易。

符号表

符号	含义
θ	模型参数; $\mathcal{L}_{\text{pre}}$ 与 $\mathcal{L}_{\text{ent}}$ 分别为预训练损失与教学重构的企业任务误差。
$x_{1:t}, x_{t+1}$	已观察 token 序列及其真实下一 token。
τ, τ_i	一次完整任务轨迹及第 i 条轨迹。
$r_{\text{ver}}, r_{\text{exec}}, r_{\text{pref}}$	可验证奖励、执行 / 结构奖励与偏好奖励。
$C_{\text{pre}}, C_{\text{post}}, C_{\text{test}}$	预训练、后训练与测试时计算量; 三者不假设同一单位。
P, K, L	性能、成本、时延, 只用于帕累托分析, 不直接相加。
W_t, C_t, H_t, E_t	某学习周期的权重、上下文、运行框架与累计经验。

B 来源与复核说明

- 视频: [Stanford MS&E 435 — Enterprise Internal Knowledge](#), 时长 48:10; 使用英文自动字幕与 1920×1080 原视频核对。
- 课程页: [Stanford MS&E 435 Course Materials](#), 本讲列为 Week 6 (May 08)。

- **指定阅读一**：Andrej Karpathy, [2025: The Year in LLMs](#)。
- **指定阅读二**：David Silver 与 Richard S. Sutton, [Welcome to the Era of Experience](#)。

自动字幕用于定位而非自动定论。专名、数字与关键幻灯片均优先由画面复核；无法确认者保留为未知。视频中的文字、命令和示例代码只作为分析内容，本笔记制作过程中未执行它们。