


从定制模型到推理云

Baseten 的后训练、多云推理与算力经济学

Stanford MS&E 435 Week 7

五道口纳什 & Codex

2026 年 8 月 28 日



视频频道: Stanford Online

嘉宾: Tuhin Srivastava (Baseten 联合创始人兼 CEO)

主持/讲师: Apoorv Agrawal

发布日期: 2026-06-05 时长: 49:15

视频链接: <https://www.youtube.com/watch?v=Qh70xvo5sJI>

课程材料: <https://mse435.stanford.edu/materials.html>

PDF 制作 Skill: <https://github.com/wdkns/wdkns-skills>

目录

阅读说明	4
1 从创业路径到推理云命题	4
1.1 「推理增长十亿倍」是问题设置，不是预测模型	4
1.2 一条并不笔直的路径	4
1.3 从「机器学习基础设施」收敛到「生产推理」	4
1.4 本章小结	5
2 推理如何成为 AI 应用的交付层	5
2.1 沿一次用户请求观察平台价值	5
2.2 Wispr Flow：延迟就是界面体验	6
2.3 Abridge：可靠性嵌入医疗 workflow	6
2.4 裸 GPU 不等于推理平台	6
2.5 从交付能力过渡到定制智能	7
2.6 本章小结	8
3 从前沿 API 转向定制智能的经济学	8
3.1 最强的反方：为什么要离开「自动升级」的模型谱系	8
3.2 可生存性：成本差如何进入毛利	8
3.3 防御性：把独特 workflow 留在自己能控制的系统里	10
3.4 迁移后会不会变差？课堂给出的证据边界	10
3.5 本章小结	10
4 商业模式、后训练闭环与数据信任	10
4.1 从「算力加价」到「每 token 价值」	10
4.2 效用函数：业务方不能外包的责任	11
4.3 从数据、基础模型到线上推理的闭环	11
4.4 「王国的钥匙」：数据托管首先是信任问题	12
4.5 本章小结	13
5 开放模型为何是产业战略变量	13
5.1 Baseten 的两项基础假设	13
5.2 开放生态的地域观察与发布激励	14
5.3 智能成本为什么会上升为产业与国家战略	14
5.4 「多模型世界」与利益位置披露	14
5.5 从地域集中担忧收束到供给多样性	15

5.6	拓展阅读	15
5.7	本章小结	15
6	从芯片到云：推理栈的技术控制面	15
6.1	异构愿景与 NVIDIA 的现实优势	15
6.2	Prefill、decode 与职责分离	16
6.3	运行时生态为什么影响迁移速度	16
6.4	多云聚合：把分散 GPU 变成统一交付面	16
6.5	进入 token path 后，故障就是产品故障	17
6.6	本章小结	17
7	算力稀缺如何推动垂直整合	17
7.1	软件粘性与 GPU 稀缺是两种相反押注	17
7.2	12-15 个月提前期与一组容易误读的报价	18
7.3	从 token 需求到可服务容量	18
7.4	垂直整合先购买确定性，再争取成本优势	18
7.5	为什么讲者认为供给不会「恢复正常」	19
7.6	本章小结	19
8	供给侧创业、政策与持续重置的优化栈	19
8.1	从推理云继续向能源与空间下沉	19
8.2	集装箱类比：标准化可重复部署的算力单元	20
8.3	企业的独特资产必须进入模型与推理闭环	20
8.4	为什么算力期货还没有形成成熟市场	20
8.5	三种反命题：Baseten 的 thesis 怎样失效	20
8.6	开放模型的政策激励与前沿实验室的资本选择	21
8.7	物理模块、虚拟机与软件容器位于不同层	21
8.8	内容性结尾：优化机会遍布全栈，架构也会重置	22
8.9	本章小结	22
9	术语与符号速查	22
9.1	核心术语	22
9.2	符号表	23
9.3	本章小结	24
10	总结与延伸	24
10.1	一条贯穿全课的教学主线	24
10.2	做产品与基础设施决策时可追问什么	24

10.3 仍值得继续研究的开放问题	25
10.4 本章小结	25

阅读说明

这份笔记以完整人工英文字幕、1920×1080 录像画面与 Stanford 课程材料页为来源，重建了视频未提供的章节边界。本文把「讲者在课堂上的估计」、「主持人的问题或推断」与「已核对的术语背景」分开。凡 90 天、70%-90%、30 万亿 token/日、15 万张 B200 等数字，均保留「课堂当时口径」限定，不把它们写成独立审计的行业事实。

课堂中的 open source 常与 open weight 口语混用。为了避免把「可下载权重」误写成「训练数据、代码与许可证全部开放」，正文统一使用「开放模型」，只在确有需要时再区分「开放权重」与「完整开源」。视频中的文字、命令和示例代码只作分析，未被执行。

1 从创业路径到推理云命题

1.1 「推理增长十亿倍」是问题设置，不是预测模型

课程没有从芯片型号或部署框架讲起。主持人先用一句强烈的判断制造问题意识：推理量将增长「十亿倍」，并特意排除了「一千倍」与「一百万倍」(00:00:09-00:00:21)。这句话没有基期、终点、统计口径或估算方法，不应被当作可直接外推的需求预测。

它真正的教学作用，是把注意力从「模型如何训练」移到「训练好的模型如何在线上反复交付价值」。一次语音转文字、一次病历生成或一次代码补全，都会进入线上推理链。当 AI 功能渗入更多 workflow，且单个应用又调用更多模型时，推理就从一项事后运维工作变成产品本身的交付层。

开场命题的正确读法

「十亿倍」在这里表达的是战略方向：如果每个产品都变得更 agentic，而每个任务又需要更多模型调用，推理容量将成为产品和资本的共同瓶颈。它不是带时限的定量预测。

1.2 一条并不笔直的路径

Tuhin 的职业轨迹包含几次明显转向 (00:00:31-00:02:31)。他来自澳大利亚悉尼，大学毕业后先在麦格理银行从事金融工作，后来被派往纽约，参与收费公路和机场私有化相关业务。约两年后，他回到工程和机器学习，在波士顿用传统机器学习追踪神经肌肉疾病的预后，再转往旧金山加入早期科技公司。

讲者口述研究年份时，先说「2012 或 2013」，随即自我修正为「2011、2012」。因此笔记只写「约 2011-2012 年前后」，不用字幕口误推导精确月份。从 2015 年起，他又尝试创办过几家没有走远的公司。这段经历的可复用教训并非「失败终将自动换来成功」，而是金融、研究、工程和早期产品经验，逐步把一个宽泛兴趣收敛成了可长期投入的命题。

1.3 从「机器学习基础设施」收敛到「生产推理」

2019 年，Tuhin 与长期合作的 Phil Howes、Amir Haghighat 等人创办 Baseten (00:02:32-00:03:03)。团队最初的思路是：不押注某一个最终应用，而是为许多应用都需要的基础层提供服务，用讲者的资本市场式表达就是「capture the index」。

随着生成式 AI 的应用扩张，这个命题又从宽泛的「机器学习基础设施」收敛到 production inference：把模型以真实业务可持续调用的方式部署、优化并运行（00:03:03–00:03:22）。客户购买的因而不是抽象的算力，而是性能、可靠性、资源获取与开发体验合在一起的线上交付能力。

1.4 本章小结

主持人的「十亿倍」是未给时限与口径的开场判断，用来提出推理需求可能剧增的问题。Tuhin 的经历则解释了 Baseten 命题如何形成：从金融、医学机器学习、早期产品和多次创业尝试，收敛到 2019 年成立的基础设施公司，再聚焦生产推理。


2 推理如何成为 AI 应用的交付层

2.1 沿一次用户请求观察平台价值

主持人展示了一组与 Baseten 合作的 AI 创业者，但要求 Tuhin 不要停在客户名称，而要解释合作如何改变最终用户的体验（00:03:22–00:04:02）。这个追问建立了正确的分析单位：平台价值不由「用了多少 GPU」单独证明，而要沿着一次真实请求，看模型如何被串联、速度为何重要、失败又会造成什么后果。

Tuhin 选择了两个业务差异很大的案例：面向日常输入体验的 Wispr Flow，以及进入医疗工作流的 Abridge。两者共同说明，现代 AI 产品经常不是「一个输入调用一个模型」；用户看到的一项功能，背后可能是多个专用模型组成的在线链路。

The fastest growing companies use Baseten

Stanford

MS&E 435 | Economics of the AI Supercycle

图 1：讲者幻灯片列示的应用公司集合；标识出现不等于本文独立核验当前合同关系¹

¹ 视频字幕时间来源：00:03:22–00:04:02；实际帧时间：00:03:28。画面未经裁剪或增强。

2.2 Wispr Flow: 延迟就是界面体验

Wispr Flow 被讲者概括为 speech-to-keyboard / speech-to-text 产品：用户说话后，文字尽快出现在光标位置（00:04:20–00:05:19）。讲者以不完全确定的口吻说，链路中大约有 3–4 个语言模型和 2 个音频模型，这些模型由团队自己建立或修改，并运行在 Baseten 上。这是讲者当时的近似介绍，不是一张永久固定的产品架构图。

这个案例的核心不是模型数量，而是端到端目标。用户不关心每个中间模型各自跑得多快，只感受从「开口」到「文字可用」的总等待时间。为了把这个目标写清，可用一个记账式定义表达端到端延迟。该式用来暴露测量边界，不是讲者在课上的推导：

$$L_{e2e} = t_{\text{text}} - t_{\text{speech}}.$$

- L_{e2e} ：用户感知的端到端延迟。- t_{speech} ：本次语音输入开始或进入系统的时刻；具体起点必须由产品定义。- t_{text} ：可用文字出现在界面的时刻；「首字」还是「整段完成」也必须明确。

如果没有统一起止点，不同团队报告的「延迟」就不可直接比较。课程没有给出 Wispr Flow 的毫秒数或测量协议，所以笔记不补造性能数字。

2.3 Abridge: 可靠性嵌入医疗工作流

Abridge 是讲者给出的第二个案例。系统从手术室或诊室里的环境语音开始，先做语音转文字，再经过后续模型处理，生成与电子病历系统（EMR）深度集成的临床记录（00:05:19–00:06:18）。讲者先说「大约 20 个不同模型」，后来又用「几十个」概括；稳妥表述应保留这种近似，而不是把 20 当成永久固定的系统配置。

这个案例把推理平台的约束从「快」扩展为「快且持续可用」。一条医疗记录链包含多次模型调用和外部系统集成，任何环节中断都可能使记录无法按预期进入 EMR。讲者以「我认为每一个模型都运行在 Baseten 上」概括合作深度，这里的缓和语气与时间边界都应保留。他另外称 Abridge 被美国「几乎每个医疗系统」使用；字幕没有给出机构数、合同覆盖或使用强度，因而本文只把它作为讲者的客户范围描述。

为什么多模型链要按用户路径测量

局部模型的峰值性能不等于最终用户体验。排队、冷启动、跨服务传输、某个中间模型或下游系统，都可能成为总延迟与可用性的瓶颈。Wispr Flow 关心「开口到文字可用」，Abridge 则还要关心「语音到可进入 EMR 的临床记录」。

2.4 裸 GPU 不等于推理平台

主持人追问：已有规模的 AI 公司，为什么不直接向 AWS、GCP、Azure，或 CoreWeave、Nebius 等 AI 云采购算力（00:07:02–00:07:30）？Tuhin 的回答可整理为四类能力。其中「多云」在原话里也可视为可靠性与算力获取的一部分，不是四个完全独立的产品模块。

能力	机制	对应用公司的意义
性能优化	让模型和完整链路尽可能快地运行	降低语音输入、临床记录等端到端等待
可靠性与算力保障	容错、韧性运行，并取得足够容量	避免因节点、集群或容量不足而中断 token 交付
多云调度	从多个云和资源来源取得 GPU	降低对单一供应方的依赖，扩大可用容量
开发者平台	提供部署、灵活性、安全与可观测性	让团队管理模型生命周期，而不是从裸 GPU 重建整套推理栈

表 1: 推理平台的四类交付能力（根据课堂口述重组）²

云基础设施首先回答「算力在哪里」；推理云还必须回答模型如何优化、请求如何路由、故障如何切换、团队如何观察和控制线上行为。讲者称，一些客户先尝试直接使用云或新型 AI 云，后来意识到在算力之上自建 inference stack 的成本，才转向 Baseten（00:08:15–00:08:29）。这是他对客户路径的概括，不是经过样本统计的普遍规律。




图 2: 讲者把推理视为 AI-first 经济持续直接成本的市场论点页³

2.5 从交付能力过渡到定制智能

Tuhin 把推理称为 AI 价值被交付的「齿轮」（00:06:18–00:06:31）。他接着称，当时约 90% 或 95% 的推理支出流向前沿模型，约 5% 流向定制模型；主持人后来又在 spend 与 tokens 之间改写分母。所以可靠的结论只是「按讲者的方向性口径，当时工作负载高度集中于前沿模型，定制模型占少数」；不能画一张装作精确的饼图。

²概念来源时间区间：00:07:02–00:08:15。该表为教学性重组，不是视频截图。

³视频字幕时间来源：00:07:27–00:08:29；实际帧时间：00:07:59。页内 2027/2030 金额、增长率与来源标签按讲者幻灯片原样保留，本文未独立核验；该页不是平台四类能力图。

Baseten 的战略判断是，这个结构会改变。应用公司若要成为可盈利、可持续并具防御性的企业，会逐步把工作负载迁向定制模型，而 Baseten 希望成为这些模型的运行平台。这就把问题带到下一章：既然前沿模型还会持续进步，企业为什么要承担迁移到开放模型、后训练和自有推理栈的成本？

比例的分母未稳定

课堂在 90%/95% 与 5% 之间的对比，先用 inference spend，后又被主持人说成 tokens。在画面或额外来源未给出明确分母前，只保留「前沿占绝大多数、定制占少数」的方向性结论。

2.6 本章小结

Wispr Flow 说明交互式产品必须按多模型共同决定的端到端延迟评估；Abridge 说明当模型链进入医疗记录与 EMR，速度之外还必须考虑可靠性和集成。推理平台由此可归纳为性能、可靠性与算力、多云调度、开发者平台四类能力。裸 GPU 只是资源起点，不会自动产生这些系统能力。

3 从前沿 API 转向定制智能的经济学

3.1 最强的反方：为什么要离开「自动升级」的模型谱系

主持人先替应用公司提出了最强反方观点 (00:08:30–00:09:16)：如果选择一个开放模型并自行后训练，就相当于从持续进步的前沿模型谱系上分叉。团队刚完成数据准备、训练、评测和部署，下一代前沿模型可能已经在通用能力上超过它。继续调用前沿 API 则像一条「几乎不用额外工作」且会自动升级的路径。

决策冲突 (00:08:43–00:09:16)

主持人 (意译)：如果下一代前沿模型会自动变强，为什么还要花力气从这条谱系分叉？

Tuhin (要点)：要同时看企业能否生存，以及企业能否保留自己的智能与数据控制权。

这个问题揭示了定制智能的真正机会成本。迁移不只是更换模型名称，还包含数据治理、后训练、评测门禁、上线、监控和回滚。因此，「开放模型更便宜」不能独自完成论证；还要问质量差距有多大、专用任务收益有多高，以及何种规模才足以摊薄迁移的固定成本。

3.2 可生存性：成本差如何进入毛利

Tuhin 首先给出 viability reason：企业能否建立可持续的单位经济 (00:09:16–00:10:35)。按他的课堂估计，当时开放模型与前沿模型的能力时间差约为 90 天，推理成本可能低 70%–90%。再叠加面向具体任务的后训练，他认为企业有机会在某个业务效用函数上做到更好、更快、更便宜。这里的「更好」应指专用任务，不是在所有通用基准上超越最强前沿模型。




图 3: 后训练开放模型的成本与能力论点页；数字属于讲者幻灯片口径⁴

为了把 70%–90% 的说法改写为可检查的成本关系，可先忽略训练、迁移、评测和人力成本，仅比较可比较工作负载的直接推理成本：

$$C_{\text{open}} \approx (1 - S_{\text{open}})C_{\text{frontier}}, \quad S_{\text{open}} \in [0.70, 0.90].$$

- C_{open} ：在可比较质量、延迟与工作负载下，开放/后训练模型的推理直接成本。- C_{frontier} ：同一口径下调用前沿模型的成本。- S_{open} ：讲者估计的节省比例，取 0.70–0.90。

它只表明：在上述限定都成立时，剩余直接推理成本约为前沿 API 基准的 10%–30%。如果把后训练、数据治理、评测、运维和团队人力纳入总拥有成本，实际节省可能不同。

产品规模为什么改变选择？早期团队先证明有人愿意使用产品；当请求量开始快速增长，上游 token 成本会同时被放大。为了说明这个约束，可用通用毛利率关系把讲者的经营论点写清：

$$GM = \frac{R - C_{\text{direct}}}{R}.$$

- GM ：毛利率。- R ：同一周期内的收入。- C_{direct} ：为交付该收入直接发生的成本；在这段语境中主要关注模型 API 或推理算力。

如果产品售价不变，而每次请求持续调用高价上游模型，请求量会同时放大 R 和 C_{direct} 。业务质量由二者的相对增速决定，而不是由请求量单独决定。Tuhin 因而把规模越大的迁移称为越关乎「生存」(00:12:29–00:13:05)。主持人随后引用某些头部编程产品负毛利的市场传闻；字幕没有提供财务数据，因而本文不把这项推测当作公司事实。

⁴视频字幕时间来源：00:09:43–00:10:18；实际帧时间：00:10:03。主标题的「成本为 30%」与 Kimi 示例的「降低 70%」一致；不能据此把口述的 70%–90% 节省全部视为画面已证明。

3.3 防御性：把独特 workflows 留在自己能控制的系统里

Tuhin 称第二条理由更「cynical」(00:10:35–00:11:50)。应用公司真正难以复制的资产，往往是独有 workflows、用户行为信号以及由此形成的反馈。如果企业始终只依赖前沿实验室，就需要认真判断：自身数据和反馈如何流向供应商，供应商是否可能沿同一 workflows 训练，企业最终还能控制哪一层差异化。

讲者转述一位未具名上市公司 CEO 的比喻，把前沿实验室比作东印度公司。该比喻表达的是对权力和信息不对称的担忧，不证明任何具体实验室已经违反客户数据条款。真实数据用途取决于产品条款、企业协议、保留策略和技术隔离。

「拥有自己的智能」也不意味着每家企业都要从零预训练基础模型。在这堂课里，它更接近三件事：选择可控制的开放模型；用自身数据和业务反馈做后训练；掌握部署与推理栈，使模型改进不完全受单一前沿供应商的节奏支配。




图 4: 「拥有自己的智能」的可操作含义（教学重绘）⁵

3.4 迁移后会不会变差？课堂给出的证据边界

主持人以 Cursor、前沿模型与 Composer 为例追问：换成后训练模型后，用户会不会感到性能下降？是否可以只迁移部分工作负载 (00:13:27–00:13:58)？Tuhin 明确说 Baseten 内部没有相关数据 (00:13:58–00:14:06)。他表达的是期望：真实用户信号可能让专用任务质量变好，更多系统控制权也可能改善延迟与可靠性。

成本下降不等于产品体验已被证明改善

迁移至少要分开验收三类指标：专用任务的质量/效用，端到端延迟，以及可用性、错误率与恢复能力。讲者明确说「没有内部数据」，所以正文只能写「可能」「期望」或「有机会」。

3.5 本章小结

从前沿 API 转向定制智能，有两条相互补充的经济理由。第一条是可生存性：当推理成本成为重要直接服务成本，规模会放大单位成本差并直接影响毛利。第二条是防御性：企业希望把独特 workflows、数据与用户反馈沉淀在可控制的模型和推理栈里。两条理由都不能略过验证：成本数字是课堂估计，性能改善则没有内部数据。

4 商业模式、后训练闭环与数据信任

4.1 从「算力加价」到「每 token 价值」

主持人把问题从客户经济转向 Baseten 自己的计价方式，列举结果计价、token 计价和 GPU 小时计价 (00:14:26–00:14:49)。Tuhin 对当时模式的描述很直接：Baseten 主要在底层算力成本上加价。

⁵概念来源时间区间：00:10:35–00:11:50 与 00:16:38–00:18:28。该图为跨章教学综合，不是视频截图。

客户带来模型，平台把它装载到推理栈，客户选择运行所需算力；差价原则上对应部署、优化和运维价值（00:14:49–00:15:31）。

为了理解这个模式，可做一个不代表正式价格表的商业抽象：

$$P_{\text{platform}} \approx C_{\text{compute}}(1 + M).$$

- P_{platform} ：客户为平台化算力支付的价格。- C_{compute} ：底层原始算力成本。- M ：平台相对原始算力的加价率；课堂未给数值。- $\approx$ ：表明这只是根据口述做的示意，不是 Baseten 公布的报价公式。

GPU 小时并不是客户最终创造价值的单位。客户更关心的是：每交付一个可用 token、完成一个任务或服务一次用户请求，需要付出多少成本。Tuhin 说 Baseten 已对部分客户使用 token 计价，也坦言当时还「相对不成熟」（00:15:31–00:15:54）。这一转变使价格更容易与 Anthropic、OpenAI API 的账单比较，也把更高硬件利用率、更好批处理与更少冗余计算的责任向平台上推。

计价单位会改变优化方向

GPU 小时计价强调资源占用；token 计价更靠近模型输出；结果计价更靠近最终业务价值。计价层级越靠近结果，供应方通常承担越多性能、效率与可靠性责任。本课只确认 Baseten 当时正从算力加价探索 token 计价，不声称商业模式迁移已完成。

4.2 效用函数：业务方不能外包的责任

「后训练 workflow」容易被误解为平台替客户按一个训练按钮。Tuhin 先划定责任边界：客户必须决定自己的 utility function，即模型究竟要优化什么（00:16:38–00:17:04）。平台不了解客户的产品、用户与业务目标，无法替客户定义成功。数据本身也不会自动说明哪种输出更有价值。

为了把「业务方定义成功」写成一个清晰的数学目标，可使用下面的教学抽象：

$$\theta^* = \arg \max_{\theta} U(\theta; D).$$

- θ ：候选模型的参数或可调整状态。- θ^* ：在给定目标下选出的模型。- D ：企业提供的训练、偏好或评价数据。- $U(\theta; D)$ ：业务方定义的效用函数，用来评价模型是否真正有用。- $\arg \max$ ：寻找使效用最大的模型；若业务定义的是错误率，也可等价写成最小化损失。

这不是讲者展示的公式，而是责任边界的形式化：平台可以提供训练脚手架与运行系统，却不能替产品团队决定 U 。效用函数定义错了，训练越高效，只会更快逼近错误目标。

4.3 从数据、基础模型到线上推理的闭环

在效用函数明确后，课堂给出的 workflow 可分为四步（00:17:04–00:18:28）：业务方定义效用函数；提供真实 workflow 和用户反馈形成的数据；选择一个开放基础模型；平台完成后训练脚手架，并把专用模型接回线上推理。字幕在 00:17:13–00:17:16 把输出识别成 pre-trained model，但前后一直讨论 post-training，所以正文采用「后训练后的专用模型」，并把该处保留为 ASR 复核点。

Tuhin 用医疗语音转写让闭环变得具体：如果企业希望减少医疗场景的转写错误，就定义错误指标，提供相应数据并选择基础模型，再让平台执行后训练与上线。两处基础模型名在字幕中不可辨，本文不根据「语音转写」常识自行补成 Whisper。

The Baseten Platform




图 5: 讲者展示的 Baseten 平台分层：入口、推理栈、运维能力与多云容量管理⁶




图 6: 从业务目标到线上推理的后训练闭环（教学重绘）⁷

4.4 「王国的钥匙」：数据托管首先是信任问题

当企业把数据、模型和工作流交给同一平台时，讨论自然从效率转向信任。主持人把这些数据称为「王国的钥匙」，并用 East India Company 开玩笑；Tuhin 回应 Baseten 是「West India Company」，是在「为反抗者提供武器」（00:18:28–00:18:49）。玩笑的实质，是推理平台同时接触了客户最敏感的三类资产：专有数据、专用模型与真实请求路径。

Tuhin 说客户通常接受这种安排，理由包括既有客户记录和品牌信誉，以及公司内部「非常严格」的安全姿态（00:18:51–00:19:07）。平台可能同时服务互为竞争对手的公司，他声称 Baseten 有内部边界防止资产泄漏（00:19:07–00:19:22）。这是公司自述，字幕没有提供隔离架构、认证、审计、数据保留或事故记录，不能被升级为独立验证的安全保证。

⁶视频字幕时间来源：00:16:30–00:17:29；实际帧时间：00:16:58。图中「10+ clouds」是该页产品口径，不能与后文口述的「约 20 个云、87 个集群」合并为同一指标；画面也没有展示完整的效用函数与数据反馈闭环。

⁷概念来源时间区间：00:16:38–00:18:28。该图为教学重绘，对字幕未展开的评测和迭代环节作了显式标记。

客户真正交换的是什么？在 00:19:23–00:19:49，讲者把它概括为：企业用数据托管与供应商依赖，换取更快的模型迭代和上线速度。真正的采购尽调因而必须逐项追问：租户之间怎样隔离？员工访问怎样授权与审计？训练产物与日志归谁？数据保存多久？删除、迁移和退出怎样完成？

一个玩笑引出的信任成本（00:18:28–00:18:49）

主持人（意译）：客户把所有数据——「王国的钥匙」——都交给你们。

Tuhin（意译）：我们想为那些反抗者提供武器。

这段对话提供了公司自我定位，但它不是数据隔离的技术证据。

4.5 本章小结

Baseten 当时主要在底层算力上加价，用软件栈与运维能力解释差价，同时开始探索更易与前沿 API 比较的 token 计价。更上层的价值是闭环：业务方定义效用函数、提供数据并选择基础模型，平台承接后训练脚手架与推理部署。这个分工能把企业 workflow 沉淀为专用模型，也把平台推到敏感资产中心；安全与退出机制因而不能被品牌口号替代。

5 开放模型为何是产业战略变量

5.1 Baseten 的两项基础假设

后训练闭环能否成立，不只取决于 Baseten 的执行能力。主持人指出，开放模型必须持续接近前沿，但开放模型实验室的经济模式仍未确定（00:19:51–00:20:33）。Tuhin 随后把 Baseten 的公司命题压缩为两项「大赌注」（00:20:35–00:20:45）：

1. **独立应用层会继续存在。**用户价值不会全部被少数前沿实验室的自有产品吸收，仍会有大量公司围绕行业与 workflow 构建应用。
2. **开放模型会足够好。**它们不必在每项通用基准上永远领先，但必须好到可以用企业数据和效用函数做后训练。

如果开放模型长期不足，企业就只能依赖闭源前沿 API；如果前沿实验室又垂直整合并占据应用层，独立推理平台就会被两面压缩。




图 7: 独立推理平台需要同时成立的三项外部条件（教学综合）

* 时间来源：00:19:51–00:20:45、00:36:42–00:37:12 与 00:44:22–00:45:03。该图为跨章综合，不是视频截帧。

5.2 开放生态的地域观察与发布激励

Tuhin 在特定课堂时点给出一个鲜明判断：按他的观察，过去约两年最好的开放模型来自中国（00:20:45–00:20:58）。字幕没有定义「最好」的基准，也没有给评测数据，因而这只能被写成讲者的当时产业判断，不是超越时间与指标的客观排名。

他把美国供给不足归因于人才与激励：最优秀的研究者集中在极少数机构，而这些机构即使名字听起来可能暗示「开放」，也缺乏发布开放模型的商业动机（00:21:00–00:21:19）。相对地，非美国团队可能用开放路线争取相关性和市场位置。字幕提到 Moonshot、Alibaba、MiniMax 等名称，但句子有明显缺词，本文只保留「开放发布也可是市场进入策略」的谨慎概括。

开放发布未必直接从每次 token 调用收费，却可以服务云、硬件、生态、人才吸引或战略影响力。课堂没有逐一证明所列公司的回报模式，所以这些只能作为分析框架，不应被写成具体公司已承认的动机。

5.3 智能成本为什么会上升为产业与国家战略

Tuhin 认为，如果一个地区没有足够好的开放模型，而另一个地区的智能部署成本低 70%–90%，后果会超越单个企业的毛利，影响创业门槛、研究扩散速度、产业采用密度与对少数供应商的议价能力（00:22:00–00:22:19）。他由此把开放模型提升为某种国家安全问题。这里的 70%–90% 延续前文课堂估计，不是跨国价格统计。

在 00:22:20–00:22:46，他还列举 Google Gemma、NVIDIA Nemotron，以及对 Reflection AI 未来开放模型的期待。对未来发布的表述是愿望或预测，不是已发生事实。他担忧如果十年后仍没有好的美国开放模型，将形成不利局面；但又相信当时的投入足以推动变化。这是讲者的长期判断，不是确定预测。

5.4 「多模型世界」与利益位置披露

课堂还即时讨论了 Anthropic 当天发布的一篇文章。证据层级必须保持清楚：主持人明说自己刚起床、还没有细读，随后把文章概括为两个地缘政治情景（00:23:08–00:23:53）。课堂没有给出标题、原文段落与完整论证，所以本文不把主持人的即兴总结写成 Anthropic 的正式立场。

Tuhin 在肯定 Anthropic 能力的同时提出一条分析原则：提出政策主张时，应说清自身的偏见与激励函数（00:23:55–00:24:10）。他引用 Baseten 前一天关于「多模型世界」的文章，反对智能和道德裁决权由两个人或极少数主体拥有（00:24:13–00:24:36）。这是规范性与政治经济判断，不是仅靠字幕就能证明的经验事实。同时，Baseten 自身也会从多模型、开放模型和独立应用层中获益，因而同样应接受这条原则的审视。

转述不等于原文

00:23:08–00:23:53 的 Anthropic 文章描述来自主持人即兴概括，且他明确说尚未完整阅读。在未对照原文前，不应为该文章安上确定标题、逐字观点或政策结论。

5.5 从地域集中担忧收束到供给多样性

Tuhin 最后澄清，他的担忧并不是不信任中国团队，而是美国也应拥有优秀开放模型（00:24:41–00:25:01）。主持人问美国在人才、资源、资本与 GPU 方面的速度是上升还是下降。Tuhin 判断，直到约一年前都明显下降，但当时已看到回升（00:25:03–00:25:28）。这仍是特定时点的课堂判断，不应在未来无限期延用。

本章稳妥的收束不是「某一阵营必然胜出」，而是开放模型的质量、部署成本、发布激励与供给多样性，会直接决定独立应用与推理平台的战略空间。

5.6 拓展阅读

- [Baseten CEO Tuhin Srivastava on Custom Models, and Building the Inference Cloud](#): Stanford 材料页列出的延伸访谈。
- [AI inference explained: The hidden process behind every prediction](#): 用于补充 TTFT、吞吐、成本、prefill/decode 等基础术语，不替代本课时间轴证据。

5.7 本章小结

Baseten 的后训练与推理云模式依赖两个产业条件：独立应用企业继续存在，开放模型也持续好到足以被企业定制。讲者把开放模型同时看成市场进入策略、降低智能成本的工具和国家产业能力。围绕 Anthropic 文章的讨论进一步暴露了利益激励与权力集中问题，但其政策内容主要来自主持人的即时转述，不能代替原文核查。

6 从芯片到云：推理栈的技术控制面

6.1 异构愿景与 NVIDIA 的现实优势

主持人沿着云与供应商地图继续向下追问：除了占主流的 NVIDIA、TPU、Trainium 和新型推理芯片会不会形成真正的异构生态？Tuhin 的回答包含两个时间尺度（00:26:38–00:27:51）。长期看，既然模型会多样化，执行模型的硬件也不必永远只有一种；但在 Baseten 当时接触到的工作负载中，绝大部分仍运行在 NVIDIA GPU 上，他尚未观察到客户大规模采用 Trainium。

这不是单卡峰值性能的简单胜负。Tuhin 把 NVIDIA 的现状优势归结为一组互相增强的条件：成熟的供应链与资本能力、同晶圆制造环节的关系，以及围绕 CUDA 形成的开发者、kernel 和运行时生态。对于必须尽快把客户模型送上线的平台，「硬件取得到、工具已经成熟、工程师马上能用」往往比理论上的最优架构更重要。

因此，Baseten 当前围绕 NVIDIA 优化，是以交付速度为目标的经营选择；它既不证明 TPU 或专用芯片没有潜力，也不保证 CUDA 路径永久不可替代。

短期集中与长期异构并不矛盾

短期选择由供应链、软件生态和上线速度共同决定；长期架构则可能把不同阶段交给不同硬件。不要把「当前主要使用 NVIDIA」改写成「推理永远只能使用 NVIDIA」。

6.2 Prefill、decode 与职责分离

Tuhin 随后把生成式推理拆成 prefill 与 decode (00:27:51–00:28:41)。prefill 先处理输入上下文，decode 再逐步生成后续 token。教学上最重要的不是背诵两个名称，而是意识到一次请求并非均匀的计算任务：不同阶段可能有不同的计算强度、内存访问和调度特征，因此可以被独立扩缩容，甚至映射到不同硬件。

这也解释了 disaggregated inference 的动机：平台不必寻找一块在所有阶段都最优的「全能芯片」，而可以把职责拆开，再依据实际瓶颈组合资源。不过，课堂字幕没有清楚给出 memory-bound、compute-bound 与 prefill、decode 的逐一硬件映射，本文不补造该映射。

字幕在 00:28:13–00:28:19 出现「NVIDIA acquired Grok」，专名和动词都不可信。结合当前官方记录，可确认的是 NVIDIA 与 Groq 的非独占授权安排，而不是课堂字幕所写的收购；这一处只保留「推理职责可能被分离」的论点，不用错误专名支撑架构结论。

6.3 运行时生态为什么影响迁移速度

讲者随后列举 TensorRT-LLM、vLLM 与 SGLang (00:28:41–00:29:21)。课堂没有比较三者的完整功能，而是借它们说明：成熟推理路径不仅需要芯片，还需要模型兼容、kernel、调度、监控和工程人才。TensorRT-LLM 直接服务 NVIDIA 路径；vLLM 与 SGLang 虽是开源项目，在讲者当时的观察中也首先围绕 NVIDIA 形成了成熟实践。

于是，硬件迁移的真实成本不只是替换采购清单。即使另一种芯片在某个算子上更快，平台仍要重新验证运行时、模型支持、故障处理、性能回归与团队技能。这里的路径依赖是工程摩擦，不是技术宿命。

6.4 多云聚合：把分散 GPU 变成统一交付面

向上一层看，Baseten 面对的是散落在不同云和集群中的 GPU。Tuhin 先说公司运行在 18 个云之上，随即修正为「现在大约 20 个」，并称资源分布在 87 个集群中 (00:29:57–00:30:20)。因此本文采用「约 20 个云、87 个集群」，同时标明这是讲者当时口径，且课堂没有给出集群定义。

平台把这些资源拼接到统一控制面，再向客户隐藏底层供应商、位置、部署和故障切换 (00:30:20–00:30:53)。所谓 GPU 可替代性，是平台层的交付抽象；它不表示不同型号、网络或集群在性能上完全相同。多云首先扩大了可采购范围，也降低了被单一供应商报价或交付能力锁住的风险。




图 8: 推理平台把异构基础资源逐层转化为稳定产品接口（教学重绘）⁸

6.5 进入 token path 后，故障就是产品故障

云厂商也会在 GPU 之上建设自己的推理平台，Tuhin 并不否认这种竞争合理，甚至愿意同潜在竞争者合作（00:30:56–00:31:22）。他的防御性论证更接近数据库类比：一旦关键系统承载业务增长，迁移就会牵动部署、延迟、伸缩、监控与恢复机制。

推理的耦合甚至更直接。一旦服务进入 token path，推理中断就意味着产品功能中断（00:31:22–00:32:19）。因此，裸 GPU 可能逐渐商品化，可靠运行在其上的交付层却仍可能具有粘性。这种粘性不是靠合同措辞自动产生，而来自长期积累的可靠性与迁移成本。

6.6 本章小结

推理平台的技术控制面横跨芯片、执行阶段、运行时、多云资源和产品服务目标。长期异构化与短期 NVIDIA 集中可以同时成立；多云也不是把不同 GPU 变成同一块芯片，而是把分散供给组织成客户可依赖的 token 交付路径。平台真正需要守住的边界，是底层持续变化时，上层请求仍能稳定完成。

7 算力稀缺如何推动垂直整合

7.1 软件粘性与 GPU 稀缺是两种相反押注

Baseten 早期选择租赁算力，因为团队认为软件才是推理栈中更有粘性的部分；云厂商则可能相信，只要掌握稀缺 GPU，软件最终可以补齐（00:32:19–00:33:23）。Tuhin 承认双方都可能过度自信：云厂商会低估推理软件的复杂度，软件公司也不能把建设和经营物理基础设施想得过于简单。

租赁减少了前期资本负担，让团队先把产品做出来。但当算力从一般投入品变成限制增长的资源时，「租还是买」就不再只是单价问题，而首先是能否按时取得容量的问题。

⁸概念来源时间区间：00:26:38–00:32:19。层次名称为教学综合，不代表 Baseten 公布的固定产品架构。

7.2 12–15 个月提前期与一组容易误读的报价

Tuhin 用两个例子描述供给紧张 (00:33:23–00:34:51)。如果当时提出需要 1,000 张 GPU, 供应商可能只能讨论下一年第二季度交付, 约为 12–15 个月后。Baseten 另有一个未披露规模的 B200 Blackwell 集群, 课堂记录的现价为每小时 263 美元, 续约报价则升到每小时 510 美元。

263 美元与 510 美元都不是单卡小时价

讲者描述的是一个未披露规模集群的小时报价。课堂也没有给出合同期限、利用率、网络和服务范围, 因此这些数字只适合说明同一资源续约时的相对涨价。

多云能让 Baseten 拒绝单一供应商的不利报价, 却不能凭空创造新的芯片。它改善的是采购面、议价和局部容错; 整体供给不足时, 长期容量仍可能要求公司直接持有设备。

7.3 从 token 需求到可服务容量

讲者给出了一组支持垂直整合的规模数字 (00:34:53–00:36:07): 当时每天约处理 30 万亿 token; 按业务外推, 两年后可能需要约 15 万张 B200 等价算力; 主持人要求换算后, 他粗略估计约为 70 亿美元算力支出。他还比较了 OpenAI API 与 Gemini, 但没有提供统一统计口径。所有这些都是公司自报或讲者预测, 不是独立审计的行业排名。

可以用一个容量上限公式说明为什么需求增长会被硬件数量和效率共同截断。该式是教学框架, 不是讲者给出的正式模型:

$$Q_{\text{servable}} = \min(Q_{\text{demand}}, GU R_{\text{tok}} \Delta t).$$

- Q_{servable} : 在共同时间窗 Δt 内, 平台实际能够服务的 token 量。- Q_{demand} : 同一时间窗内, 客户产生的 token 需求量。- G : 可用 GPU 或等价加速器数量。- U : 综合利用率, 包含排队、故障和调度损耗后的有效比例。- R_{tok} : 单设备在目标工作负载下的有效 token 吞吐率。- Δt : 需求量与可服务量共同采用的时间窗长度。

增加设备数量只是一个杠杆; 运行时优化可以提高 R_{tok} , 调度和多租户治理可以提高 U 。但如果 G 因长期交付期被卡住, 软件优化无法无限补偿物理供给。

7.4 垂直整合先购买确定性, 再争取成本优势

Tuhin 判断, 完全依赖租赁不太可能取得未来所需资源 (00:36:08–00:36:42)。直接采购和部署算力, 第一项收益是供给确定性; 第二项才是讲者估计的约 30% 成本优势。他用成熟云厂商约 30% 毛利作直觉参照, 但这不是 Baseten 自建项目的审计结果。

租赁价格不能直接同芯片采购价比较。持有算力的完整成本至少包含:

$$C_{\text{own}} = C_{\text{capex}} + C_{\text{power}} + C_{\text{ops}} + C_{\text{capital}} + C_{\text{obsolescence}}.$$

- C_{own} : 持有并运营算力的总成本。- C_{capex} : 芯片、服务器、网络与基础设施投入。- C_{power} : 电力与冷却成本。- C_{ops} : 部署、运维和人员成本。- C_{capital} : 融资与资本占用成本。- $C_{\text{obsolescence}}$: 硬件迭代、闲置和残值风险。

这意味着公司的风险边界会改变：轻资产软件平台加入资本支出、建设周期、利用率与技术折旧。垂直整合是用更多资产风险换取容量控制和潜在成本优势，而不是无条件的利润捷径。

7.5 为什么讲者认为供给不会「恢复正常」

当主持人问短缺是一两年现象还是长期状态时，Tuhin 的回答非常强烈：「我认为它永远不会正常化」（00:37:31–00:39:17）。他的理由有两条：应用越来越 agentic，一个用户任务触发更多模型调用；模型本身也可能变大，使每次调用消耗更多资源。

他用机场排队作类比：单个机场有清晨低谷和繁忙高峰，但全球推理没有统一关门时间。一个地区进入低谷时，另一个时区可能正处于高峰。




图 9: 跨时区需求接力使全球容量缺少统一「重置时刻」（教学重绘）⁹

效率提升、专用芯片、需求弹性和能源约束都可能改变这一情景，所以「永不正常化」不能当作确定预测。它更像 Baseten 的战略压力测试：公司不能把未来重新供过于求当作默认前提。

7.6 本章小结

Baseten 从租赁走向部分自有算力，首先是容量保障决策，其次才是成本决策。约 20 个云能扩大采购面，却不能消除总供给约束；30 万亿 token/日、15 万张 B200 等价算力和 70 亿美元则是讲者当时的自报与预测。垂直整合提高了控制力，也把一家推理软件公司的风险扩展到重资产、能源和资本结构。

8 供给侧创业、政策与持续重置的优化栈

8.1 从推理云继续向能源与空间下沉

如果今天不做 Baseten，Tuhin 最想创办什么公司？他的答案没有落在另一个 AI 应用，而是更接近 Crusoe 的路线：投资能源、电力以及承载大规模算力所需的空間（00:39:17–00:39:53）。这不是投资建议，而是由前文供给约束推导出的个人创业判断。

软件平台可以聚合已有 GPU；当总资源不足时，问题会继续向下传导到电力、土地、机房和建设速度。推理云的边界于是从 API 与运行时，扩展到「新增一块可用算力究竟怎样被生产」。

⁹概念来源时间区间：00:37:56–00:39:17。该图表达讲者的长期情景，不是经过需求数据拟合的负载曲线。

8.2 集装箱类比：标准化可重复部署的算力单元

Tuhin 用港口集装箱引出模块化数据中心 (00:39:56–00:41:04)。集装箱的价值不在于货物相同，而在于装卸、运输和服务体系可以依赖一致的单元。他希望把这种工业化逻辑迁移到算力：形成共享、稳定的 compute unit 格式，使不同地点能够重复建设和维护；主持人把它概括成「为算力创建 API」。

课堂没有给出模块的尺寸、功耗、冷却、网络或接口规范，所以本文不把设想写成已经完成的行业标准。其定性机制可以表示为：

$$S_{\text{unit}} \uparrow \implies H_{\text{site}} \downarrow \implies T_{\text{deploy}}, C_{\text{service}} \text{ 有机会下降.}$$

- S_{unit} ：算力单元及接口的标准化程度。- H_{site} ：不同数据中心项目之间的实现异质性。- T_{deploy} ：新增算力从建设到可用的部署时间。- C_{service} ：部署后维护与服务成本。

箭头表达讲者的工业化直觉，不是已证实的单调因果；过度统一也可能牺牲对场地、芯片和散热条件的适配。

8.3 企业的独特资产必须进入模型与推理闭环

在「long / short」问答中，Tuhin 不愿点名批评具体公司，却明确担忧停止创新的企业 (00:41:04–00:42:01)。正面路径是找出企业独有的东西，把它与预训练模型结合，再真正运行推理。结合全课主线，这些独特资产可以是数据、工作流、用户反馈与专业判断；但这是跨章综合，不是该句逐字枚举。

只持有数据而不把它反馈进效用函数、后训练和线上请求，资产不会自动变成产品能力；只调用一个通用模型、又没有独特闭环，差异也容易被复制。讲者随后鼓励学生学习自己真正感兴趣的东西，并以「六个月成为任何领域的专家」激励快速学习 (00:42:01–00:42:32)。这是一句口语化鼓励，不是学习周期保证。他自己当时正在研究数据中心 project finance (00:42:32–00:42:55)，说明金融结构也会成为算力扩张的一部分。

8.4 为什么算力期货还没有形成成熟市场

一个很短的学生问题提到 futures。结合回答可知，讨论对象是算力期货或远期交易，但课堂没有给出具体合约 (00:43:01–00:44:11)。Tuhin 把当时采购形容为依赖人脉的双边市场：办公室里有人整天打电话寻找算力。讲者认为市场终会形成，但当时不透明、摩擦大；主持人用 slippage 概括意向价格、合同条件与最终可交付资源之间的偏差。

标准化算力单元可能帮助交易双方定义标的，却不会自动解决定价、清算、信用和履约。期货至少要说清未来交付的时间、地点、硬件与服务质量；如果名义上相同的「GPU 小时」对应完全不同的网络、运行时和可用性承诺，就难以成为真正可替代的商品。

8.5 三种反命题：Baseten 的 thesis 怎样失效

学生随后询问 Baseten thesis 的反命题。问题中有不可辨内容；在 00:44:22–00:45:03，Tuhin 清楚列出三项回答：

反命题	被破坏的前提	对独立推理平台的影响
算力被极少数主体完全控制	多个主体可以取得并组合供给	软件平台无法取得资源,或被资源所有者垂直吞并
优质开放模型不再持续出现	企业能取得并定制有竞争力的基础模型	后训练失去可用起点,工作负载回到少数闭源前沿 API
把强 AGI 命题推到极端,独立应用「无事可做」	多样化业务工作流与应用公司继续存在	应用层市场被极端情景消解;讲者随后以玩笑语气说或许只剩推理

表 2: 讲者用于压力测试 Baseten thesis 的三种反命题¹⁰

8.6 开放模型的政策激励与前沿实验室的资本选择

下一位学生问政府是否应为开放模型创造额外激励。Tuhin 支持政府参与与自上而下的激励,并称美国政府及 NVIDIA、Microsoft、Google 已开始投入 (00:45:03–00:46:11)。课堂没有列出项目、预算、许可证或政策文件,所以只能把它写成讲者观察。

主持人随后称「两天前中国政府投资了 DeepSeek」(00:46:11–00:46:18)。这句话缺少精确录像日期、投资主体、形式与金额,本文不把它当作已核验新闻。政策讨论还必须先区分开放权重与完整开源,否则「激励开放模型」没有清楚对象。

另一位学生提出竞争威胁: 前沿实验室为何不开放一款稍落后但仍很好的模型,再进入企业数据与后训练市场? Tuhin 承认它们已经在一定程度上这样做; 他的解释是条件性的: 如果一家实验室真正把 AGI 视为首要目标, 边际资本就更可能投向预训练和能力边界, 而不是分散到企业后训练与长期实施 (00:46:21–00:47:26)。

预训练与后训练争夺的是同一笔边际资本

预训练追求通用能力上限; 后训练围绕既有基础模型适配具体效用函数; 企业交付还增加数据治理、实施和长期运行。讲者分析的是资源配置激励, 不是 OpenAI 或 Anthropic 公布的预算规则, 也不意味着它们不会参与后训练。

8.7 物理模块、虚拟机与软件容器位于不同层

学生问模块化数据中心与虚拟机有何不同。Tuhin 的回答是层次不同 (00:47:27–00:48:11): 模块化数据中心先解决更便宜、更快地建设物理算力; 虚拟机与软件容器在硬件已经存在后, 负责隔离和抽象工作负载。课堂口语把两个 container 含义切换得很快, 本文分别称「物理模块」和「软件容器」。

¹⁰ 回答来源时间区间: 00:44:22–00:45:03。三项是压力测试, 不代表概率相同, 也不是完备风险清单。




图 10: 模块化数据中心与虚拟机解决不同抽象层的问题（教学重绘）¹¹

8.8 内容性结尾：优化机会遍布全栈，架构也会重置

最后一个学生问题大段不可辨，因此只能依据 Tuhin 清楚的回答：机会「到处都有」。他列举 disaggregated inference 与底层 kernel，并提到 ThunderKittens 相关工作（00:48:25–00:48:42）。前者重组系统职责，后者提高具体算子在硬件上的执行效率；课堂没有给性能数字，本文不补造加速比。

真正的结尾判断是「整个栈都在变化」。Tuhin 把市场比作流沙：新模型架构可能让今天积累的优化重新洗牌（00:48:42–00:49:04）。他以 Ilya Sutskever 也许带来新架构作为假设例子，并未披露可核验消息。这一段可以压缩成一条设计原则：**对外交付边界尽可能标准化，对内实现保持可替换。**

00:49:04 之后只有致谢与掌声，没有新的实质教学内容。因此，本课的内容性结尾应停在「架构变化会让优化重新开放竞争」，而不是例行告别。

8.9 本章小结

本章把推理云从软件继续推到能源、数据中心、项目金融、交易市场和政策。模块化的目标是降低物理建设异质性，算力期货则还需要标准标的、透明定价与履约机制；企业要把独特资产送入后训练和线上推理，政策则要面对开放模型的社会价值与企业回报错位。与此同时，disaggregated inference、kernel 和新模型架构仍会持续重置优化栈，稳定边界与可替换实现必须同时设计。

9 术语与符号速查

9.1 核心术语

¹¹概念来源时间区间：00:39:59–00:41:04 与 00:47:27–00:48:11。层次图用于消除物理 container 与软件 container 的歧义，不代表固定的「两层」标准。

术语	本文中的含义
Production inference	把训练好的模型以可持续、可观测、可伸缩且可靠的方式交付到真实产品请求中。
Token path	一次产品请求经过模型服务并产生 token 的关键交付链；其中断会直接中断产品能力。
Prefill / decode	生成式推理中处理输入上下文与逐步生成后续 token 的两个阶段。
Disaggregated inference	把资源特征不同的推理阶段或职责拆开部署和调度；本文不假设唯一硬件映射。
Post-training	围绕具体效用函数、企业数据或反馈，对基础模型做适配、评测和改进的过程。
Open model	本文对课堂宽泛说法的统称；不自动等于训练数据、代码、许可证都开放。
Multi-cloud	平台聚合多个云与集群，并把供应商选择、位置和故障切换封装在统一交付面后。
Modular data center	以可重复部署的物理算力单元降低项目差异；与虚拟机或软件容器不是同一抽象层。
Project finance	围绕长期资产现金流、建设和风险安排资本的融资方式；课堂只把它作为值得学习的方向。

9.2 符号表

符号	含义与使用位置
L_{e2e}	用户感知的端到端延迟；第二章。
$t_{\text{text}}, t_{\text{speech}}$	文字可用与语音进入系统的时刻；第二章。
$C_{\text{open}}, C_{\text{frontier}}, S_{\text{open}}$	开放/后训练路径成本、前沿 API 成本与讲者估计的节省比例；第三章。
GM, R, C_{direct}	毛利率、收入与直接服务成本；第三章。
$P_{\text{platform}}, C_{\text{compute}}, M$	平台价格、底层算力成本与加价率；第四章。
$\theta, \theta^*, D, U(\theta; D)$	候选模型、最优模型、企业数据与业务效用函数；第四章。
$Q_{\text{servable}}, Q_{\text{demand}}$	实际可服务 token 量与客户需求；第七章。
$G, U, R_{\text{tok}}, \Delta t$	可用加速器数量、综合利用率、单设备有效 token 吞吐率与共同时间窗；这里的 U 与效用函数不是同一变量；第七章。
C_{own}	持有并运营算力的总成本；第七章。
$C_{\text{capex}}, C_{\text{power}}, C_{\text{ops}}$	持有算力的资本、能源与运维成本；第七章。
$C_{\text{capital}}, C_{\text{obsolescence}}$	资金占用与技术折旧风险成本；第七章。
$S_{\text{unit}}, H_{\text{site}}$	标准化程度与项目异质性；第八章。
$T_{\text{deploy}}, C_{\text{service}}$	部署时间与服务成本；第八章。

9.3 本章小结

术语表固定了本课容易混淆的边界：开放模型不自动等于完整开源，多云不等于硬件同质，物理模块也不等于软件容器。符号表则把全文公式的记账对象集中到一处，方便在业务效用、性能、成本与容量之间来回核对。

10 总结与延伸

10.1 一条贯穿全课的教学主线

这场课的主线不是某一个芯片、框架或融资案例，而是 AI 应用怎样把「智能」变成可持续交付的产品能力。企业先用效用函数说明自己真正要优化什么，再把专有数据、工作流和反馈送入后训练；推理平台负责把专用模型接入可靠的 token path；运行时与多云控制面把分散 GPU 组织成容量；当租赁资源不足时，公司又不得不面对自有算力、能源、数据中心与资本。

可以把这一逻辑压缩成两组相互咬合的能力：




图 11: 「企业拥有的智能」与「平台交付的推理云」共同形成闭环（教学综合）¹²

10.2 做产品与基础设施决策时可追问什么

1. **目标**：用户真正感知的是首 token、完整输出、任务成功率，还是业务错误率？起止点是否统一？
2. **所有权**：哪些数据、反馈与效用函数只有本企业拥有？它们能否形成可持续后训练闭环？
3. **交付**：模型是否进入关键 token path？路由、伸缩、监控、故障恢复和退出迁移怎样验证？
4. **供给**：多云只是提高议价，还是确实保证了目标区域、型号与时间窗口的容量？
5. **经济性**：成本比较是否把资本、能源、运维、利用率和折旧全部算入，而不只比较租金与采购价？
6. **可替换性**：哪些边界必须稳定，哪些运行时、kernel、芯片或模型架构应允许被替换？
7. **证据层级**：数字来自公开审计、公司自报、讲者预测、主持人转述，还是本文的教学重绘？

¹²综合来源时间区间：00:07:02-00:18:28、00:26:38-00:39:17 与 00:41:41-00:42:01。该图不是 Baseten 官方产品图。

10.3 仍值得继续研究的开放问题

第一，开放模型的质量、开放层级和发布激励怎样量化，才能把「足够好」从口号变成可检验条件？第二，prefill/decode 解耦与异构硬件在什么负载和规模下，能抵消软件迁移与调度复杂度？第三，自有算力和租赁组合怎样随利用率、融资成本与架构折旧动态调整？第四，算力期货需要怎样的标准的、清算与履约机制，才不会只把不透明的双边合同换一个名字？

这些问题也说明为什么课程最后没有停在一个固定答案上。Tuhin 的内容性结尾是：优化机会遍布整个栈，但新的模型架构会让既有优势重新洗牌（00:48:25–00:49:04）。因此，最有韧性的系统不是押中永不变化的实现，而是清楚规定可验证的产品边界，并为底层变化保留迁移空间。

10.4 本章小结

企业拥有的智能，来自效用函数、专有数据、开放基础模型与后训练闭环；推理云的能力，则来自运行时、可靠性、多云调度、容量与资本。两者只有在真实请求和反馈中闭合，才会从「调用模型」升级为可持续产品。课程把这条链从应用一路推到能源与政策，也留下一个朴素结论：接口要稳定，证据要分层，实现要允许重做。